



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ &
ΠΛΗΡΟΦΟΡΙΚΗΣ

**Τεχνητά Νευρωνικά Δίκτυα εφαρμοσμένα σε
στατιστικά στοιχεία καλαθοσφαιριστών για την
εκτίμηση της απόδοσής τους σε αγώνες.**

ΧΡΥΣΟΓΕΛΟΣ ΑΛΕΞΑΝΔΡΟΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Γ. - Π. Κ. Οικονόμου, Ε.ΔΙ.Π. (Επιβλέπων)

Σπυρίδων Σιούτας, Δ.Ε.Π. (μέλος)

Κωνσταντίνος Τσίγλας, Δ.Ε.Π. (μέλος)

ΠΑΤΡΑ, Μάιος 2023

Χρυσόγελος Αλέξανδρος

ΠΡΟΛΟΓΟΣ

Η παρούσα Διπλωματική Εργασία εκπονήθηκε στα πλαίσια του προπτυχιακού κύκλου σπουδών του Τμήματος Μηχανικών Η/Υ και Πληροφορικής της Πολυτεχνικής Σχολής του Πανεπιστημίου Πατρών υπό την επίβλεψη του κ. Γεωργίου Πέτρου Οικονόμου μέλους του εργαστηριακού διδακτικού προσωπικού.

Αρχικά, διατρέχει τη σχετική βιβλιογραφία, για την κατανόηση των νευρωνικών δικτύων και παρέχει ενδιαφέροντα στοιχεία για την καλαθοσφαίριση και το στοιχηματισμό. Εν συνεχεία, μελετώνται οι εφαρμογές των νευρωνικών δικτύων στις διάφορες πτυχές της καθημερινότητας μας και καταγράφονται τα βασικά είδη των νευρωνικών δικτύων. Στα τελευταία κεφάλαια, αναλύεται η υλοποίηση του επιλεγέντος νευρωνικού δικτύου για πρόβλεψη της απόδοσης των καλαθοσφαιριστών καθώς και καλαθοσφαιριστριών στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης.

Σκοπός της συγκεκριμένης εργασίας είναι να διερευνηθεί η χρήση των αλγορίθμων τεχνητών νευρωνικών δικτύων (ANN) και του αλγορίθμου λειτουργίας βάσης ακτίνας (RBF) στην πρόβλεψη του μέσου αριθμού σκοραρίσματος των αθλητών και αθλητριών του NBA και WNBA αντίστοιχα. Με το αυξανόμενο ενδιαφέρον για την μηχανική μάθηση, η εφαρμογή των νευρωνικών δικτύων έχει γίνει όλο και πιο δημοφιλής σε διάφορους τομείς. Το NBA, ως έναν από τα πιο εξελιγμένα και διάσημα αθλητικά πρωταθλήματα, προσφέρει μια ιδανική ευκαιρία για να διερευνηθεί η αποτελεσματικότητα αυτών των αλγορίθμων στην πρόβλεψη της απόδοσης των παικτών. Η παρούσα εργασία θα εξετάσει την υλοποίηση των αλγορίθμων ANN και RBF στην πρόβλεψη του μέσου αριθμού σκοραρίσματος των παικτών και παικτριών του NBA και WNBA αντίστοιχα σύμφωνα με διάφορα χαρακτηριστικά, όπως η προηγούμενη απόδοση του παίκτη, όπου περιλαμβάνονται στατιστικά όπως ποσοστά ευστοχίας, ριμπάουντ κ.α. Τα αποτελέσματα αυτής της μελέτης θα συμβάλλουν στην καλύτερη κατανόηση της αποτελεσματικότητας των νευρωνικών δικτύων στην πρόβλεψη της απόδοσης, καθώς επίσης να δοθεί και το έναυσμα για την παροχή εισηγήσεων και σε άλλα αθλήματα. Η συλλογή και η ανάλυση των δεδομένων θα πραγματοποιηθεί με τη χρήση επιλεγμένων προγραμματιστικών εργαλείων και τεχνικών μηχανικής μάθησης, ενώ οι επιδόσεις των αλγορίθμων θα αξιολογηθούν μέσω της σύγκρισής τους με πραγματικά στατιστικά στοιχεία των παικτών του NBA.

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω τον κ. Οικονόμου για την ευκαιρία που μου έδωσε αναθέτοντας μου την παρούσα Διπλωματική Εργασία αλλά κυρίως και για την πολύτιμη συνεισφορά του στην εκπόνηση της, μέσω της καθοδήγησης και των συμβουλών που προσέφερε καθ' όλη τη διάρκεια της συνεργασίας μας.

Επιπλέον, θα ήθελα να εκφράσω τις θερμές μου ευχαριστίες στους υπόλοιπους καθηγητές που έχουν συμμετάσχει στο ακαδημαϊκό μου ταξίδι, παρέχοντας μου μια πλούσια και ποικιλόμορφη εκπαιδευτική εμπειρία ενθαρρύνοντας με να αναπτύξω τις ικανότητές μου και να επιτύχω τους στόχους μου.

Τέλος, θα ήθελα να ευχαριστήσω την αδελφή μου, καθώς μου παρείχε καθοδήγηση και συμβουλές κατά τις δύσκολες στιγμές ενθαρρύνοντας με να συνεχίσω και να ξεπεράσω τα εμπόδια που προέκυπταν. Η απόλυτη αγάπη και στήριξή της μου έδωσε την απαραίτητη αυτοπεποίθηση και θάρρος να αντιμετωπίσω νέες προκλήσεις και να επιδιώξω την αριστεία σε όλα όσα κάνω.

Χρυσόγελος Αλέξανδρος

Απρίλιος 2023

ΠΕΡΙΕΧΟΜΕΝΑ

ΠΡΟΛΟΓΟΣ.....	i
ΕΥΧΑΡΙΣΤΙΕΣ	iii
ΠΕΡΙΕΧΟΜΕΝΑ.....	v
ΠΙΝΑΚΑΣ ΕΙΚΟΝΩΝ	xi
ΠΙΝΑΚΑΣ ΕΞΙΣΩΣΕΩΝ	xv
ΠΙΝΑΚΕΣ.....	xvii
ΠΙΝΑΚΑΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ.....	xix
ΠΕΡΙΛΗΨΗ.....	xxi

1.	Εισαγωγή.....	1
1.1.	Αντικείμενο διπλωματικής εργασίας.....	1
1.2.	Αθλητισμός και στοιχηματισμός.....	2
1.2.2.	Γυναικείος αθλητισμός στην αρχαία Ελλάδα	3
1.2.3.	Πρώιμη μορφή στοιχηματισμού.....	3
1.2.4.	Ανάλυση αθλητισμού και στοιχηματισμού στη νεότερη εποχή.....	5
1.2.4.1.	Εισαγωγή στατιστικών στα αθλήματα	5
1.2.4.2.	Στατιστικά και στοιχηματισμός στο Αμερικανικό πρωτάθλημα καλαθοσφαίρισης.....	6
1.3.	Ιστορικά στοιχεία στα NBA και WNBA	7
1.3.1.	Πρωτάθλημα NBA	7
1.3.2.	Πρωτάθλημα WNBA	8
1.4.	Δομή των πρωταθλημάτων στις μέρες μας	9
1.4.1.	Δομή NBA.....	9
1.4.2.	Δομή WNBA.....	11
1.5.	Παρουσία Ελλήνων αθλητών και αθλητριών σε NBA και WNBA	12
1.5.1	Ταλαντούχοι Έλληνες που συμμετέχουν στο NBA	12

1.	Εισαγωγή <συνέχεια>	
1.5.2	Ταλαντούχες Ελληνίδες που συμμετέχουν στο WNBA.....	13
1.6.	Ενδιαφέροντα στατιστικά για NBA και WNBA σήμερα.....	13
2.	Νευρωνικά δίκτυα (Neural Networks)	15
2.1.	Εισαγωγή στα νευρωνικά δίκτυα	15
2.1.1.	Δομή νευρωνικών δικτύων.....	15
2.1.2.	Εφαρμογές τεχνητών νευρωνικών δικτύων	16
2.1.2.1.	Εφαρμογές με χρήση Linear Neural Networks	16
2.1.2.2.	Εφαρμογές με χρήση Multielement nonlinear Neural Networks	17
2.2.	Είδη τεχνητών νευρωνικών δικτύων	20
2.2.1.	Feed-forward Neural Networks.....	21
2.2.1.1.	Perceptrons	22
2.2.1.2.	Multi-layer Perceptrons.....	23
2.2.1.3.	Radial Basis Function Neural Networks	23
2.2.2.	Recurrent Neural Networks (RNNs)	24
2.2.2.1.	Hopfield Networks	26
2.2.2.2.	Long Short-Term Memory Networks (LSTMs).....	27
2.2.3.	Convolutional Neural Networks (CNNs).....	28
2.2.4.	Autoencoders.....	29
2.2.5.	Generative Adversarial Networks (GANs)	30
2.3.	Χρήση τεχνητών νευρωνικών δικτύων στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης	31

3.	Υλοποίηση σε λογισμικό.....	33
3.1.	Εισαγωγή.....	33
3.2.	Υπολογιστής που χρησιμοποιήθηκε	33
3.3.	Δεδομένα.....	34
3.3.1.	Προεπεξεργασία δεδομένων	39
3.4.	Τεχνητά νευρωνικά δίκτυα που χρησιμοποιήθηκαν	39
3.5.	Εργαλεία υλοποίησης.....	40
3.5.1.	Google Colaboratory	40
3.5.1.1.	PYTHON.....	41
3.5.1.2.	Βιβλιοθήκη Tensorflow	41
3.5.2.	MATLAB.....	42
4.	Περιγραφή Προγράμματος.....	50
4.1.1.	Πρόβλεψη απόδοσης κανονικής περιόδου NBA	50
4.1.1.1.	Υλοποίηση σε γλώσσα PYTHON.....	50
4.1.1.1.1.	Πειράματα μέγιστης ακρίβειας	52
4.1.1.1.2.	Πρόσθετα Πειράματα	57
4.1.1.1.2.1.	Πειράματα με διαφορετικά train-test splits	57
4.1.1.1.2.2.	Πειράματα με διαφορετικό αριθμό epochs.....	59
4.1.1.1.2.3.	Πειράματα με περισσότερες Loss functions.....	60
4.1.1.1.2.4.	Διαφορετική επιλογή κρυφών επίπεδων.....	61
4.1.1.1.2.5.	Διαφορετική επιλογή συναρτήσεων ενεργοποίησης	61
4.1.1.1.2.6.	Διαφορετική επιλογή εισόδων	62
4.1.1.2.	Υλοποίηση με MATLAB	63
4.1.1.2.1.	Πείραμα μέγιστης ακρίβειας.....	63
4.1.1.2.2.	Πρόσθετα Πειράματα	65
4.1.1.2.2.1.	Πειράματα με διαφορετικά test-train splits	66

4.	Περιγραφή Προγράμματος <συνέχεια>	
4.1.1.2.2.2.	Διαφορετική επιλογή κρυφών επίπεδων.....	67
4.1.1.2.2.3.	Διαφορετική επιλογή εισόδων	68
4.1.1.3.	Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων PYTHON -MATLAB	69
4.1.2.	Πρόβλεψη σε συνθήκες clutch NBA	70
4.1.2.1.	Υλοποίηση σε γλώσσα PYTHON.....	71
4.1.2.1.1.	Πειράματα μέγιστης ακρίβειας	72
4.1.2.1.2.	Πρόσθετα πειράματα	75
4.1.2.1.2.1.	Πειράματα με διαφορετικά train-test splits	75
4.1.2.1.2.2.	Πειράματα με διαφορετικό αριθμό «epochs»	77
4.1.2.1.2.3.	Πειράματα με περισσότερες Loss functions.....	78
4.1.2.1.2.4.	Διαφορετική επιλογή κρυφών επίπεδων.....	79
4.1.2.1.2.5.	Διαφορετική επιλογή συναρτήσεων ενεργοποίησης	79
4.1.2.1.2.6.	Διαφορετική επιλογή εισόδων	80
4.1.2.2.	Υλοποίηση σε MATLAB.....	81
4.1.2.2.1.	Πείραμα μέγιστης ακρίβειας.....	81
4.1.2.2.2.	Πρόσθετα Πειράματα	83
4.1.2.2.2.1.	Πειράματα με διαφορετικά train-test splits	83
4.1.2.2.2.2.	Διαφορετική επιλογή κρυφών επιπέδων.....	86
4.1.2.2.2.3.	Διαφορετική επιλογή εισόδων	86
4.1.2.3.	Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων PYTHON - MATLAB	87
4.1.3.	Πρόβλεψη απόδοσης κανονικής περιόδου WNBA	88
4.1.3.1.	Υλοποίηση σε γλώσσα PYTHON.....	89
4.1.3.1.1.	Πειράματα μέγιστης ακρίβειας	89
4.1.3.1.2.	Πρόσθετα πειράματα	91
4.1.3.1.2.1.	Διαφορετική επιλογή train-test splits.....	92

4.	Περιγραφή Προγράμματος <συνέχεια>	
4.1.3.1.2.2.	Διαφορετική επιλογή «epochs»	94
4.1.3.1.2.3.	Διαφορετική επιλογή loss functions	95
4.1.3.1.2.4.	Διαφορετική επιλογή κρυφών επιπέδων.....	96
4.1.3.1.2.5.	Διαφορετική επιλογή συναρτήσεων ενεργοποίησης	96
4.1.3.1.2.6.	Διαφορετική επιλογή εισόδων	97
4.1.3.2.	MATLAB.....	98
4.1.3.2.1.	Πείραμα μέγιστης ακρίβειας.....	98
4.1.3.2.2.	Πρόσθετα πειράματα	99
4.1.3.2.2.1.	Διαφορετική επιλογή train-test splits.....	100
4.1.3.2.2.2.	Διαφορετική επιλογή κρυφών επιπέδων.....	101
4.1.3.2.2.3.	Διαφορετική επιλογή εισόδων	102
4.1.3.3.	Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων	103
5.	Συμπεράσματα.....	105
6.	Μελλοντική εργασία	107
Παράρτημα		109
Αναφορές.....		113

ΠΙΝΑΚΑΣ ΕΙΚΟΝΩΝ

Εικόνα 1: Τυχερά παίγνια στην Αρχαία Ελλάδα	4
Εικόνα 2: NBA Champions 2021-22: Golden State Warriors	10
Εικόνα 3: WNBA Champions 2022: Las Vegas Aces	12
Εικόνα 4: Στατιστικά Lebron James	35
Εικόνα 5: Ενδεικτική εικόνα βάσης δεδομένων NBA σε clutch χρόνο	37
Εικόνα 6: Ενδεικτική εικόνα βάσης δεδομένων WNBA	38
Εικόνα 7: Relu figure (Γραφική παράσταση Relu)	44
Εικόνα 8: Sigmoid figure (Γραφική παράσταση Sigmoid)	44
Εικόνα 9: Elu figure (Γραφική παράσταση Elu)	45
Εικόνα 10: Softmax figure (Γραφική παράσταση Softmax)	46
Εικόνα 11: Softsign (Γραφική παράσταση Softsign)	47
Εικόνα 12: Δομή TNΔ NBA	53
Εικόνα 13: Δομή RBF NBA	53
Εικόνα 14: ANN Train - Test loss (80%-20% train-test)	55
Εικόνα 15: ANN Πειράματα (80%-20% train-test) και ακρίβεια	55
Εικόνα 16: RBF Train - Test loss (80%-20% train-test)	55
Εικόνα 18: RBF Πειράματα(80%-20% train-test) και ακρίβεια	55
Εικόνα 19: ANN Train loss- Test loss (70%-30% train-test)	57
Εικόνα 20: ANN Πειράματα (70%-30% train-test) και ακρίβεια	57
Εικόνα 21: RBF Train loss- Test loss (70%-30% train-test)	57
Εικόνα 22: RBF Πειράματα (70%-30% train-test) και ακρίβεια	57
Εικόνα 23: ANN Train loss- Test loss (90%-10% train-test)	58
Εικόνα 24: ANN Πειράματα (90%-10% train-test) και ακρίβεια	58
Εικόνα 25: RBF Train loss- Test loss (90%-10% train-test)	58
Εικόνα 26: RBF Πειράματα (90%-10% train-test) και ακρίβεια	58
Εικόνα 27: ANN Train loss- Test loss (60%-40% train-test)	58
Εικόνα 28: ANN Train loss- Test loss (60%-40% train-test) και ακρίβεια	58
Εικόνα 29: RBF Train loss- Test loss (60%-40% train-test)	59
Εικόνα 30: RBF Πειράματα (60%-40% train-test) και ακρίβεια	59

ΠΙΝΑΚΑΣ ΕΙΚΟΝΩΝ <συνέχεια>

Εικόνα 31: Δομή ΤΝΔ MATLAB.....	64
Εικόνα 32: Πειράματα MATLAB 80%train-20%test splits.....	65
Εικόνα 33: Πειράματα MATLAB 90% train-10% splits	66
Εικόνα 34: Πειράματα MATLAB 70% train-30%test splits.....	66
Εικόνα 35: Πειράματα MATLAB 60% train-40%test split	67
Εικόνα 36: ANN Train - Test loss (75%-25% train-test).....	73
Εικόνα 37: ANN Πειράματα (80%-20% train-test) και ακρίβεια	73
Εικόνα 38: ANN Πειράματα αθλητών με κακά ποσοστά στον χρόνο clutch αλλά υψηλούς Μ.Ο.	73
Εικόνα 39: RBF Train - Test loss (80%-20% train-test).....	74
Εικόνα 40: RBF Πειράματα(80%-20% train-test) και ακρίβεια	74
Εικόνα 41:RBF Πειράματα αθλητών με κακά ποσοστά στον χρόνο clutch αλλά υψηλούς Μ.Ο.	74
Εικόνα 42: ANN Train loss- Test loss (70%-30% train-test).....	75
Εικόνα 43:ANN Πειράματα (70%-30% train-test)	75
Εικόνα 44: RBF Train loss- Test loss (70%-30% train-test).....	75
Εικόνα 45: RBF Πειράματα (70%-30% train-test)	75
Εικόνα 46: ANN Train loss- Test loss (90%-10% train-test).....	76
Εικόνα 47: ANN Πειράματα (90%-10% train-test)	76
Εικόνα 48: RBF Train loss- Test loss (90%-10% train-test).....	76
Εικόνα 49: RBF Πειράματα (90%-10% train-test) και ακρίβεια	76
Εικόνα 50: ANN Train loss- Test loss (60%-40% train-test).....	76
Εικόνα 51: ANN Πειράματα (60%-40% train-test) και ακρίβεια	76
Εικόνα 52: RBF Train loss- Test loss (60%-40% train-test).....	77
Εικόνα 53: RBF Πειράματα (60%-40% train-test) και ακρίβεια	77
Εικόνα 54: πειράματα μέγιστης ακρίβειας MATLAB	82
Εικόνα 55: MATLAB 90%-10% train - test split	83
Εικόνα 56: MATLAB 75%-25% train - test split	84

ΠΙΝΑΚΑΣ ΕΙΚΟΝΩΝ <συνέχεια>

Εικόνα 57: MATLAB 70%-30% train - test split	84
Εικόνα 58: MATLAB 60%-40% train - test split	85
Εικόνα 59: ANN Train - Test loss (80%-20% train-test) <συνέχεια>	90
Εικόνα 60: ANN Train - Test loss (80%-20% train-test).....	90
Εικόνα 61: RBF Train - Test loss (80%-20% train-test).....	91
Εικόνα 62: RBF Πειράματα (80%-20% train-test) και ακρίβεια	91
Εικόνα 63: ANN Train - Test loss (90%-10% train-test).....	92
Εικόνα 64: ANN Πειράματα (90%-10% train-test) και ακρίβεια	92
Εικόνα 65: RBF Train - Test loss (90%-10% train-test	92
Εικόνα 66: RBF Πειράματα (90%-10% train-test) και ακρίβεια	92
Εικόνα 67: ANN Train - Test loss (70%-30%) train-test.....	93
Εικόνα 68: ANN Πειράματα (70%-30% train-test) και ακρίβεια	93
Εικόνα 69: RBF Train - Test loss (70%-30%) train-test	93
Εικόνα 70: RBF Πειράματα (70%-30% train-test) και ακρίβεια	93
Εικόνα 71: ANN Train - Test loss (60%-40%) train-test.....	93
Εικόνα 72: RBF Πειράματα (70%-30% train-test) και ακρίβεια	93
Εικόνα 73: RBF Train - Test loss (60%-40%) train-test.....	94
Εικόνα 74: RBF Πειράματα (70%-30% train-test) και ακρίβεια	94
Εικόνα 75: ANN MSLE loss function (πείραμα 80% - 20% train -test split).....	96
Εικόνα 76: ANN elu- softmax activation function (πείραμα 80% - 20% train -test split)	97
Εικόνα 77: ANN χωρίς τραυματισμούς Εικόνα 78: ANN πειράματα χωρίς FG%. 98	
Εικόνα 79: MATLAB μέγιστης ακρίβειας αποτελέσματα.....	99
Εικόνα 80: MATLAB 90%-10% train - test split	100
Εικόνα 81: MATLAB 70%-30% train - test split	100
Εικόνα 82: MATLAB 60%-40% train - test split	101
Εικόνα 83: Ενδεικτική εικόνα βάσης δεδομένων NBA	109
Εικόνα 84: Ενδεικτικές εικόνες κώδικα MATLAB	110

ΠΙΝΑΚΑΣ ΕΙΣΩΣΕΩΝ

Εξίσωση 1: Gaussian function	23
------------------------------------	----

ΠΙΝΑΚΕΣ

Πίνακας 1: Πρώιμη μορφή Αμερικάνικου πρωταθλήματος καλαθοσφαίρισης ανδρών (NBA wiki)	8
Πίνακας 2: Πρώιμη μορφή Αμερικάνικου πρωταθλήματος καλαθοσφαίρισης γυναικών (WNBA wiki).....	8
Πίνακας 3: Σημερινή μορφή NBA (NBA wiki).....	9
Πίνακας 4: Σημερινή μορφή WNBA (WNBA wiki)	11
Πίνακας 5: Αποτελέσματα βέλτιστων πειραμάτων κανονικής περιόδου NBA	55
Πίνακας 6: Περαιτέρω πειράματα για την κανονική περίοδο NBA	59
Πίνακας 7: Πειράματα ANN με διαφορετικά Epochs	59
Πίνακας 8: Πειράματα RBF με διαφορετικά Epochs.....	60
Πίνακας 9: Πειράματα ANN- RBF με διαφορετικές loss functions	60
Πίνακας 10: Πειράματα ANN-RBF με διαφορετικό αριθμό κρυφών επιπέδων	61
Πίνακας 11: Πειράματα ANN-RBF με διαφορετικές activation functions.....	62
Πίνακας 12: Διαφορετική επιλογή εισόδων	63
Πίνακας 13: Βέλτιστα αποτελέσματα MATLAB	64
Πίνακας 14: Ενδεικτικά πειράματα 90%-10% train-test.....	66
Πίνακας 15: Ενδεικτικά πειράματα 70%-30% train-test.....	66
Πίνακας 16: Ενδεικτικά πειράματα 60%-40% train-test.....	67
Πίνακας 17: Διαφορετική επιλογή κρυφών επιπέδων MATLAB.....	67
Πίνακας 18: Διαφορετική επιλογή εισόδων MATLAB	68
Πίνακας 19: Συγκεντρωτικά αποτελέσματα πειραμάτων	69
Πίνακας 20: Χρόνοι εκτελέσεων μεταξύ εργαλείων.....	69
Πίνακας 21: Χωρίς τραυματισμούς MATLAB.....	69
Πίνακας 22: Παράμετροι βέλτιστων πειραμάτων clutch	72
Πίνακας 23: Αποτελέσματα βέλτιστων πειραμάτων ANN clutch	73
Πίνακας 24: Αποτελέσματα βέλτιστων πειραμάτων RBF clutch	74
Πίνακας 25: Περαιτέρω πειράματα clutch.....	77
Πίνακας 26: Αποτελέσματα ANN με διαφορετικό αριθμό epochs.....	78
Πίνακας 27: Αποτελέσματα RBF με διαφορετικό αριθμό epochs	78

ΠΙΝΑΚΕΣ <συνέχεια>

Πίνακας 28: Πειράματα με διαφορετικές loss functions	78
Πίνακας 29: Πειράματα με διαφορετικό αριθμό κρυφών επιπέδων	79
Πίνακας 30: Πειράματα διαφορετικών συναρτήσεων ενεργοποίησης.....	79
Πίνακας 31: Πειράματα διαφορετικής επιλογής εισόδου	80
Πίνακας 32: Περαιτέρω πειράματα train-test splits	85
Πίνακας 33: Διαφορετική επιλογή αριθμού κρυφών επιπέδων	86
Πίνακας 34: Διαφορετική επιλογή εισόδων	86
Πίνακας 35: Συγκεντρωτικά αποτελέσματα μεταξύ υλοποιήσεων	87
Πίνακας 36: Χρόνος εκτελέσεων μεταξύ υλοποιήσεων	87
Πίνακας 37: Παράμετροι βέλτιστων αποτελεσμάτων WNBA.....	90
Πίνακας 38: Αποτελέσματα βέλτιστων πειραμάτων WNBA	91
Πίνακας 39: Περαιτέρω πειράματα WNBA.....	94
Πίνακας 40: Πειράματα σε ANN με διαφορετική επιλογή epochs.....	94
Πίνακας 41: Πειράματα σε RBF με διαφορετική επιλογή epochs.....	94
Πίνακας 42: Πειράματα με διαφορετική επιλογή loss functions	95
Πίνακας 43: Πειράματα με διαφορετικό αριθμό κρυφών επιπέδων	96
Πίνακας 44: Πειράματα με διαφορετική επιλογή συναρτήσεων ενεργοποίησης.....	96
Πίνακας 45: Διαφορετική επιλογή εισόδων	97
Πίνακας 46: Πειράματα μέγιστης ακρίβειας MATLAB.....	98
Πίνακας 47: Περαιτέρω πειράματα MATLAB.....	101
Πίνακας 48: Πειράματα επιλογής διαφορετικού αριθμού κρυφών επιπέδων	101
Πίνακας 49: Πειράματα με διαφορετική επιλογή εισόδων MATLAB	102
Πίνακας 50: Συγκεντρωτικά αποτελέσματα WNBA	103
Πίνακας 51: Χρόνοι εκτέλεσης μεταξύ υλοποιήσεων	103
Πίνακας 52: Αποτελέσματα χωρίς είσοδο τραυματισμών	103
Πίνακας 53: επεξήγηση στατιστικών	111

ΠΙΝΑΚΑΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ

ABA	American Basketball Association
BAA	Basketball Association of America
CNNs	Convolutional Neural Networks
FFNNs	Feedforward Neural Networks
GANs	Generative Adversarial Networks
HNC	Hecht-Nielsen Corporation
LSTMs	Long Short-Term Memory Networks
LVQ	Learning Vector Quantization
MLPs	Multi-layer Perceptrons
MSE	Mean Squared Error
NBA	National Basketball Association
NBL	National Basketball League
ANN	Artificial Neural Networks
RBF	Radial Basis Function
RBFNs	Radial Basis Function Networks
RNNs	Recurrent Neural Networks
WNBA	Women National Basketball Association
ΣΒΑ	Συνάρτηση Βάσης Ακτίνας
TNΔ	Τεχνητά Νευρωνικά Δίκτυα
Μ.Ο.	Μέσος Όρος

ΠΕΡΙΛΗΨΗ

Είναι ευρέως γνωστό ότι η καλαθοσφαίριση είναι ένα άθλημα που βασίζεται και μπορεί να αναλυθεί σε μεγάλο βαθμό με αριθμούς. Η παρούσα εργασία επιδιώκει να αξιοποιήσει το συγκεκριμένο γεγονός για την ανάπτυξη μοντέλων υψηλής ακρίβειας. Γενικότερα, η εργασία μας επιδιώκει να επιλύσει το πρόβλημα πρόβλεψης του μέσου όρου πόντων που πετυχαίνουν οι καλαθοσφαιριστές και καλαθοσφαιρίστριες στο αμερικάνικο πρωτάθλημα NBA και WNBA ¹στην κανονική περίοδο μέσω της χρήσης αρχιτεκτονικών νευρωνικών δικτύων. Επίσης, εξετάζεται η απόδοση των αθλητών του NBA σε κρίσιμες χρονικές στιγμές ή αλλιώς «clutch» στην κανονική περίοδο του πρωταθλήματος NBA. Προκειμένου να επιτευχθεί αυτό, γίνεται χρήση των αλγορίθμων ANN («artificial neural networks») και RBF ²(«radial basis function») υλοποιημένων σε PYTHON και σε MATLAB.

Στόχος μας είναι η αξιολόγηση και σύγκριση της ακρίβειας μεταξύ των υλοποιήσεων των προγραμμάτων των νευρωνικών δικτύων για την πρόβλεψη απόδοσης αθλητών και αθλητριών. Για την επίτευξη του γεγονότος αυτού, γίνεται χρήση ενός συνόλου δεδομένων που περιέχει διάφορα χαρακτηριστικά που σχετίζονται με την απόδοση αθλητών, όπως ποσοστά ευστοχίας, βοηθητικές πάσες, ριμπάουντ, κλεψίματα και λάθη.

Τα αποτελέσματα δείχνουν ότι οι αρχιτεκτονικές ANN και RBF είναι σε θέση να προβλέψουν τον μέσο όρο επίτευξης πόντων αθλητών και αθλητριών με ακρίβεια έως και 87% για την κανονική περίοδο του πρωταθλήματος NBA και WNBA, και έως και 81% για την πρόβλεψη μέσου όρο επίτευξης πόντων αθλητών NBA σε κρίσιμες στιγμές. Επιπλέον, η εργασία τονίζει επίσης την σημασία ορθής επιλογής των παραμέτρων και αποδεικνύει ότι ορισμένες μετρικές έχουν μεγαλύτερη επίδραση στην απόδοση από άλλες.

Σημαντικό να ειπωθεί ότι καλύτερα αποτελέσματα θα είχαν προκύψει αν είχαν χρησιμοποιηθεί δεδομένα τα οποία είναι ιδιωτικά σε κάθε αθλητικό οργανισμό όπως ποσοστό διαχείρισης της επίθεσης από τον εκάστοτε αθλητή, στάση σώματος όταν γίνεται προσπάθεια σουτ, κερδισμένες «μάχες» με την αντίπαλη ομάδα. Δυστυχώς, παρόμοια δεδομένα δεν γίνονται γνωστά

Συνολικά, τα ευρήματα της εργασίας αυτής συμβάλλουν στην κατανόηση των δυνατοτήτων των νευρωνικών δικτύων στον τομέα της ανάλυσης δεδομένων αθλητισμού παρέχοντας ενδεχομένως πολύτιμες πληροφορίες σε προπονητές, κυνηγούς ταλέντων («scouters») και οπαδούς που επιθυμούν να αναλύσουν το άθλημα και να εμβαθύνουν σε αυτό. Εκμεταλλευόμενοι λοιπόν τον πλούτο των δεδομένων που είναι δημοσίως διαθέσιμα στο διαδίκτυο για τα πρωταθλήματα NBA και WNBA, η εργασία μας επιδεικνύει την ισχύ των νευρωνικών δικτύων στο καλύτερο πρωτάθλημα καλαθοσφαίρισης παγκοσμίως.

¹ WNBA: Women National Basketball Association

²RBF: Radial Basis Function

Όσον αφορά τη δομή της εργασίας, αρχικά, γίνεται μία εισαγωγή στον αθλητισμό και στις πρώτες του γραπτές αναφορές στην ανθρωπότητα τονίζοντας ταυτοχρόνως την έμφυτη ανάγκη του ανθρώπου να καταφύγει σε μορφές εκτόνωσης, ψυχαγωγίας και εύκολου κέρδους. Επίσης, αναφέρεται η εμφάνιση του στοιχηματισμού και η άμεση σύνδεση του με στατιστικές κατηγορίες αθλημάτων και το πως συνέβαλλε στην ανάπτυξη του αθλήματος. Θα αναλυθεί ακόμα, η δομή των πρωταθλημάτων NBA και WNBA όπου αργότερα θα διενεργηθούν πειράματα.

Στο επόμενο κεφάλαιο, περιγράφεται η δομή των νευρωνικών δικτύων και οι εφαρμογές τους. Αναλύονται τα πιο γνωστά είδη νευρωνικών δικτύων όσον αφορά τις εφαρμογές, τα πλεονεκτήματα και τα μειονεκτήματα τους, δίνοντας έμφαση παράλληλα στα είδη δικτύων που θα χρησιμοποιηθούν για την ανάπτυξη του προγράμματος παρακάτω.

Στην συνέχεια, περιγράφεται η διαδικασία ανάπτυξης του προγράμματος. Ειδικότερα, αναλύεται από το πως πραγματοποιήθηκε η συλλογή δεδομένων και τι διαδικασία ακολουθήθηκε έως τις εφαρμογές που χρησιμοποιήθηκαν και τις συγκεκριμένες διεπαφές που αξιοποιήθηκαν.

Ακολουθεί το πιο σημαντικό κεφάλαιο της πτυχιακής αυτής εργασίας όπου παρουσιάζεται η δομή των πειραμάτων και τα αποτελέσματα τους. Περιγράφονται τρία ξεχωριστά προγράμματα με τρεις ξεχωριστές υλοποιήσεις, όπως και τα χαρακτηριστικά και τις παραμέτρους του καθενός. Σημαντικό είναι να σημειωθεί ότι η ακρίβεια των τριών προγραμμάτων κυμαίνεται μεταξύ 78 έως και 87 τις εκατό. Ταυτοχρόνως, γίνεται παρουσίαση περαιτέρω πειραμάτων με διαφορετικές παραμέτρους και εργαλεία προκειμένου να αποδειχθεί η εγκυρότητα του εκάστοτε προγράμματος.

Στο τελευταίο κομμάτι του κειμένου αυτού γίνεται περιγραφή της χρησιμότητας της εργασίας και του πως είναι δυνατόν να γίνει αξιοποίηση των ευρημάτων της όχι μόνο στον χώρο του αθλητισμού αλλά και σε άλλους τομείς των τυχερών παιγνίων. Κλείνοντας δίνεται έναυσμα για αξιοποίηση της παρούσας διπλωματικής εργασίας σε περισσότερους πειραματισμούς για την διεύρυνση της θεματολογίας και αξιοποίησης των ευρημάτων σε άλλους τομείς του αθλητισμού.

1. Εισαγωγή

1.1. Αντικείμενο διπλωματικής εργασίας

Τα τελευταία χρόνια, η εφαρμογή των νευρωνικών δικτύων χαίρει ευρείας αποδοχής σε διάφορους τομείς λόγω της ικανότητάς εκμάθησης πολύπλοκων πρότυπων και επιθυμητής ακρίβειας στις προβλέψεις σε δεδομένα στα οποία δεν εκπαιδεύθηκαν. Ένας από τους τομείς αυτούς είναι ο αθλητικός, όπου η χρήση μοντέλων μηχανικής μάθησης έχει γίνει όλο και πιο δημοφιλής στην ανάλυση απόδοσης των αθλητών και στην πρόβλεψη αποτελεσμάτων αγώνων.

Στην παρούσα εργασία ερευνάται η χρήση των νευρωνικών δικτύων για την πρόβλεψη του μέσου αριθμού πόντων που σκοράρουν ο καλαθοσφαιριστής ή η καλαθοσφαιρίστρια στο Εθνικό πρωτάθλημα καλαθοσφαίρισης της Αμερικής, εν συντομία NBA ή WNBA αντίστοιχα. Ειδικότερα, πραγματοποιήθηκε η εκπαίδευση δύο διαφορετικών αλγορίθμων νευρωνικών δικτύων: σε PYTHON ο αλγόριθμος του Artificial Neural Network (ANN) και του Radial Basis Function (RBF), ενώ σε MATLAB εφαρμόστηκε και πάλι του ANN για σύγκριση αποτελεσμάτων.

Ως είσοδοι, δίνονται σε όλες τις περιπτώσεις στοιχεία από διαφορετικές στατιστικές κατηγορίες, όπως ποσοστό εύστοχων προσπαθειών, ευστοχία ελεύθερων βολών και λεπτά συμμετοχής. Επιπλέον, λαμβάνονται υπόψιν και στοιχεία που έχουν να κάνουν με την φυσική κατάσταση του εκάστοτε αθλητή όπως τραυματισμοί και λεπτά συμμετοχής. Τα προαναφερθέντα στοιχεία δίνονται κάτω από συγκεκριμένες συνθήκες: κατά την διάρκεια ενός αγωνιστικού έτους και κάτω από συνθήκες πίεσης ή όπως αλλιώς ονομάζεται χρόνος «clutch». Σαν έξοδος δίνεται ο μέσος όρος πόντων στην αντίστοιχη περίπτωση.

Το κίνητρο της έρευνας πηγάζει από τη δυσκολία πρόβλεψης της απόδοσης των ατομικών στατιστικών αθλητών, ιδιαίτερα στο πλαίσιο ενός γρήγορου και δυναμικού αθλήματος όπως η καλαθοσφαίριση. Το συγκεκριμένο πρόγραμμα προσφέρει μια ακριβή και αξιόπιστη μέθοδο για την πρόβλεψη απόδοσης των αθλητών καλαθοσφαίρισης. Παρόμοια μοντέλα είναι δυνατόν να χρησιμοποιηθούν για την πρόβλεψη αποτελεσμάτων αθλητικών γεγονότων, ωστόσο η συγκεκριμένη εργασία εστιάζει στην απόδοση των αθλητών, ένα ιδιαίτερος κρίσιμο στοιχείο για το αποτέλεσμα των αγώνων.

Η παρούσα εργασία αποσκοπεί στο να παρουσιάσει το πρόγραμμα και τους αλγόριθμους που χρησιμοποιήθηκαν αλλά και στην εξέταση των αποτελεσμάτων που προέκυψαν κατά την εκτέλεσή του. Επιπλέον, παρουσιάζεται μια πιθανή μέθοδος για τη χρήση μηχανικής μάθησης και σε άλλα αθλήματα. Τέλος, αξίζει να αναφερθεί ότι ενδέχεται να βοηθήσει στην βελτίωση της μεθόδου προσέλκυσης και διαχείρισης ταλέντων σε αθλητικούς οργανισμούς και δη καλαθοσφαίρισης, καθώς επιτρέπει σε προπονητές και σε ανιχνευτές ταλέντων να εντοπίσουν και να αξιολογήσουν

πιο αποτελεσματικά τους αθλητές και τις αθλήτριες που έχουν τις κατάλληλες ικανότητες ώστε να συμβάλουν στην επίτευξη των στόχων ενός αθλητικού οργανισμού.

Επιπλέον, από τις πιο σημαντικές χρήσεις αποτελούν η πρόληψη τραυματισμών και η βελτίωση των αδυναμιών της επίδοσης αθλητών και αθλητριών. Είναι δυνατή η εφαρμογή σε δεδομένα ζωντανής ροής αγώνα και τραυματισμών, προβλέποντας πιθανές περιοχές κινδύνου και προσαρμόζοντας την διατροφή, την προπόνηση και τον σχεδιασμό μίας ομάδας ανάλογα. Τα αποτελέσματα των προβλέψεων ενδέχεται να βοηθήσουν προπονητές, ιατρούς και γυμναστές να προσαρμόσουν τα αντίστοιχα προγράμματα για αποφυγή τραυματισμών, βελτιώνοντας την απόδοση των ομάδων, την υγεία και απόδοση των αθλητών. Ταυτόχρονα, σε συλλογικό επίπεδο θα ήταν ιδιαίτερα χρήσιμο να χρησιμοποιηθούν για την ανάλυση των αγώνων ώστε να βελτιωθούν οι τακτικές των ομάδων, εντοπίζοντας τα ισχυρά και αδύναμα σημεία τους. Γίνεται αντιληπτό ότι η χρήση των νευρωνικών δικτύων στον αθλητισμό μπορεί να οδηγήσει σε βελτιωμένη απόδοση των αθλητών και ενισχυμένο ανταγωνιστικό πλεονέκτημα των ομάδων.

Συνολικά, η εργασία προσφέρει μια πρακτική και καινοτόμο προσέγγιση στην χρήση της μηχανικής μάθησης στον αθλητισμό δείχνοντας ότι η ανάλυση των δεδομένων μπορεί να εφαρμοστεί αποτελεσματικά για τη βελτίωση της απόδοσης των αθλητών.

1.2. Αθλητισμός και στοιχηματισμός

1.2.1. Πρώιμη μορφή αθλητισμού

Η ιστορία των αθλημάτων και του στοιχηματισμού πάνω σε αυτά χρονολογείται από τα παλαιά χρόνια. Σύμφωνα με τον Όμηρο, Πλάτωνα και Αριστοτέλη στην αρχαία Ελλάδα, η άθληση και η φυσική ευεξία ήταν σημαντικά για την πολιτιστική και πολιτική ζωή των ανθρώπων. Οι πρώτες αναφορές για στοιχηματισμό στην αρχαία Ελλάδα προέρχονται από τον Όμηρο μέσα στα έργα του «Ιλιάδα» και «Οδύσσεια» αλλά και από τον Ηρόδοτο και το έργο του «Ιστορίες».

Αναλυτικότερα, τα αθλήματα ήταν και θα είναι αναπόσπαστο κομμάτι του ανθρώπινου πολιτισμού για χιλιάδες χρόνια. Ένα από τα πρώτα παραδείγματα οργανωμένων αγώνων για το οποίο υπάρχουν αναρίθμητες αναφορές είναι οι Ολυμπιακοί αγώνες της αρχαίας Ελλάδας. Γενικότερα, ποικίλα αγωνίσματα που βασίζονταν κυρίως στην ανθρώπινη δύναμη ήταν κομμάτι των θρησκευτικών εκδηλώσεων, υποδεικνύοντας την στενή σχέση των αρχαίων Ελλήνων με τα αθλήματα και τον τρόπο ζωής τους. Αποτελούσαν αναπόσπαστο κομμάτι της παιδείας των αρχαίων Ελλήνων καθώς θεωρούσαν ότι η φυσική κατάσταση ήταν το κλειδί για την διαμόρφωση δυνατού χαρακτήρα. Οι Ολυμπιακοί αγώνες διεξάγονταν κάθε τέσσερα χρόνια στην αρχαία Ολυμπία και αποτελούσαν ένα από τα πιο σημαντικά και ιερά αθλητικά δρώμενα της εποχής. Ενδεικτικά αγωνίσματα αποτελούσαν: ο στίβος, η δισκοβολία και η πάλη (Miller S. G., Ancient Greek Athletics. , 2010).

1.2.2. Γυναικείος αθλητισμός στην αρχαία Ελλάδα

Στην αρχαία Ελλάδα, τα αθλητικά δρώμενα αποτελούσαν σημαντικό κομμάτι της κοινωνίας και ήταν στενά συνδεδεμένα με έννοιες όπως η αρετή, η τιμή και η αριστεία. Ωστόσο, παρά την κυριαρχία των ανδρών στον αθλητικό χώρο, και οι γυναίκες είχαν παρουσία στον αθλητισμό. Είναι θαυμαστό το γεγονός αν σκεφτεί κανείς ότι η θέση τους και οι ευκαιρίες τους διαμορφώνονταν από κοινωνικούς κανόνες και παραδόσεις. Παρά τους περιορισμούς που αντιμετώπιζαν, οι γυναίκες αθλήτριες στην αρχαία Ελλάδα κατάφεραν να αποδείξουν τις αθλητικές τους ικανότητες και την διάθεσή τους για αγώνα, και έτσι η συμβολή τους στην ιστορία του αθλητισμού αποτελεί σημαντικό στοιχείο που δεν πρέπει να παραλειφθεί.

Ανάμεσα στα πιο σημαντικά αθλητικά γεγονότα που ήταν ανοιχτά στις γυναίκες στην αρχαία Ελλάδα ήταν τα «Ηραία», αγώνες προς τιμήν της θεάς Ήρας, που διοργανώνονταν στην Ολυμπία. Σε αντίθεση, με τους Ολυμπιακούς Αγώνες, μόνο ανύπαντρες γυναίκες είχαν το δικαίωμα συμμετοχής στους αγώνες, οι οποίοι περιλάμβαναν αγώνες δρόμου και προσφέρονταν στις νικήτριες δάφνες ως έπαθλο. (Swaddling, 1999)

Η συμμετοχή των γυναικών στον αθλητισμό συνέβαλε στο διάλογο για τις ικανότητες και τους ρόλους των γυναικών στην κοινωνία, καθώς και στον καθορισμό της θηλυκότητας και της αρρενωπότητας. Η ιδέα της συμμετοχής των γυναικών στον αθλητισμό θεωρήθηκε ως συνταρακτική και αντισυμβατική, καθώς ερχόταν σε αντίθεση με παραδοσιακές απόψεις και αντιλήψεις για τις γυναίκες που θεωρούνταν παθητικές και απαλές. (Sansone, 2003)

Στη σύγχρονη εποχή, η συμμετοχή των γυναικών στον αθλητισμό έχει γίνει περισσότερο αποδεκτή και ενθαρρυντική, αν και οι ανισότητες και οι προκαταλήψεις σχετικά με το φύλο εξακολουθούν να υπάρχουν. Το κληροδότημα της συμμετοχής των γυναικών στον αθλητισμό στην αρχαία Ελλάδα φαίνεται στις επιτυχίες των γυναικών στον τομέα του αθλητισμού στη σύγχρονη εποχή, αποτελώντας μια απόδειξη της επιμονής και της αποφασιστικότητας των γυναικών καθ' όλη τη διάρκεια της ιστορίας. (Schulz, 1991)

1.2.3. Πρώιμη μορφή στοιχηματισμού

Στην «Ιλιάδα» υπάρχει η αναφορά ότι ο Διομήδης πόνταρε στο Σθένελο στον αρματηλάτη του ότι θα φτάσει πρώτος στις εχθρικές γραμμές. Ένα άλλο παράδειγμα από την «Οδύσσεια» είναι σχετικά με τους διεκδικητές της Πηνελόπης που πόνταραν ποιος θα καταφέρει να ρίξει με το τόξο του Οδυσσέα ένα βέλος ανάμεσα σε μια σειρά από τσεκούρια. Ωστόσο, αντιλαμβάνεται κανείς ότι αυτές οι αναφορές είναι αποδείξεις ότι ο στοιχηματισμός ήταν παρών στην αρχαία Ελλάδα αλλά δεν αποτελούσε από μόνος του μορφή δραστηριότητας αλλά πιο πολύ ήταν μια μορφή γενναιότητας, ανδρισμού και δύναμης πάρα κάποιας μορφής στοιχηματισμού.



Εικόνα 1: Τυχερά παίγνια στην Αρχαία Ελλάδα

(Τυχερά παίγνια «The history of gambling in ancient Greece», ο Αχιλλέας και Αίαντας παίζοντας ζάρια)

Μία άλλη ενδιαφέρουσα αναφορά στον στοιχηματισμό βρίσκεται στην «Ιλιάδα» του Ομήρου, όπου περιγράφεται ένας αγώνας ιπποδρόμου μεταξύ δύο αναβατών, του Νηλέα και του Αίαντα. Οι δύο αυτοί αναβάτες ανταγωνίζονταν μεταξύ τους στο άθλημα των ιπποδρομιών, έως ότου φτάσουν στον τερματισμό «σαν νεκροί», ψυχαγωγώντας με αυτόν τον τρόπο το κοινό. Ταυτόχρονα, οι θεατές όπως είναι γνωστό στην αρχαία Ελλάδα, είχαν την δυνατότητα να ποντάρουν στους αναβάτες και στα άλογα τους, καθώς και σε άλλες λεπτομέρειες του αγώνα, όπως στο χρόνο που θα χρειαστεί ο νικητής να τερματίσει ή στον αριθμό των γύρων που θα κάνουν οι αναβάτες.

Επιπροσθέτως, πρέπει να σημειωθεί ότι έχουν βρεθεί ενδείξεις στοιχηματισμού σε αρκετά αθλητικά δρώμενα όπως στα Ίσθμια, στα Νέμεα, στα Πύθια και στους πολύ δημοφιλείς Ολυμπιακούς αγώνες. Αρκετοί πολίτες στοιχημάτιζαν είτε στο αποτέλεσμα των αθλητικών δρώμενων είτε στην απόδοση ενός αθλητή. (Golden, 1998)

Ωστόσο, αξίζει να ειπωθεί ότι υπήρχε διαφορετική αντίληψη για τον στοιχηματισμό και τα τυχερά παίγνια γενικότερα. Επικρατούσε διαφορετικό θεσμικό και ηθικό πλαίσιο από το αντίστοιχο της νεότερης εποχής διαμορφώνοντας τα τυχερά παίγνια ως μία μορφή διασκέδασης. (Kyle, 1998)

1.2.4. Ανάλυση αθλητισμού και στοιχηματισμού στη νεότερη εποχή

1.2.4.1. Εισαγωγή στατιστικών στα αθλήματα

Με την πάροδο των ετών η τεχνολογία έχει εισέλθει σε κάθε πτυχή της καθημερινότητας. Λογικό επακόλουθο ήταν να εισβάλει η τεχνολογία στον αθλητισμό και ιδιαίτερα στα ομαδικά αθλήματα (ποδόσφαιρο, καλαθοσφαίριση, μπίτζμπολ κλπ.) από την μετάδοση των αγώνων και την εμπορευματοποίηση τους έως και την εκτενή ανάλυση κάθε αθλητικού γεγονότος. Τα προαναφερθέντα συμβάλλουν στην καλύτερη δυνατή εμπειρία των οπαδών διότι η παρακολούθηση από οπουδήποτε και του οτιδήποτε είναι προσιτά σε όλους.

Η εισαγωγή στατιστικών στα αθλήματα είναι ένα σημαντικό θέμα στην επιστήμη των αθλητικών αναλύσεων και αποτελείται από την συλλογή δεδομένων μέχρι την επεξεργασία και την ανάλυση των δεδομένων. Συγκεκριμένα, η συλλογή δεδομένων από διάφορες πηγές, όπως από τα αθλητικά γεγονότα, από συσκευές καταγραφής δεδομένων ή από διαδικτυακούς χώρους, είναι σημαντική για την επεξεργασία και την ανάλυση των δεδομένων. Μετά τη συλλογή δεδομένων, η επεξεργασία και η ανάλυση τους παρέχει σημαντικές πληροφορίες για την απόδοση των αθλητών και των ομάδων. Με τη βοήθεια των στατιστικών μεθόδων, είναι δυνατό να κατανοηθούν οι συνθήκες που βοηθούν την απόδοση, να εκτιμηθούν οι επιδόσεις των αθλητών και να ληφθούν αποφάσεις για την επιλογή των αθλητών ή την αναθεώρηση των προγραμμάτων εκπαίδευσης.

Όσον αφορά στους αθλητές παρέχονται από τους εκάστοτε αθλητικούς οργανισμούς τα πιο εξελιγμένα τεχνολογικά «εργαλεία» με απώτερο σκοπό την διαρκή βελτίωση των αθλητών είτε αυτή είναι σωματική, είτε τεχνική, είτε στρατηγική είτε πνευματική. Τα δεδομένα που αντλούνται με την βοήθεια της τεχνολογίας μετατρέπονται σε αναλυτικά δεδομένα τα οποία τίθενται στην διάθεση κάθε ενδιαφερόμενου.

Επιστημονικά άρθρα στο χώρο των αθλητικών στατιστικών συνεχίζουν να παρουσιάζουν νέες μεθόδους και τεχνικές για τη συλλογή, επεξεργασία και ανάλυση δεδομένων, παρουσιάζουν ερευνητικά αποτελέσματα που μπορούν να χρησιμοποιηθούν για την βελτίωση της απόδοσης αθλητών και ομάδων, και παρουσιάζουν ερευνητικά σχέδια για μελλοντικές ερευνητικές δραστηριότητες στον τομέα.

1.2.4.2. Στατιστικά και στοιχηματισμός στο Αμερικανικό πρωτάθλημα καλαθοσφαίρισης

Η ανάλυση που διενεργούνταν σε έναν αγώνα του πρωταθλήματος καλαθοσφαίρισης ανδρών πριν από 50 χρόνια δεν έχει καμία ομοιότητα με την σημερινή. Στους πρώτους αγώνες καταγράφονταν στο «φύλλο» αγώνα μόνο γενικά χαρακτηριστικά όπως: το συνολικό σκορ, οι πόντοι κάθε παίκτη, οι προσπάθειες του και τα αντικανονικά του μαρκαρίσματα («φάουλ»).

Η «επανάσταση» στον τομέα αυτό δεν προήλθε όμως από το άθλημα της καλαθοσφαίρισης αλλά του μπέιζμπολ. Ο Billy Bane βασιζόμενος στο βιβλίο του Michael Lewis (Moneyball) κατάφερε να χτίσει σιγά - σιγά επιτυχημένες ομάδες στο μπέιζμπολ στηριζόμενος σε ανεπτυγμένα αναλυτικά δεδομένα αθλητών και όχι στα κοινά δεδομένα που είναι ορατά στους θεατές. Κατάφερε να προσεγγίσει την αξιολόγηση των δυνατοτήτων των αθλητών με τρόπο ώστε η ομάδα που προπονούσε να δημιουργήσει ένα πολύ καλό σύνολο με έναν πολύ χαμηλό προϋπολογισμό (NBASTuffer, n.d.).

Όσον αφορά στο NBA τα στατιστικά αποτελούν αναπόσπαστο κομμάτι για την ανάλυση και την κατανόηση του πρωταθλήματος. Στατιστικά όπως το «Player Efficiency Rating» (PER) εισήλθαν την δεκαετία του 90 παρέχοντας νέα εργαλεία αξιολόγησης της απόδοσης του εκάστοτε αθλητή. Τα επόμενα χρόνια, αναπτύχθηκαν οπτικά μέσα τα οποία έδιναν πια στους αθλητικούς οργανισμούς πλήρη εικόνα για τον κάθε αθλητή κάτω από οποιαδήποτε συνθήκη. Η χρήση των δεδομένων αυτών από τις ομάδες συνέβαλε στις καλύτερες δυνατές αποφάσεις όσον αφορά θέματα όπως εκγύμνασης του αθλητή αναλόγως των αναγκών του, τις προσθήκες («μετεγγραφές») αθλητών στην ομάδα, ακόμα και τις αποφάσεις του προπονητή σε ζωντανή ροή αγώνα για την καλύτερη απόδοση της ομάδας.

Ωστόσο, η χρήση της εκτενούς στατιστικής ανάλυσης σε αγώνες NBA και γενικότερα σε αθλητικά δρώμενα δεν βελτίωσε μόνο την ποιότητα του αθλήματος και την εμπειρία των οπαδών, αλλά είχε και τεράστια συμβολή στην ανάπτυξη της βιομηχανίας του στοιχηματισμού. Συμπερασματικά, η έλευση του διαδικτύου και γενικότερα η ανάπτυξη της τεχνολογίας συνετέλεσε στην ραγδαία ανάπτυξη στον τομέα του στοιχηματισμού καθώς όχι μόνο είναι διαθέσιμα μία πληθώρα αθλητικών γεγονότων στο ευρύ κοινό αλλά τίθενται στην διάθεση του για στοιχηματισμό με ένα απλό πάτημα από τον υπολογιστή ή το κινητό του. Δεν θα ήταν υπερβολή να ειπωθεί, ότι λόγω της ευκολίας πρόσβασης και την υπερ-προβολή που προωθείται από τα μέσα μαζικής ενημέρωσης σε συνδυασμό με άλλα κοινωνικά προβλήματα όπως φτώχεια και ανάγκη γρήγορου εισοδήματος διαμορφώνεται ένα κλίμα ανησυχίας για τυχόν προβλήματα εξάρτησης και άλλες συσχετιζόμενες κοινωνικές επιπτώσεις π.χ. κλοπές, φτώχεια.

Εν αντιθέσει με τα αρχαία χρόνια όπου ο στοιχηματισμός στον αθλητισμό και τα τυχερά παίγνια γενικότερα συνδεόταν με θρησκευτικά δρώμενα, σήμερα είναι καθαρά συνυφασμένος με τα εμπορικά συμφέροντα. Η εμπορευματοποίηση αυτή του αθλητισμού οδήγησε στην ανάγκη να θεσμοθετηθεί κάποια μορφή ελέγχου και πολλά κράτη προέβησαν σε αυστηρούς περιορισμούς, υιοθετώντας έτσι ένα αρκετά αυστηρό

νομικά και αυτορρυθμιζόμενο πλαίσιο για την προστασία της κοινωνίας (Sports Betting Market - Global Outlook and Forecast 2020-2024).

Συνοψίζοντας, τα εκτενή στατιστικά (ή «analytics») που αναλύουν εις βάθος έναν αγώνα καλαθοσφαίρισης και πιο συγκεκριμένα του NBA έχουν συμβάλει σημαντικά στην ανάπτυξη του αθλήματος της καλαθοσφαίρισης. Η χρήση της τεχνολογίας παρέχει μετρικές και αναλύσεις στοιχείων μη εμφανών κατά την διάρκεια ενός αγώνα όχι μόνο για την εκάστοτε ομάδα αλλά και για τον αθλητή. Παράλειψη θα ήταν να μην αναφερθεί ότι, διαμορφώνεται μια ολοκληρωμένη εικόνα πάνω στο άθλημα για όσους το παρακολουθούν.

Ειδικότερα, το θέαμα που παρακολουθεί ο οπαδός είναι αισθητά βελτιωμένο. Παροτρύνεται η συμμετοχή του και ενδυναμώνεται η κατανόηση του για το άθλημα μέσα από την ελεύθερη διάθεση των αναλυτικών στατιστικών στο ευρύ κοινό. Καθημερινά μέσα από αθλητικές εκπομπές στην τηλεόραση, διαφημίσεις σε μέσα κοινωνικής δικτύωσης γίνεται αναφορά σε αθλητές και στην απόδοσή τους. Δεν είναι τυχαίο άλλωστε ότι δεν υπάρχει οπαδός του αθλήματος της καλαθοσφαίρισης που να μην γνωρίζει τους γνωστούς αθλητές του αμερικανικού πρωταθλήματος (NBA) και την αντίστοιχη του απόδοση σε πόντους. Επί προσθέτως, την ανάπτυξη του αθλήματος ακολούθησε και η βιομηχανία του στοιχηματισμού που αναπτύχθηκε ραγδαία, παρέχοντας εργαλεία όχι μόνο στις εταιρείες αλλά και στους ενδιαφερόμενους στον τομέα αυτό.

1.3. Ιστορικά στοιχεία στα NBA και WNBA

1.3.1. Πρωτάθλημα NBA

Μετά την αναφορά χρήσης στατιστικών καθώς και στην ύπαρξη στοιχηματισμού στην καλαθοσφαίριση και στο NBA, αξίζει να αναφέρουμε κάποια σημαντικά ιστορικά στοιχεία για αυτό το πρωτάθλημα.

Στις 6 Ιουνίου του 1946 στην Νέα Υόρκη με την επωνυμία BAA ³ ιδρύθηκε το πρωτάθλημα καλαθοσφαίρισης της Αμερικής. Μετέπειτα (το 1949), μετονομάστηκε στο γνωστό σε όλους NBA (National Basketball Association) έπειτα από την συγχώνευση της BAA με την ανταγωνίστρια της τότε εποχής NBL⁴ (National Basketball League). Το πρωτάθλημα της εποχής χωριζόταν σε δύο τμήματα στο ανατολικό (Eastern Division) κομμάτι και το δυτικό (Western Division). Το μοντέλο αυτό εξελίχθηκε σε διαίρεση περιφερειών ανατολική περιφέρεια (Eastern Conference) και δυτική περιφέρεια (Western Conference) ανάλογα με τη γεωγραφική θέση της εκάστοτε ομάδας. Οι ομάδες του πρωταθλήματος μέχρι και εκείνη τη χρονιά ήταν 18.

Παρόλα αυτά, το 1967 ιδρύθηκε το πρωτάθλημα ABA ⁵ ως αντίπαλον δέος του NBA. Συμμετείχαν 11 ομάδες, κάποιες από αυτές εξακολουθούν να συμμετέχουν και

³ BAA: Basketball Association of America

⁴ NBL: National Basketball League

⁵ ABA: American Basketball Association

σήμερα στο πρωτάθλημα του NBA. Πιο συγκεκριμένα, έως και τη χρονιά 1976-1977 αποτελούσαν μέλη οι Denver Nuggets, οι San Antonio Spurs, οι Indiana Pacers και οι New York Nets (σημερινοί Brooklyn Nets). Σημαντικό να σημειωθούν κάποιες από τις καινοτομίες που έφερε η ABA στο NBA όπως η γραμμή του τρίποντου, ο χρόνος των 30 δευτερόλεπτων για κάθε επιτιθέμενη ομάδα.

Η τελική μορφή του πρωταθλήματος σχηματίστηκε το 1976 όταν συγχωνεύθηκαν τα δύο κορυφαία πρωταθλήματα το ABA και το NBA. Οι 18 ομάδες του NBA ενώθηκαν με τις προαναφερθείσες 4 του πρωταθλήματος ABA και οι υπόλοιπες ομάδες αναγκάστηκαν είτε να ενωθούν με άλλες ομάδες είτε να πάψουν να υπάρχουν. Πιο συγκεκριμένα οι 22 ομάδες διαιρέθηκαν σε 2 περιφέρειες από 11 η κάθε μία:

Ανατολική Περιφέρεια	Δυτική Περιφέρεια
Philadelphia 76ers	Los Angeles Lakers
Houston Rockets	Denver Nuggets
Washington Bullets	Portland Trail Blazers
Boston Celtics	Golden State Warriors
San Antonio Spurs	Detroit Pistons
Cleveland Cavaliers	Chicago Bulls
New York Knicks	Kansas City Kings
New Orleans Jazz	Seattle SuperSonics
Atlanta Hawks	Indiana Pacers
Buffalo Braves	Phoenix Suns
New York Nets	Milwaukee Bucks

*Πίνακας 1: Πρώιμη μορφή Αμερικάνικου πρωταθλήματος καλαθοσφαίρισης ανδρών
(Δομή πρωταθλήματος NBA από wikipedia)*

1.3.2. Πρωτάθλημα WNBA

Το Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης γυναικών (WNBA) ιδρύθηκε το 1996 και αποτελούσε το πρώτο επαγγελματικό πρωτάθλημα καλαθοσφαίρισης γυναικών στις Ηνωμένες Πολιτείες. Σημαντική συμβολή στη δημιουργία του υπήρξε η υποστήριξη από το αντίστοιχο πρωτάθλημα καλαθοσφαίρισης ανδρών (NBA).

Παρόμοια με το NBA αποτελούνταν από δύο περιφέρειες, την Ανατολική και την Δυτική με τέσσερις ομάδες η κάθε μία. Πιο συγκεκριμένα:

Ανατολική Περιφέρεια	Δυτική Περιφέρεια
Charlotte Sting	Los Angeles Sparks
Cleveland Rockers	Phoenix Mercury
New York Liberty	Sacramento Monarchs
Houston Comets	Utah Starzz

Πίνακας 2: Πρώιμη μορφή Αμερικάνικου πρωταθλήματος καλαθοσφαίρισης γυναικών

(Πρώιμη μορφή πρωταθλήματος WNBA)

Η ίδρυση του πρωταθλήματος αποτελεί σημαντικό ορόσημο στην ανάπτυξη του γυναικείου επαγγελματικού αθλητισμού στις Ηνωμένες Πολιτείες. Θεωρείται μία πολύ σημαντική στιγμή καθώς παρεχόταν πλέον η ευκαιρία στις γυναίκες καλαθοσφαιρίστριες να ανταγωνιστούν στο υψηλότερο επίπεδο και συνέβαλε στην αύξηση της αναγνωρισιμότητας των γυναικείων αθλημάτων γενικότερα. (WNBA Format)

1.4. Δομή των πρωταθλημάτων στις μέρες μας

1.4.1. Δομή NBA

Το πρωτάθλημα σήμερα αριθμείται από 30 ομάδες (29 από τις Η.Π.Α. και 1 από Καναδά). Η σημερινή μορφή, διαμορφώθηκε με την πάροδο των χρόνων με τις επεκτάσεις τα λεγόμενα «expansions» του πρωταθλήματος (έχουν γίνει 11 συνολικά). Τελευταία ομάδα που προστέθηκε ήταν οι Charlotte Bobcats (οι σημερινοί Charlotte Hornets). Για την καλύτερη διεξαγωγή του πρωταθλήματος οι ομάδες έχουν χωριστεί σε δύο περιφέρειες, την Ανατολική και τη Δυτική. Πιο συγκεκριμένα αποτελούνται από:

Ανατολική Περιφέρεια	Δυτική Περιφέρεια
Atlanta Hawks	Dallas Mavericks
Boston Celtics	Denver Nuggets
Brooklyn Nets	Golden State Warriors
Charlotte Hornets	Houston Rockets
Chicago Bulls	Los Angeles Clippers
Cleveland Cavaliers	Los Angeles Lakers
Detroit Pistons	Memphis Grizzlies
Indiana Pacers	Minnesota Timberwolves
Miami Heat	New Orleans Pelicans
Milwaukee Bucks	Oklahoma City Thunder
New York Knicks	Phoenix Suns
Orlando Magic	Portland Trail Blazers
Philadelphia 76ers	Sacramento Kings
Toronto Raptors	San Antonio Spurs
Washington Wizards	Utah Jazz

Πίνακας 3: Σημερινή μορφή NBA (Δομή πρωταθλήματος NBA από wikipedia)

Το πρωτάθλημα χωρίζεται σε 4 φάσεις:

- Κανονική περίοδο: που διαρκεί από τον Οκτώβριο έως τον Απρίλιο με την κάθε ομάδα να δίνει από 82 αγώνες.
- Play-in: που συμμετέχουν ομάδες από την έβδομη έως δέκατη θέση από κάθε περιφέρεια για δύο εισιτήρια στα playoffs.
- Playoffs: Επεκτείνουν την διάρκεια του πρωταθλήματος έως και τον Ιούνιο. Συμμετέχουν οι 6 κορυφαίες ομάδες και 2 από τα play-in από την κάθε περιφέρεια, δίνουν αγώνες μεταξύ τους. Η πιο δυνατή ομάδα αγωνίζεται με την πιο αδύναμη από την κάθε περιφέρεια. Ειδικότερα, ο πρώτος διεκδικεί την θέση του στον επόμενο γύρο με τον όγδοο, ο δεύτερος με τον έβδομο και ούτω καθεξής. Συνολικά υπάρχουν 3 γύροι όπου προχωράει ο νικητής του εκάστοτε γύρου έπειτα από 4 νίκες με την αντίπαλη ομάδα. Ο νικητής της κάθε περιφέρειας οδηγείται στον μεγάλο τελικό του NBA.
- Μεγάλος Τελικός: Οι 2 νικητές της κάθε περιφέρειας δίνουν μία σειρά αγώνων διεκδικώντας τον τίτλο του «πρωταθλητή», ο πρώτος στις τέσσερις νίκες «στέφεται πρωταθλητής». Τελευταίοι πρωταθλητές ήταν οι Golden State Warriors (2022).



Εικόνα 2: NBA Champions 2021-22: Golden State Warriors

(Οι πιο πρόσφατοι πρωταθλητές NBA (εικόνα από <https://www.pxfuel.com/desktop-wallpaper-kkzdh>))

1.4.2. Δομή WNBA

Με την πάροδο του χρόνου έχει αυξηθεί η δημοτικότητα του γυναικείου πρωταθλήματος καλαθοσφαίρισης της Αμερικής (WNBA) με λογικό επακόλουθο την αύξηση των ομάδων που το απαρτίζουν. Την χρονιά του 2000 και 2001 αποτελούνταν από 16 ομάδες αλλά σταθεροποιήθηκε στις 12 τα τελευταία χρόνια. Αναλυτικότερα, η δομή του πρωταθλήματος είναι παρόμοια με των αντρών, δηλαδή οι ομάδες χωρίζονται σε περιφέρειες, και κάθε περιφέρεια αποτελείται από:

Ανατολική Περιφέρεια	Δυτική Περιφέρεια
Atlanta Dream	Dallas Wings
Chicago Sky	Las Vegas Aces
Connecticut Sun	Los Angeles Sparks
Indiana Fever	Minnesota Lynx
New York Liberty	Phoenix Mercury
Washington Mystics	Seattle Storm

Πίνακας 4: Σημερινή μορφή WNBA (Πρώιμη μορφή πρωταθλήματος WNBA)

Το πρωτάθλημα χωρίζεται σε 4 φάσεις:

- Κανονική περίοδο: που διαρκεί από τον Μάιο έως τον Σεπτέμβριο με την κάθε ομάδα να δίνει από 36 αγώνες, αριθμός ο οποίος θα αυξηθεί σε 40 από αυτήν την χρονιά.
- Playoffs: Συμμετέχουν συνολικά 8 ομάδες με την καλύτερη βαθμολογία ανεξαρτήτως περιφέρειας. Όπως και στο NBA η πιο δυνατή ομάδα έρχεται αντιμέτωπη με την πιο αδύναμη. Ειδικότερα, ο πρώτος διεκδικεί την θέση του στον επόμενο γύρο με τον όγδοο, ο δεύτερος με τον έβδομο και ούτω καθεξής. Συνολικά υπάρχουν 2 γύροι όπου προκρίνεται ο νικητής του εκάστοτε γύρου έπειτα από 2 νίκες με την αντίπαλη ομάδα στον πρώτο γύρο και τρεις νίκες στον δεύτερο γύρο.
- Τελικός: Οι 2 νικητές των προηγούμενων φάσεων έρχονται αντιμέτωποι σε μία σειρά αγώνων όπου ανακηρύσσεται νικητής η ομάδα που θα κερδίσει 3 αγώνες. Τελευταία πρωταθλήτρια ομάδα ανακηρύχθηκε η ομάδα Las Vegas Aces.



Εικόνα 3: WNBA Champions 2022: Las Vegas Aces

(Πιο πρόσφατες πρωταθλήτριες WNBA (εικόνα από τον λογαριασμό της fanduel στο Twitter))

1.5. Παρουσία Ελλήνων αθλητών και αθλητριών σε NBA και WNBA

1.5.1 Ταλαντούχοι Έλληνες που συμμετέχουν στο NBA

Το αμερικάνικο πρωτάθλημα καλαθοσφαίρισης ανδρών ή αλλιώς NBA έχει δει αρκετούς ταλαντούχους Έλληνες αθλητές μέσα στα χρόνια, κανένας όμως δεν έχει γνωρίσει τόσο μεγάλη επιτυχία όσο ο Γιάννης Αντετοκούνμπο. Γεννημένος στην Ελλάδα από Νιγηριανούς γονείς, ο Αντετοκούνμπο έχει γίνει γνωστός σε όλη την υφήλιο κατά τη διάρκεια της παρουσίας του στους Milwaukee Bucks. Εισήχθη στην ομάδα το 2013 και καθιερώθηκε γρήγορα ως μια δύναμη στο γήπεδο, χάρη στον εντυπωσιακό του σωματότυπο, την αθλητικότητα του και τις δεξιότητες του στο άθλημα.

Η λίστα των επιτευγμάτων του Αντετοκούνμπο είναι εντυπωσιακή. Έχει κερδίσει δύο φορές τον τίτλο MVP του NBA, έχει επιλεγθεί επτά φορές στο All-Star Game του NBA και έχει κερδίσει έναν τίτλο όντας ο πολυτιμότερος παίκτης της ομάδας του, μεταξύ άλλων διακρίσεων. Η σκληρή δουλειά, η αφοσίωσή του στο παιχνίδι έχουν καταστήσει τον Αντετοκούνμπο τον μεγαλύτερο Έλληνα αθλητή που έχει περάσει ποτέ από το NBA.

Ανάμεσα, σε άλλους Έλληνες αθλητές ο Κώστας Παπανικολάου έπαιξε για την ομάδα των Houston Rockets και τους Denver Nuggets. Παρόλο το σύντομο πέρασμα του, ο Παπανικολάου έδειξε ταλέντο και ήταν γνωστός για το σταθερό παιχνίδι του σε όλους τους τομείς.

Ένας άλλος Έλληνας παίκτης που είχε δύο χρόνια παρουσία στο NBA είναι ο Νικ Καλάθης, ο οποίος έπαιξε στους Memphis Grizzlies. Ο Καλάθης είχε μια επιτυχημένη καριέρα στην Ευρώπη πριν κάνει το άλμα στο NBA ωστόσο δεν γνώρισε την ίδια επιτυχία στο NBA.

Τέλος, ο Βασίλης Σπανούλης, έπαιξε για τους Houston Rockets για μία χρονιά. Ο Σπανούλης είχε μια επιτυχημένη καριέρα στην Ευρώπη πριν έρθει στο NBA, αλλά λόγω δυσκολίας προσαρμογής στον τρόπο παιχνιδιού στο NBA επέστρεψε στην Ευρώπη.

1.5.2 Ταλαντούχες Ελληνίδες που συμμετέχουν στο WNBA

Άξιες αναφοράς είναι επίσης, οι Ελληνίδες που είχαν σημαντική συμβολή στο άθλημα της καλαθοσφαίρισης, με αρκετές επιτυχημένες αθλήτριες να αγωνίζονται στο WNBA και διεθνείς διοργανώσεις. Κάποιες από αυτές όπως η Ευανθία Μάλτση αγωνίστηκε με την ομάδα των Connecticut Sun του WNBA το 2009 και έχει μία επιτυχημένη καριέρα σε Ελλάδα, Ιταλία και Ισπανία. Η Μαρία Φασούλα, έχει επίσης επιδείξει τις ικανότητές της στο WNBA, παίζοντας τόσο για την ομάδα των Los Angeles Sparks όσο και για την Atlanta Dream. Άλλες αξιοσημείωτες Ελληνίδες στο πρωτάθλημα WNBA είναι η Στέλλα Καλτσίδου και η Ζωή Δημητράκου, οι οποίες έχουν αγωνιστεί για διάφορες ομάδες στην Ευρώπη και έχουν εκπροσωπήσει την Ελλάδα σε διεθνείς διοργανώσεις.

1.6. Ενδιαφέροντα στατιστικά για NBA και WNBA σήμερα

Το αμερικάνικο πρωτάθλημα καλαθοσφαίρισης (NBA και WNBA) είναι αδιαμφισβήτητα τα κορυφαία πρωταθλήματα καλαθοσφαίρισης διεθνώς και οι αθλητές και αθλήτριες που το απαρτίζουν, είναι από τους πιο ταλαντούχους και ικανούς αθλητές καλαθοσφαίρισης παγκοσμίως. Προκειμένου να γίνουν αντιληπτές οι ικανότητες των αθλητών, είναι απαραίτητο να καταφύγουμε σε εξειδικευμένα στατιστικά πέρα των παραδοσιακών («boxscore») τα οποία περιλαμβάνουν πόντους, ριμπάουντ, ασίστ και ποσοστά ευστοχίας. Ειδικότερα, απαιτούνται μετρικές οι οποίες θα παρέχουν μια πιο ολοκληρωμένη εικόνα στην συνεισφορά του αθλητή. Κάποιες από αυτές τις μετρικές οι οποίες είναι διαθέσιμες στο κοινό είναι:

- Player Efficiency Rating (PER): Αξιολόγηση απόδοσης αθλητή σύμφωνα με τα στοιχεία του σε πόντους, ριμπάουντ, ασίστ στον χρόνο που αγωνίζεται.
- True Shooting Percentage (TS%): Η ευστοχία του στο σύνολο των προσπαθειών του δηλαδή σε βολές, τρίποντα και δίποντα.
- Usage Percentage (USG%): Παρέχει την εικόνα στο πόσο εμπλέκεται ένας αθλητής στην επίθεση.

- Win Shares (WS): Η συνεισφορά ενός αθλητή στις νίκες της ομάδας του.
- BoxPlus/Minus (BPM): Ο επηρεασμός ενός αθλητή στον αγώνα βασισμένος στην απόδοση του.
- Value Over Replacement Player (VORP): Η συνεισφορά ενός αθλητή στην ομάδα του.

Πέρα όλων αυτών πρέπει να σημειωθεί ότι υπάρχουν επιπλέον εξειδικευμένα στατιστικά τα οποία είναι διαθέσιμα μόνο σε αθλητικούς οργανισμούς και κρατούνται κρυφά καθώς είναι πολύτιμες πληροφορίες όχι μόνο για τους προπονητές, αλλά και για τους αθλητικούς οργανισμούς καθώς σύμφωνα με αυτά διαμορφώνεται μία ομάδα. Ενδεικτικά προχωρημένα στατιστικά είναι:

- Player Tracking Data, SportVU Data: Αφορά δεδομένα όπως στις κινήσεις ενός αθλητή την ώρα του αγώνα, δηλαδή την ταχύτητα του, την απόσταση που διανύει. Τα δεδομένα αυτά συλλέγονται μέσω αισθητήρων και εξειδικευμένων καμερών εγκατεστημένων στα γήπεδα της εκάστοτε ομάδας.
- Play-by-Play Data, Synergy Sports Data: Καταγράφονται στατιστικά στην διάρκεια του αγώνα τα οποία αφορούν στις κινήσεις των αθλητών, στην κυκλοφορία της μπάλας και στις ενέργειες όλων των αθλητών. Η καταγραφή διενεργείται από ειδικά εξειδικευμένους αναλυτές για να παράσχουν μια αναλυτική αναφορά για κάθε γεγονός στο παιχνίδι.

Η χρήση όλων αυτών των στατιστικών βοηθά τους αθλητικούς οργανισμούς να αποκτήσουν μια ολοκληρωμένη εικόνα για τον εκάστοτε αθλητή και τις επιδόσεις του ώστε να είναι όσο το δυνατόν πιο ανταγωνιστικοί. (NBA metrics)

2. Νευρωνικά δίκτυα (Neural Networks)

2.1. Εισαγωγή στα νευρωνικά δίκτυα

Τα νευρωνικά δίκτυα αποτελούν αντικείμενο έρευνας για αρκετές δεκαετίες. Οι ρίζες τους χρονολογούνται την δεκαετία του 40 όταν δημοσιεύθηκε το ακαδημαϊκό άρθρο των McCulloch και Walter Pitts με τίτλο «A Logical Calculus of the Ideas Immanent in Nervous Activity.». Προτάθηκε ένα μοντέλο δικτύου το οποίο θα ήταν σε θέση να υπολογίσει οποιαδήποτε λογική πράξη, θέτοντας τα θεμέλια για περαιτέρω έρευνα στον τομέα. Η ουσιαστική πρόοδος στο πεδίο της εκπαίδευσης των νευρωνικών δικτύων προήλθε από τους ερευνητές Frank Rosenblatt και Geoffrey Hinton. Από τον Rosenblatt αναπτύχθηκε ο αλγόριθμος του «perceptron» ο οποίος είχε την δυνατότητα να διδαχθεί γραμμικό διαχωρισμό και από τον Hinton αναπτύχθηκε ο αλγόριθμος «backpropagation» που έδωσε το «έναυσμα» για την μελέτη της εκπαίδευσης πολλαπλών επιπέδων νευρωνικών δικτύων. Σε συνδυασμό με άλλες καινοτομίες οι οποίες θα αναφερθούν παρακάτω, επήλθε η ανάπτυξη των σύγχρονων νευρωνικών δικτύων όπως είναι γνωστή στις μέρες μας. Ενδεικτικές εφαρμογές είναι η αναγνώριση εικόνας, επεξεργασία φυσικής γλώσσας και τα αυτοκινούμενα αυτοκίνητα. (McCulloch, 1943)

2.1.1. Δομή νευρωνικών δικτύων

Ένα νευρωνικό δίκτυο αποτελεί ένα μοντέλο μηχανικής μάθησης, η δομή του οποίου είναι εμπνευσμένη από τον ανθρώπινο εγκέφαλο. Βασίζεται, σε διασυνδεδεμένους κόμβους, οι οποίοι ονομάζονται «νευρώνες» και επεξεργάζονται ή μεταδίδουν πληροφορίες. Οι συνδέσεις μεταξύ των κόμβων αναπαριστούνται με ακμές οι οποίες φέρουν μια τιμή, το βάρος των οποίων προσαρμόζεται κατά την διάρκεια της εκπαίδευσης του δικτύου. Η είσοδος η οποία εφαρμόζεται στο δίκτυο, διαβιβάζεται μέσω των πολλαπλών επιπέδων των νευρώνων. Ο κάθε νευρώνας εφαρμόζει τον δικό του μη γραμμικό μετασχηματισμό στην είσοδο μεταφέροντας το αποτέλεσμα στο επόμενο επίπεδο. Αυτή η διαδικασία διαρκεί έως ότου η πληροφορία οδηγηθεί στο τελευταίο επίπεδο νευρώνων το οποίο ονομάζεται εξωτερικό επίπεδο. Τα βάρη στους εκάστοτε κόμβους προσαρμόζονται ανάλογα με τον αλγόριθμο που εφαρμόζεται (π.χ. backpropagation) κατά την διάρκεια της εκπαίδευσης του νευρωνικού έχοντας ως στόχο την ελαχιστοποίηση της συνάρτησης λάθους η οποία εφαρμόζεται στο δίκτυο(π.χ. Mean Squared Error). Προβλήματα στα οποία προσφέρει λύσεις είναι είτε της κατηγοριοποίησης αλλιώς «classification», είτε της αναδρομής αλλιώς «regression». (LeCun Y. B., 2015) (Schmidhuber, 2015)

Μία σημαντική έννοια όσων αφορά τα νευρωνικά δίκτυα είναι ο αλγόριθμος «backpropagation». Αποτελεί έναν αλγόριθμο επιβλεπόμενης εκμάθησης («supervised learning») που χρησιμοποιείται για την εκπαίδευση των όχι μόνο των MLPs ⁶ αλλά και άλλων «feedforward» νευρωνικών δικτύων. Ο αλγόριθμος βασίζεται στην μέθοδο της βαθμιαίας κλήσης καθόδου ώστε να είναι το ελάχιστο δυνατό

⁶ MLPs: Multi-layer Perceptrons

σφάλμα μεταξύ επιθυμητής εξόδου και πραγματικής εξόδου. Το σφάλμα διαδίδεται από το εξωτερικό πλέγμα στο εσωτερικό ώστε να ενημερωθούν τα βάρη και η είσοδος πόλωσης («bias») του δικτύου. Η παραπάνω διαδικασία είναι γνωστή ως «backpropagation».

Η διαδικασία του αλγόριθμου είναι να χωριστεί σε δύο στάδια: την εμπρός διάδοση («forward propagation») και την πίσω διάδοση («backward propagation»). Κατά την διάρκεια της εμπρός διάδοσης η είσοδος διασχίζει το δίκτυο και τα επίπεδα του και υπολογίζεται η έξοδος. Στην πίσω διάδοση, υπολογίζεται το σφάλμα, η κλίση («gradient») των βαρών των κόμβων και υπολογίζονται οι είσοδοι πόλωσης («bias»). Τα συγκεκριμένα στοιχεία χρησιμοποιούνται έως ότου το σφάλμα πάρει την ελάχιστη δυνατή τιμή. (Rumelhart, Parallel Distributed Processing, 1986)

2.1.2. Εφαρμογές τεχνητών νευρωνικών δικτύων

Κάποια χρόνια πριν, οι μόνες εμπορικές εφαρμογές που έκαναν χρήση των τεχνητών νευρωνικών δικτύων πέραν του χρηματοοικονομικού τομέα ήταν τα συστήματα ανίχνευσης εκρηκτικών στην διαχείριση των αποσκευών στα αεροδρόμια, τα οποία και είχαν αναπτυχθεί από την Science Applications International Corporation (SAIC).

Στις μέρες μας τα τεχνητά νευρωνικά δίκτυα έχουν αναπτυχθεί πολύ και χρησιμοποιούνται ευρέως σε διάφορους τομείς της καθημερινότητας μας. Κάποια ενδεικτικά παραδείγματα αναφέρονται παρακάτω.

2.1.2.1. Εφαρμογές με χρήση Linear Neural Networks

Η πρώτη επιτυχημένη εφαρμογή των προσαρμοστικών νευρωνικών δικτύων (adaptive neural networks) έγινε από τους Widrow and Hoff κατά τη δεκαετία των 1960. Αυτοί έκαναν χρήση ενός νευρώνα γραμμικού νευρωνικού δικτύου εκπαιδεύοντας το με τον αλγόριθμο LMS.

Τα γραμμικά μοντέλα με έναν ή πολλαπλούς νευρώνες είναι εξίσου εύκολα στο να εκπαιδευτούν και έχουν ευρεία εμπορική εφαρμογή τις τελευταίες τρεις δεκαετίες. Μερικές από αυτές τις εφαρμογές περιλαμβάνουν:

- Τηλεπικοινωνίες. Τα modems που χρησιμοποιούνται στην υψηλής ταχύτητας μετάδοση ψηφιακών δεδομένων μέσω τηλεφωνικών καναλιών χρησιμοποιούν προσαρμοστικούς εξομαλυντές γραμμής και προσαρμοστικούς ακυκλοφόρητους εκχωρητές. Κάθε προσαρμοστικό σύστημα χρησιμοποιεί ένα νευρωνικό δίκτυο ενός νευρώνα. Η σημαντικότερη εμπορική εφαρμογή των νευρωνικών δικτύων σήμερα είναι σε αυτόν τον τομέα.
- Έλεγχος ήχου και δόνησης. Ο έλεγχος δόνησης και θορύβου επιτυγχάνεται χρησιμοποιώντας ένα προσαρμοστικό ενεργοποιητή που παράγει ίση και αντίθετη δόνηση και θόρυβο. Αυτό χρησιμοποιείται στα συστήματα

κλιματισμού, στα συστήματα αυτοκινήτων καθώς και σε εμπορικές εφαρμογές.

- Έλεγχος δέσμης σωματιδίων σε επιταχυντές σωματιδίων. Το Κέντρο Επιτάχυνσης Γραμμικών Σωματιδίων του Πανεπιστημίου Stanford (SLAC) χρησιμοποιεί προσαρμοστικές τεχνικές για την ακύρωση των διαταραχών που μειώνουν την ακρίβεια θέσης σωματιδίων. Η ακρίβεια των 3 χιλιομέτρων επιταχυντή ενισχύεται με τη χρήση ενός γραμμικού προσαρμοστικού μηχανισμού ακύρωσης θορύβου.

2.1.2.2. Εφαρμογές με χρήση Multielement nonlinear Neural Networks

Τα πολυ-στοιχειώδη μη γραμμικά νευρωνικά δίκτυα, άργησαν να αποδείξουν την εμπορική τους αξία. Ο λόγος για αυτήν την κατάσταση είναι κυρίως ότι ο πιο γνωστός αλγόριθμος, ο backpropagation έγινε γνωστός γύρω στο 1986 όταν δημοσιεύσαν σχετικό άρθρο οι Rumelhart και McClelland's. Ένα άλλο στοιχείο που έδωσε ώθηση στην διάδοση αυτών των αλγορίθμων είναι η τεχνολογική πρόοδος στην απόδοση υπολογιστών και μικροεπεξεργαστών, η οποία συνεχίζει να βελτιώνει την ικανότητα των αλγορίθμων με υπολογιστική πολυπλοκότητα. Αν και τα μη γραμμικά νευρωνικά δίκτυα δεν χρησιμοποιούνται αυτήν τη στιγμή τόσο ευρέως όσο τα γραμμικά δίκτυα, είναι εφαρμόσιμα σε ένα πολύ πιο ευρύ φάσμα προβλημάτων από τους γραμμικούς αντίστοιχους τους. Οι εφαρμογές για τις οποίες είναι πιο κατάλληλα συχνά περιλαμβάνουν πολύπλοκες μη γραμμικές σχέσεις, για τις οποίες οι κλασικές λύσεις δεν είναι διαθέσιμες.

Οι περισσότερες επιτυχημένες εμπορικές εφαρμογές των μη γραμμικών πολυστοιχικών νευρωνικών κάνουν χρήση του αλγόριθμου backpropagation, των radial basis συναρτήσεων, των γενετικών αλγορίθμων, αλγορίθμων μάθησης Κβάντων του Kohonen (LVQ⁷) κ.α. Οι περισσότερες εφαρμογές νευρωνικών δικτύων απευθύνονται σε προβλήματα που περιγράφονται σε κάθε μία από τις ακόλουθες τρεις κατηγορίες: ταξινόμηση προτύπων, πρόβλεψη και οικονομική ανάλυση, και έλεγχος και βελτιστοποίηση. Παραδείγματα από κάθε κατηγορία ακολουθούν:

Κατηγορία εφαρμογών: Ταξινόμηση προτύπων

- Ανίχνευση απάτης σε πιστωτικές κάρτες. Αρκετές τράπεζες και εταιρείες πιστωτικών καρτών, συμπεριλαμβανομένων της American Express, της Mellon Bank, της First USA Bank και άλλων, χρησιμοποιούν νευρωνικά δίκτυα για τη μελέτη προτύπων χρήσης των πιστωτικών καρτών και την ανίχνευση συναλλαγών που πιθανότατα είναι απάτες.
- Αναγνώριση χαρακτήρων εκτυπωμένων μηχανικά. Εμπορικά προϊόντα που πραγματοποιούν αναγνώριση χαρακτήρων έχουν εισαχθεί από πολλές εταιρείες και έχουν περιγραφεί στη βιβλιογραφία. Ανάμεσα σε αυτά τα προϊόντα είναι αυτά που κατασκευάζονται από τη Sharp Corp., τη Mitsubishi

⁷ LVQ: Learning Vector Quantization

Electric Corp., τη VeriFone Inc., τη Hecht-Nielsen Corp. (HNC⁸), τη Nestor Inc., τη Calera Recognition Systems Inc., τη Caere Corp. και την Audre Recognition Systems.

- Αναγνώριση χειρόγραφων χαρακτήρων. Το σύστημα αυτόματης καταχώρησης δεδομένων Quickstrokes της HNC χρησιμοποιείται για την αναγνώριση χειρόγραφων φορμών στο κέντρο επεξεργασίας παραγγελιών της Avon και στο τμήμα εσόδων της πολιτείας του Wyoming.
- Quality control στην κατασκευή. Τα νευρωνικά δίκτυα χρησιμοποιούνται σε μεγάλο αριθμό προγραμμάτων ελέγχου και διασφάλισης ποιότητας σε όλο το φάσμα της βιομηχανίας. Οι εφαρμογές περιλαμβάνουν τον εντοπισμό επιπέδου ρύπανσης σε χημικά εργοστάσια και την ταξινόμηση ελαττωματικών ηχείων από την CTS Electronics. Σύμφωνα με τον Justin Kestelyn στο τεύχος Ιουνίου 1990 του AI Expert, τα τ.ν.δ. χρησιμοποιούνται επίσης από το Τμήμα Εσπεριδοειδών της Φλόριντα για την εκτέλεση εκτίμησης καθαρότητας του χυμού πορτοκαλιού.
- Ανίχνευση πετρελαϊκών κοιτασμάτων. Εταιρείες πετρελαίων, όπως η Arco και η Texaco, χρησιμοποιούν νευρωνικά δίκτυα για τον προσδιορισμό των τοποθεσιών των υπογείων πετρελαϊκών κοιτασμάτων καθώς και αυτών του φυσικού αερίου.
- Πόλεμος κατά των ναρκωτικών. Τα νευρωνικά δίκτυα έκαναν την εμφάνισή τους στον διάσημο πόλεμο κατά των ναρκωτικών της κυβέρνησης των ΗΠΑ. Λογισμικό βασισμένο σε PC που αναπαριστά ένα πολυεπίπεδο νευρωνικό δίκτυο χρησιμοποιείται καθημερινά στο Κρατικό Γραφείο Ερευνών της Βόρειας Καρολίνας (NCSBI) για να βοηθήσει τους εμπειρογνώμονες της φαρμακολογικής ανάλυσης να αναγνωρίσουν δείγματα κοκαΐνης που προέρχονται από την ίδια παρτίδα.
- Ιατρικές εφαρμογές. Τα εμπορικά προϊόντα της Neuromedical Systems, Inc. χρησιμοποιούνται για την ανίχνευση καρκίνου και άλλων ιατρικών εφαρμογών. Η εταιρεία διαθέτει συστήματα ηλεκτροκαρδιογραφήματος που βασίζεται στην τεχνολογία νευρωνικών δικτύων.

Κατηγορία εφαρμογών: Πρόβλεψη και οικονομική ανάλυση

- Οικονομική προβλεψή και διαχείριση portfolio. Τα νευρωνικά δίκτυα χρησιμοποιούνται για την πρόβλεψη οικονομικών σε μεγάλο αριθμό επενδυτικών εταιρειών, συμπεριλαμβανομένων των Merrill Lynch & Co., Salomon Brothers, Shearson Lehman Brothers Inc., Citibank και της Παγκόσμιας Τράπεζας. Ένα ακόμα παράδειγμα είναι η Gerber Baby Foods που χρησιμοποιεί νευρωνικά δίκτυα για να διαχειριστεί τις συναλλαγές κτηνοτροφίας. Χρησιμοποιώντας νευρωνικά δίκτυα που εκπαιδεύονται με γενετικούς αλγόριθμους, ο Andrew Colin της Citibank ισχυρίζεται ότι μπορεί να κερδίσει αποδόσεις 25% ετησίως επενδύοντας στις αγορές νομισμάτων. Μια άλλη εταιρεία, η Promised Land Technologies, προσφέρει ένα πακέτο

⁸ HNC: Hecht-Nielsen Corporation

λογισμικού \$249 που ισχυρίζεται ότι παράγει εντυπωσιακές ετήσιες αποδόσεις.

- Έγκριση δανείων. Η τράπεζα Chase Manhattan χρησιμοποιεί ένα υβριδικό σύστημα που χρησιμοποιεί ανάλυση προτύπων και νευρωνικά δίκτυα για να αξιολογήσει τον κίνδυνο εταιρικών δανείων. Το σύστημα αυτό, το Creditview βοηθά τους υπαλλήλους δανείων να εκτιμήσουν την πιστοληπτική ικανότητα των υποψήφιων δανειοληπτών.
- Ανάλυση ακινήτων. Η Foster Ousley Conley κάνει χρήση του συστήματος “areas automated property valuation” της NC για να εκτιμήσει την αξία των κατοικιών στην Καλιφόρνια.
- Ανάλυση αγοράς. Το σύστημα «target marketing system» της Churchill systems χρησιμοποιείται από την Veratex Corp. για τη βελτιστοποίηση της στρατηγικής μάρκετινγκ και τη μείωση του κόστους διαφήμισης κάνοντας διαχωρισμό των πιθανών πελατών από αυτούς που δεν είναι πιθανό να αγοράσουν στο μέλλον. Επίσης, η Spiegel Inc. χρησιμοποιεί λογισμικό που δημιουργήθηκε από την NeuralWare Inc. για να καθορίσει ποιοι πελάτες θα πρέπει να λάβουν τους καταλόγους τους. Ο διευθυντής ερευνών αγοράς της Spiegel αναμένει εξοικονόμηση τουλάχιστον ενός εκατομμυρίου δολαρίων ετησίως βασισμένος σε αυξημένες πωλήσεις και μειωμένη αποστολή καταλόγων.
- Σύστημα κατανομής θέσεων στις αεροπορικές εταιρείες. Το αντίστοιχο σύστημα που αναπτύχθηκε από την BehavHeuristics Inc. χρησιμοποιεί νευρωνικά δίκτυα για να προβλέψει τη ζήτηση των επιβατών και να διαμορφώσει την κατανομή θέσεων για αεροπορικές εταιρείες, όπως η Nationair Canada και η USAir..

Κατηγορία εφαρμογών: Έλεγχος και βελτιστοποίηση

- Έλεγχος θέσεως ηλεκτρικού τόξου κατασκευής. Τα ηλεκτρικά τόξα κατασκευής χρησιμοποιούνται για τη λήψη μεταλλικών παλιοσίδερων (scrap). Τα συστήματα ελέγχου Intelligent Arc Furnace που εγκαθίστα η Neural Applications Corp. αναφέρεται ότι εξοικονομούν εκατομμύρια δολάρια ανά χρόνο για κάθε φούρνο λόγω αύξησης της παραγωγικότητας του φούρνου και μείωσης της φθοράς των ηλεκτροδίων και της κατανάλωσης ηλεκτρικής ενέργειας. Να σημειωθεί ότι ο έλεγχος αυτός εγκαθίσταται σε φούρνους σε όλο τον κόσμο.
- Έλεγχος διαδικασίας ημιαγωγών. Η Korin Corp. έχει χρησιμοποιήσει νευρωνικά δίκτυα για να μειώσει τα σφάλματα στη συγκέντρωση dopant καθώς και το πάχος των επικαθιμένων στρώσεων στα ηλιακά σώματα περισσότερο από διπλάσιο παράγοντα.
- Έλεγχος διεργασιών χημικής παραγωγής. Η Pavilion Technologies έχει αναπτύξει ένα πακέτο ελέγχου διεργασιών με νευρωνικά δίκτυα, το “process insights”, το οποίο βοηθά την Eastman Kodak και μια σειρά άλλων εταιρειών να μειώσουν τα απόβλητα, να βελτιώσουν την ποιότητα των προϊόντων και να αυξήσουν την απόδοση των εργοστασίων. Τα νευρωνικά δίκτυα χρησιμοποιούνται για να πραγματοποιήσουν μελέτες ευαισθησίας, να

καθορίσουν τα σημεία ρύθμισης της διεργασίας, να ανιχνεύσουν βλάβες και να προβλέψουν την απόδοση της διεργασίας.

- Έλεγχος διεργασιών στην πετρελαιοχημική βιομηχανία. Στο εργοστάσιο Puget Sound της Texaco, το οποίο επεξεργάζεται 120.000 βαρέλια πετρελαίου την ημέρα, έχουν ενσωματωθεί νευρωνικά δίκτυα στα συστήματα ελέγχου διεργασιών του εργοστασίου. Όπως περιγράφεται στο τεύχος του AI Expert, ένα από αυτά τα δίκτυα χρησιμοποιείται στον έλεγχο ενός συστήματος debutanizer, το οποίο διαχωρίζει υδρογονάνθρακες ανάλογα με τα μοριακά τους βάρη. Η Διαδικασία αυτή απαιτεί ακριβή παρακολούθηση της θερμοκρασίας, της πίεσης και των ρυθμών ροής. Το δίκτυο επτά- εισόδων και δύο -εξόδων, το οποίο εκπαιδεύτηκε με περίπου 1.500 δείγματα δεδομένων, είναι συνήθως σε θέση να διορθώνει σφάλματα πριν εκδηλωθούν.
- Βελτιστοποίηση συνταγών τροφίμων και χημικών προϊόντων. Νευρωνικά δίκτυα χρησιμοποιούνται επίσης για τη βελτιστοποίηση συνταγών στις εταιρείες Glidden Co., Lord Corp. και στη M&M/Mars. Οι ερευνητές των δύο πρώτων εταιρειών αναφέρουν επιτυχία στη χρήση του πακέτου CAD/Chem της AI Ware στην αναζήτηση βελτιωμένων χημικών για τις συνταγές. Η CAD/Chem χρησιμοποιήθηκε από την Lord Corp. στη διαδικασία διαμόρφωσης ενός νέου προϊόντος κόλλας με iterative τεχνική αναζήτησης.
- Έλεγχος κατασκευής κατά τη διάρκεια της παραγωγής χάλυβα. Ένα σύστημα ελέγχου με τη χρήση νευρωνικών δικτύων χρησιμοποιείται στην Ιαπωνία σε εργοστάσια που ανήκουν στην Fujitsu Ltd. και Nippon Steel Corp. Το σύστημα έχει μειώσει το κόστος κατά μερικά εκατομμύρια δολάρια ετησίως εξαλείφοντας τη ζημιά και το χρόνο αδράνειας που προκαλείται από το «σπάσιμο». Το σύστημα χρησιμοποιεί ένα δίκτυο τροφοδοσίας που εκπαιδεύτηκε με αναδρομική διάδοση για να ανιχνεύσει το «σπάσιμο» πριν συμβεί, επιτρέποντας λήψη διορθωτικών μέτρων. Το σύστημα ελέγχου λειτουργεί από τα μέσα του 1990. (Widrow, 1994)

2.2. Είδη τεχνητών νευρωνικών δικτύων

Τα τεχνητά νευρωνικά δίκτυα χωρίζονται σε διαφορετικές κατηγορίες αναλόγως την αρχιτεκτονική τους, τον αλγόριθμο στον οποίο εκπαιδεύονται ή το είδος των εφαρμογών που υλοποιούν. Επιγραμματικά τα πιο γνωστά είδη ΤΝΔ⁹ είναι τα:

- Feedforward Neural Networks (FFNNs¹⁰)
- Recurrent Neural Networks (RNNs¹¹)
- Convolutional Neural Networks (CNNs¹²)
- Long Short-Term Memory Networks (LSTMs¹³)
- Generative Adversarial Networks (GANs¹⁴)

⁹ ΤΝΔ: Τεχνητά Νευρωνικά Δίκτυα

¹⁰ FFNNs: Feedforward Neural Networks

¹¹ RNNs: Recurrent Neural Networks

¹² CNNs: Convolutional Neural Networks

¹³ LSTMs: Long Short-Term Memory Networks

2.2.1. Feed-forward Neural Networks

Τα Feed forward Neural Networks αποτελούν ένα είδος τεχνητού νευρωνικού δικτύου που αποτελείται από τρία επίπεδα:

- Επίπεδο εισόδου
- Κρυφό επίπεδο (ενδέχεται να είναι και πάνω από ένα)
- Επίπεδο εξόδου

Όλα τα επίπεδα αποτελούνται από έναν περισσότερους κόμβους ή αλλιώς νευρώνες που ο καθένας αρχικοποιείται με μία τιμή η οποία αποτελεί το βάρος του.

Οι ρίζες αυτού του τύπου δικτύου χρονολογούνται την δεκαετία του 40 από τους McCullochPitts αλλά η σημαντική πρόοδος προήλθε από τους ερευνητές Rosenblatt και Hinton (Hinton G. O., 2006). Εκπαιδεύονται με τον αλγόριθμο «backpropagation», επιτρέποντας την προσαρμογή των βαρών ώστε να έχει την ελάχιστη δυνατή τιμή η συνάρτηση λάθους. Ως συνάρτηση λάθους ορίζεται η διαφορά μεταξύ της πραγματικής τιμής με αυτής της συνάρτησης λάθους. (Schmidhuber, 61, 2015)

Σημαντικό να αναφερθούν κάποια πλεονεκτήματα τους, που είναι η ικανότητα διαχείρισης τεράστιου όγκου δεδομένων και εκμάθησης τους από αυτόν. Η εκπαίδευση τους θεωρείται εύκολη και ταχεία διαμορφώνοντας τα μία συχνή επιλογή για διάφορες εφαρμογές (McCulloch, 1943). Ενδεικτικές εφαρμογές αποτελούν:

- Η αναγνώριση εικόνας και επεξεργασίας.
- Αναγνώρισης ομιλίας.
- Ιατρικές διαγνώσεις.

Ωστόσο θα ήταν σημαντική παράλειψη να μην τονιστεί ότι έχουν και μειονεκτήματα, Αυτός ο τύπος δικτύου καθώς ο τεράστιος όγκος δεδομένων που απαιτούνται για την εκπαίδευση τους ελλοχεύει τον κίνδυνο της μη ορθής λειτουργίας («overfitting») που συμβαίνει όταν το δίκτυο είναι αρκετά πολύπλοκο. Τα FFNNs χωρίζονται και αυτά με την σειρά τους σε κατηγορίες αναλόγως των χαρακτηριστικών τους με πιο γνωστά από αυτά να είναι (Bengio Y. C., 2013):

- Perceptron
- Multi-layer Perceptrons (MLPs)
- Radial Basis Function Networks (RBFNs¹⁵)

¹⁴ GANs: Generative Adversarial Networks

¹⁵ RBFNs: Radial Basis Function Networks

2.2.1.1. Perceptrons

Τα Perceptrons παρουσιάστηκαν πρώτα από τον Frank Rosenblatt το 1958, αποτελούν έναν τύπο Feedforward τεχνητού νευρωνικού δικτύου ο οποίος μπορεί να χρησιμοποιηθεί για διαδικασίες δυαδικής ταξινόμησης. Αποτελείται από ένα πλέγμα νευρώνων όπου οι νευρώνες υποδοχής λαμβάνουν την είσοδο και παράγουν μία έξοδο σύμφωνα με αυτά.

Στο άρθρο του ο Rosenblatt (Rosenblatt, 1958) εισήγαγε τον κανόνα εκμάθησης του perceptron, βασιζόμενος σε έναν αλγόριθμο για την προσαρμογή του βάρους του κόμβου, όπως συμβαίνει και στα FFNNs γενικότερα. Ο αλγόριθμος βασιζόταν στην αρχή της κλήσης καθόδου (gradient descent) η οποία ελαχιστοποιεί το σφάλμα μεταξύ της προβλεπόμενης και πραγματικής εξόδου. Ο συγκεκριμένος αλγόριθμος αποτελεί έναν από τους πρώτους επιβλεπόμενης εκμάθησης των τεχνητών νευρωνικών δικτύων. (Minsky M. L., 1969)

Το 1972 ο Minsky και ο Papert δημοσίευσαν το δικό τους άρθρο όπου εξηκούσαν ότι τα δίκτυα αυτά είναι ικανά να λύσουν μόνο γραμμικά διαχωρισμένα προβλήματα και όχι μη γραμμικά. Για παράδειγμα δεν ήταν δυνατή η αναπαράσταση της συνάρτησης XOR.

Αργότερα το 1972, δημοσιεύθηκε από τον Anderson (Anderson, 1972) μία εκτεταμένη εκδοχή του αλγόριθμου του perceptron έτσι ώστε να είναι δυνατή η επίλυση του προαναφερθέντος προβλήματος. Πιο συγκεκριμένα, επιτρέπονταν τα σφάλματα στον αλγόριθμο στη φάση εκπαίδευσης για την καλύτερη δυνατή προσαρμογή του βάρους.

Συμπερασματικά τα perceptrons αν και είναι απλά στον σχεδιασμό τους ήταν ο προάγγελος των ΤΝΔ για την ανάπτυξη τους (Zurada J. M., 1992). Παρακάτω, θα μελετηθεί η επέκταση του συγκεκριμένου αλγορίθμου σε περισσότερα του ενός επίπεδα για την επίλυση πιο πολύπλοκων προβλημάτων. (Platt, Sequential minimal optimization: A fast algorithm for training support vector machines, 1998)

2.2.1.2. Multi-layer Perceptrons

Τα Multi-layer Perceptrons αποτελούν επέκταση του μοντέλου του Perceptron η οποία αποτελείται όπως τα παραδοσιακά FFNNs από τρία επίπεδα: το επίπεδο εισόδου, τα κρυφά επίπεδα τα οποία ενδέχεται να είναι ένα ή και περισσότερα, το επίπεδο εξόδου. Η ανάπτυξη τους όπως είναι γνωστή στις μέρες μας προήλθε από τους Rumelhart, Hinton, και Williams (Rumelhart, Parallel Distributed Processing., 1986) το 1986 από τους οποίους προτάθηκε η εισαγωγή του αλγόριθμου backpropagation για την εκπαίδευση των MLPs. (Minsky M. &., 1969)

Η ικανότητα τους να υπολογίσουν οποιαδήποτε συνεχή συνάρτηση αποδείχθηκε το 1989 από τον Cybenko, χρησιμοποιώντας ένα κρυφό επίπεδο. Το συγκεκριμένο αποτέλεσμα έθεσε το έναυσμα για την χρήση των MLPs σε εφαρμογές όπως επεξεργασία εικόνας και αναγνώρισης διαλόγου. (Cybenko, 1989)

Ωστόσο, θα πρέπει να αναφερθούν οι περιορισμοί των MLPs, τα οποία αντιμετωπίζουν δυσκολία στην μοντελοποίηση προσωρινών ή ακολουθιακών δεδομένων. Ακόμη, εάν υπάρχουν πολλά κρυφά επίπεδα είναι σχετικά πολύπλοκα στο σχεδιασμό τους.

Τα τελευταία χρόνια τα MLPs πολλών κρυφών επιπέδων είναι ο προάγγελος των νευρωνικών δικτύων που είναι γνωστά ως βαθιάς εκμάθησης νευρωνικά δίκτυα («deeplearning») καθώς σύμφωνα με τους LeCun, Bengio και Hinton έχουν την ικανότητα να μαθαίνουν ιεραρχικές αναπαραστάσεις δεδομένων, οι οποίες βοηθούν στην επίλυση αρκετών προβλημάτων (LeCun Y. B., Deep learning. Nature).

2.2.1.3. Radial Basis Function Neural Networks

Τα Radial Basis Function νευρωνικά δίκτυα (RBF) αποτελούν ένα σχετικά πρόσφατο μοντέλο νευρωνικών δικτύων. Τα RBF δίκτυα αποδείχθηκαν από τον Haykin το 1994 ότι είναι δυνατόν να χρησιμοποιηθούν ως εκτιμητές, το οποίο μεταφράζεται ότι έχουν την ικανότητα να υπολογίσουν οποιαδήποτε συνάρτηση στον βαθμό ακρίβειας που επιθυμεί ο εκάστοτε χρήστης.

Η διαφορά στην δομή τους με τα παραδοσιακά FFNNs είναι ότι το κρυφό τους επίπεδο βασίζεται σε συναρτήσεις ακτινικής βάσης («radial basis») οι οποίες αποτελούν μη γραμμικές συναρτήσεις ενεργοποίησης.

Οι προαναφερθείσες συναρτήσεις ορίζονται ως η απόσταση μεταξύ του διανύσματος εισόδου και του κέντρου της συνάρτησης radial basis που είναι γνωστό και ως πρωτότυπο («prototype»). Η πιο γνωστή radial basis συνάρτηση είναι η Γκαουσιανή:

$$f(x) = \exp\left(-\frac{\|x - c\|^2}{2 * \sigma^2}\right)$$

Εξίσωση 1: Gaussian function

όπου:

- x : είναι το διάνυσμα εισόδου
- c : είναι το πρωτότυπο
- σ : είναι η έκταση της RBF
- $\|x - c\|$: αναπαριστά την ευκλείδεια απόσταση μεταξύ εισόδου και πρωτότυπου

Τέλος όλη η συνάρτηση δίνει το σχήμα της.

Επιπλέον χρησιμοποιούνται ευρέως σε εφαρμογές όπως:

- Αναλύσεις συναρτήσεων: χρησιμοποιούνται για την ανάλυση πολύπλοκων, μη γραμμικών συναρτήσεων. Χρήσιμα στα συστήματα ελέγχου, στα αναγνωριστικά συστήματα και στην επεξεργασία σήματος.
- Ταξινόμηση προτύπων: Τα δίκτυα RBF έχουν χρησιμοποιηθεί για προβλήματα ταξινόμησης προτύπων όπως την αναγνώριση εικόνας, την αναγνώριση ομιλίας και ταξινόμησης κειμένου.
- Ρομποτική: Τα δίκτυα RBF έχουν χρησιμοποιηθεί για εργασίες όπως την τοποθεσία και έλεγχο ρομπότ.
- Ιατρικές: εφαρμογές στην καρδιολογία και στη νευρολογία.

Σε σύγκριση με άλλα μοντέλα FFNNs, όπως τα MLPs παρουσιάζουν αρκετά πλεονεκτήματα. Παραδείγματος χάρη, σύμφωνα με τον Bishop (Bishop, 1995) το 1995, η κατασκευή του κρυφού επιπέδου με radial basis συναρτήσεις επιτρέπει πιο πολύπλοκες σχέσεις μεταξύ εισόδων και εξόδων. Επιπλέον οι vander Velden και Loog ανέφεραν το 2010 ότι το μοντέλο των RBF δικτύων παρουσιάζουν καλύτερη απόδοση από άλλους ταξινομητές όπως δέντρα αποφάσεων ή («k-nearest neighbors») k κοντινών γειτόνων. (Haykin, 1994)

Ωστόσο παράλειψη θα ήταν να μην αναφερθούν κάποιοι σημαντικοί περιορισμοί. Ενδέχεται να είναι ευαίσθητα στην επιλογή των νευρώνων του κρυφού επιπέδου του δικτύου διότι στην περίπτωση των πολλών κρυφών νευρώνων θα επιφέρει σαν αποτέλεσμα την χαμηλή απόδοση του μοντέλου. (Poggio, 2002)

2.2.2. Recurrent Neural Networks (RNNs)

Τα Recurrent Neural Networks ή αλλιώς Επαναλαμβανόμενα Νευρωνικά δίκτυα (RNNs) αποτελούν έναν τύπο νευρωνικών δικτύων ιδανικών για την επεξεργασία ακολουθιακών δεδομένων. Η διαφορά με τους προαναφερθέντες τύπους δικτύων είναι ότι χαρακτηρίζονται από την παρουσία συνδέσεων ανατροφοδότησης («feedback connections») οι οποίες επιτρέπουν στο δίκτυο να διατηρήσει μία κρυφή κατάσταση η οποία κωδικοποιεί τα προηγούμενα στοιχεία μίας ακολουθίας. Το ιδιαίτερο αυτό χαρακτηριστικό, επιτρέπει τον εντοπισμό προσωρινών εξαρτήσεων στα δεδομένα διαμορφώνοντας τα ως μία ιδανική λύση για προβλήματα αναγνώρισης ομιλίας και μηχανικής μετάφρασης (Chung, 2014).

Το κύριο πρόβλημα που αντιμετωπίζει ο συγκεκριμένος τύπος νευρωνικών δικτύων σε σχέση με τους προηγούμενους τύπους είναι ότι δεν είναι δυνατή η χρήση της κλίσης («gradient») καθώς εξασθενεί στην προσπάθεια εκπαίδευσης του δικτύου με ακολουθίες μεγάλης εξάρτησης. Το πρόβλημα προκύπτει από τη συσσώρευση των σφαλμάτων μέσω των επαναλαμβανόμενων συνδέσεων και έτσι η σύγκλιση που προκύπτει από την εκπαίδευση είναι αμελητέα. Όπως θα αναλυθεί στην επόμενη ενότητα για να καταπολεμηθεί το συγκεκριμένο πρόβλημα προτάθηκε η παραλλαγή της Long Short-term Memory (LSTM). (Gal, 2016)

Επιπλέον, ένα άλλο πρόβλημα που αντιμετωπίζει και αυτός ο τύπος δικτύων είναι η υπερφόρτωση («overfitting») εξαιτίας των πολλών παραμέτρων του δικτύου. Προκειμένου να αντιμετωπιστεί, ενδέχεται να γίνει χρήση παραμέτρων κανονικοποίησης όπως της εγκατάλειψης («dropout») με απώτερο στόχο τη βελτίωση απόδοσης του δικτύου. (Jozefowicz, 2015)

Επαναλαμβανόμενες συνδέσεις (Feedback connections)

Είναι επίσης γνωστές ως επαναλαμβανόμενες συνδέσεις και, αποτελούν το κύριο χαρακτηριστικό των Επαναλαμβανόμενων Νευρωνικών δικτύων. Οι συνδέσεις αυτές επιτρέπουν στο δίκτυο να διατηρεί μία κρυφή κατάσταση όπου λαμβάνει τόπο η κωδικοποίηση των προηγούμενων στοιχείων της ακολουθίας. (Graves, 2012) (Olah, 2015)

Η εφαρμογή αυτού του τύπου συνδέσεων λαμβάνει χώρα έχοντας μία ομάδα επαναλαμβανόμενων βαρών κόμβων η οποία θα συνδέει την κρυφή κατάσταση μίας χρονικής στιγμής με την κρυφή κατάσταση της επόμενης χρονικής στιγμής. Τα βάρη που αναφέρθηκαν διαμοιράζονται σε όλες τις χρονικές στιγμές επιτρέποντας στην πληροφορία που έχει εισέλθει στο δίκτυο να διαδίδεται στο σύνολο του. (Karpathy, 2015)

Ένα από τα κύρια προτερήματα των συνδέσεων αυτών είναι ότι επιτρέπουν στα RNNs να επεξεργάζονται ακολουθίες μεταβλητού μήκους, σε αντίθεση με τα παραδοσιακά FFNNs (Zaremba, 2014) τα οποία απαιτούν έναν συγκεκριμένο αριθμό εισόδου και αποτελούν ιδανική λύση καθώς είναι δυνατή η επίλυση μεγαλύτερου εύρους προβλημάτων. (Le, 2015)

2.2.2.1. Hopfield Networks

Το 1982 από τον John Hopfield (Hopfield J. J., 1982) προτάθηκε ένας τύπος επαναλαμβανόμενου νευρωνικού δικτύου («recurrent»). Ειδικότερα, η ιδέα πίσω από την ανάπτυξη των δικτύων αυτών είναι η μοντελοποίηση του ανθρώπινου εγκεφάλου σαν ένα τεχνητό σύστημα που έχει την ικανότητα αποθήκευσης και ανάκλησης πληροφοριών.

Σε αντίθεση, με άλλους τύπους ΤΝΔ τα δίκτυα του Hopfield (Hopfield J. J., 1982) αποτελούνται από ένα επίπεδο νευρώνων ή αλλιώς κόμβων οι οποίοι είναι όλοι συνδεδεμένοι μεταξύ τους. Ειδικότερα έχουν την ικανότητα να αναπαριστούν δυαδικές καταστάσεις, δηλαδή έχουν την δυνατότητα αναπαράστασης τιμών είτε +1 είτε -1 και τα βάρη των συνδέσεων μεταξύ των κόμβων καθορίζουν την επιρροή του ενός νευρώνα στον άλλον.

Επιπλέον, η ικανότητα αποθήκευσης και ανάκλησης πληροφοριών επιτυγχάνεται χάρη σε καταστάσεις «έλξης» («attractor states»), οι οποίες αποτελούν τις ρυθμίσεις των δυαδικών καταστάσεων των νευρώνων παραμένοντας σταθερές και διατηρούμενες με την πάροδο του χρόνου. Οι συγκεκριμένες καταστάσεις χρησιμοποιούνται για την αποθήκευση και ανάκληση της δραστηριότητας του δικτύου.

Όσον αφορά στην εκπαίδευση των δικτύων Hopfield αυτή επιτυγχάνεται μέσω μίας συνάρτησης ενέργειας η οποία αναπαριστά τη σταθερότητα του δικτύου. Ελαχιστοποιείται όταν το δίκτυο βρίσκεται σε κατάσταση «έλξης και επιτυγχάνεται διαμέσου των κανόνων που εφαρμόζονται στους κόμβους κατά τη διάρκεια λειτουργίας του δικτύου. Η τελική κατάσταση του δικτύου αναπαριστά την πιο κοντινή κατάσταση μνήμης της εισόδου που δόθηκε. (Hopfield J. J., 1982)

Από την στιγμή εισαγωγής των δικτύων του Hopfield (Hopfield J. J., 1982) μέχρι και σήμερα υπήρξε αντικείμενο έρευνας και ανάπτυξης. Έχουν προταθεί πολλές επεκτάσεις και προσαρμογές στην δομή του δικτύου περιλαμβάνοντας συνεχείς τιμές νευρώνων, πολλαπλά επίπεδα και εφαρμογές των κανόνων εκμάθησης του Hebbian.

Σημαντικές εξ' αυτών που αξίζει να αναφερθούν, είναι το άρθρο του Little όπου αποδείχθηκε η ικανότητα διόρθωσης και απόρριψης λαθών. Επίσης το 1991 οι Hopfield και Tank έκαναν χρήση της συνάρτησης ενέργειας για την επίλυση προβλημάτων βελτιστοποίησης δρομολογώντας το πρόβλημα σε αυτήν. Τα τελευταία χρόνια χρησιμοποιούνται από αλγόριθμους μηχανιστικής μάθησης για την επίλυση πολύπλοκων προβλημάτων όπως η κατηγοριοποίηση εικόνας και αναγνώρισης αντικειμένου. (Hopfield J. J., 1991)

Εν κατακλείδι, παρά την απλότητα του συγκεκριμένου τύπου ΤΝΔ, έχει συμβάλει στην περαιτέρω έρευνα και ανάπτυξη του πεδίου της τεχνητής νοημοσύνης και μηχανιστικής μάθησης (Little, 1986)

2.2.2.2. Long Short-Term Memory Networks (LSTMs)

Τα Long Short-Term Memory Networks είναι ένας τύπος («recurrent») νευρωνικού δικτύου που προτάθηκε πρώτα από τους Sepp Hochreiter και Jürgen Schmidhuber το 1997. Αναπτύχθηκαν ως απάντηση στο πρόβλημα των εξαφανιζόμενων εξαφανιζόμενης βάρμωσης που αντιμετώπιζαν έως τότε τα RNNs. Το πρόβλημα αφορούσε τις κλίσεις της διαδικασίας «backpropagation» καθώς οι κλίσεις είτε ήταν πολύ μεγάλες είτε πολύ μικρές για να είναι δυνατή η χρήση τους από τα βάρη των κόμβων οδηγώντας το δίκτυο σε αστάθεια. (Lipton, 2015)

Ένας άλλος λόγος εισαγωγής αποτελεί ότι τα δίκτυα RNNs αποτελούν μια κατηγορία τεχνητών νευρωνικών δικτύων που έχουν αποδειχθεί ιδιαιτέρως αποτελεσματικά στην μοντελοποίηση δεδομένων χρονοσειράς. Ωστόσο, ένα από τα βασικά προβλήματα στη μοντελοποίηση των δεδομένων χρονοσειρών με νευρωνικά δίκτυα είναι η αντιμετώπιση μακροπρόθεσμων εξαρτήσεων, δηλαδή σχέσεων μεταξύ εισόδων που χωρίζονται από αρκετές χρονικές στιγμές. Οι Hochreiter και Schmidhuber (1997) για αυτόν τον λόγο εισήγαγαν το νευρωνικό δίκτυο μακράς και βραχείας μνήμης (LSTM), μια αρχιτεκτονική τύπου RNN που αντιμετωπίζει αυτή την πρόκληση χρησιμοποιώντας κατάλληλα κελιά μνήμης που επιτρέπουν την επιλεκτική διατήρηση ή απόρριψη πληροφοριών (Hochreiter, 1997).

Το πρόβλημα αντιμετωπίστηκε με την εισαγωγή κελιών μνήμης τα οποία είναι ικανά να διατηρήσουν πληροφορίες για ένα εκτεταμένο χρονικό διάστημα, σε συνδυασμό με πύλες οι οποίες ελέγχουν την ροή πληροφοριών μέσα και έξω από τα κελιά μνήμης. Πιο συγκεκριμένα οι πύλες λειτουργούν ως φίλτρα τα οποία είναι υπεύθυνα για το ποιες πληροφορίες θα πρέπει να διατηρηθούν και ποιες όχι. Το αποτέλεσμα της διαδικασίας είναι ότι το δίκτυο είναι σε θέση να αφομοιώσει τις μακροπρόθεσμες εξαρτήσεις ανάμεσα σε ακολουθιακά δεδομένα όπως ομιλία, γραπτά κείμενα και δεδομένα χρονικών σειρών.

Ωστόσο, όπως αναφέρθηκε προηγουμένως, τα RNNs μπορεί να αντιμετωπίζουν προβλήματα με την εκπαίδευση και την απώλεια της πληροφορίας σε μεγάλα χρονικά βήματα, καθώς και την ευαισθησία στην αρχική κατάσταση του δικτύου. Ως αποτέλεσμα, έχουν προταθεί εναλλακτικές αρχιτεκτονικές, όπως οι CNNs και οι TCNs (Temporal Convolutional Networks), που είναι δυνατόν να αντιμετωπίσουν αυτά τα προβλήματα με πιο αποτελεσματικό τρόπο. Στην περίπτωση των CNNs, χρησιμοποιούνται συνήθως μίας διάστασης συνελίξεις για την εξαγωγή χαρακτηριστικών από χρονοσειρές, ενώ οι TCNs χρησιμοποιούν συνελίξεις σε συνδυασμό με την αντιγραφή στοιχείων (dilated convolutions) για την επέκταση του πεδίου όρασης του δικτύου και την αντιμετώπιση της πρόκλησης της μοντελοποίησης μακροπρόθεσμων εξαρτήσεων.

Επιπλέον, τα δίκτυα LSTM εφαρμόζονται σε ένα ευρύ φάσμα διεργασιών, το οποίο περιλαμβάνει επεξεργασία φυσικής γλώσσας και αναγνώριση ομιλίας. Στην επεξεργασία φυσικής γλώσσας χρησιμοποιείται για την μοντελοποίηση των εξαρτήσεων μεταξύ λέξεων σε μία πρόταση και αποδίδει καλύτερα από παραδοσιακά δίκτυα RNNs ή άλλα ακολουθιακά μοντέλα. Στην αναγνώριση ομιλίας,

μοντελοποιούν τις εξαρτήσεις μεταξύ δεδομένων ήχου επιτρέποντας την αναγνώριση ομιλίας ακόμα και με την παρουσία θορύβου.

Ωστόσο υπάρχουν και περιορισμοί. Είναι απαραίτητο να αναφερθεί το πρόβλημα της μετάφρασης καθώς όσο τα κελιά μνήμης λειτουργούν είναι δύσκολο για τις πύλες να το αντιληφθούν. Επιπλέον, είναι ακριβά από υπολογιστική άποψη καθώς απαιτούνται αρκετοί πόροι για την επεξεργασία και εκπαίδευση μεγάλων βάσεων δεδομένων ή ακολουθιών.

Εν κατακλείδι, αν και τα δίκτυα LSTM κρύβουν σημαντικές δυσκολίες αποτελούν έναν ιδιαίτερο τύπο επαναλαμβανόμενου («recurrent») νευρωνικού δικτύου το οποίο έφερε την επανάσταση στο πεδίο ανάλυσης ακολουθιακών δεδομένων με την ικανότητα τους να διατηρούν μακροχρόνιες εξαρτήσεις.

2.2.3. Convolutional Neural Networks (CNNs)

Τα Convolutional Neural Networks (CNNs) αποτελούν έναν τύπο νευρωνικού δικτύου βαθιάς εκμάθησης («Deep Learning») όπως και τα «Recurrent». Η χρήση τους είναι αρκετά διευρυμένη στο πεδίο της υπολογιστικής όρασης και αναγνώρισης εικόνας. Οι ρίζες των CNNs χρονολογούνται στο τέλος της δεκαετίας του 90 με την δημοσίευση του άρθρου Yann LeCun όπου για πρώτη φορά εφαρμόστηκε επιτυχημένα η αναγνώριση ψηφίων αριθμών γραμμένων από ανθρώπινο χέρι. (LeCun Y. B., 1998)

Πιο συγκεκριμένα, η κύρια λειτουργία των CNNs ήταν η αυτοματοποιημένη εκμάθηση ιεραρχικών αναπαραστάσεων οπτικής πληροφορίας. Η ανάπτυξη τους αφορούσε την επίλυση προβλημάτων αλγορίθμων μηχανικής μάθησης όπου ήταν αδύνατη η λειτουργία τους χωρίς την παρέμβαση ανθρώπου. Τα δίκτυα CNNs αποτελούνται από επίπεδα τα οποία δέχονται σαν είσοδο μία εικόνα και εντοπίζουν χαρακτηριστικά όπως γωνίες, ακμές και κομμάτια γραφής. Έπειτα, μεταβιβάζονται στα επόμενα επίπεδα όπου εφαρμόζονται μη γραμμικές συναρτήσεις ενεργοποίησης για την εκπαίδευση υψηλότερου επιπέδου αναπαραστάσεις της φωτογραφίας. (Krizhevsky, 2012)

Επιπλέον, είναι απαραίτητο να αναφερθούμε στα πεδία εφαρμογής των CNNs. Αναλυτικότερα, στην υπολογιστική όραση χρησιμοποιούνται για την ανίχνευση, κατηγοριοποίηση και καταγραφή αντικειμένων. Στην ιατρική, γνώρισαν ιδιαίτερη επιτυχία καθώς χρησιμοποιούνται για κατηγοριοποίηση μολώπων και μυϊκών ιστών (Szegedy, 2015). Ακόμα, εφαρμόζονται στον τομέα επεξεργασίας φυσικής γλώσσας, δηλαδή σε πεδία ταξινόμησης κειμένων και αναγνώρισης συναισθημάτων. Παράλειψη θα ήταν να μην αναφερθούν και οι εφαρμογές τους στην ρομποτική όπου χρησιμοποιούνται για διεργασίες όπως στην πλοήγηση. (Simonyan, 2014)

Πάρα την ευρεία επιτυχία των CNNs ελλοχεύουν και αρκετοί περιορισμοί. Ειδικότερα, διακρίνονται από ιδιαίτερη ευαισθησία σε σχέση με τον προσανατολισμό των αντικειμένων της φωτογραφίας στο χώρο. Επιπροσθέτως, η διαδικασία της εκπαίδευσης τους είναι υπολογιστικά ακριβή, δηλαδή απαιτείται ένας τεράστιος αριθμός υπολογισμών και πόρων μνήμης. Τέλος, ελλοχεύει ο κίνδυνος του λεγόμενου

«overfitting» που σημαίνει ότι το δίκτυο δεν έχει αξιόπιστη επίδοση σε άγνωστα δεδομένα. (He, 2016)

2.2.4. Autoencoders

Οι αυτόματοι κωδικοποιητές αλλιώς «autoencoders» αποτελούν έναν σχετικά πρόσφατο τύπο νευρωνικών δικτύων με χρήση σε ένα ευρύ φάσμα εφαρμογών. Αρχικά εισήχθησαν ως ένα μοντέλο μη επιβλεπόμενης μάθησης, του οποίου στόχος ήταν η απλοποίηση των δεδομένων εισόδου χωρίς την χρήση ετικετών. Με άλλα λόγια, εκπαίδευση του δικτύου με δεδομένα εισόδου χωρίς την χρήση ετικετών για την αναπαράστασή τους. Με την πάροδο των χρόνων οι «autoencoders» έχουν εξελιχθεί και βελτιωθεί ώστε να συμβάλουν στην επίλυση περισσότερων προβλημάτων, όπως μείωση διαστάσεων («dimensionality reduction»), δημιουργία προτύπων («Generative modeling») και εκμάθησης χαρακτηριστικών.

Με τον όρο μείωση διαστάσεων («dimensionality reduction») αναφερόμαστε στην διαδικασία μείωσης των χαρακτηριστικών μίας βάσης δεδομένων διατηρώντας τις πιο σημαντικές πληροφορίες. Η διαδικασία που ακολουθείται έχει ως εξής: κωδικοποίηση των δεδομένων εισόδου σε μία αναπαράσταση με λιγότερα χαρακτηριστικά και μετά αποκωδικοποίηση στην αρχική μορφή (Vincent, 2010).

Με τον όρο δημιουργία προτύπων («Generative modeling») αναφερόμαστε στην δημιουργία δεδομένων παρόμοιων με αυτών που προορίζονται για την εκπαίδευση ενός τεχνητού νευρωνικού δικτύου. Η προαναφερθείσα μέθοδος επιτυγχάνεται μέσω της χρήσης της κωδικοποιημένης αναπαράστασης και έπειτα γίνεται η δημιουργία νέων δεδομένων από αυτή. (Kingma D. P., 2013)

Με τον όρο εκμάθησης χαρακτηριστικών αναφερόμαστε στην επεξεργασία χρήσιμων χαρακτηριστικών μίας βάσεως δεδομένων. Η διεργασία αυτή επιτυγχάνεται κατά την διάρκεια εκπαίδευσης του δικτύου μέσω της εκμάθησης των δεδομένων εισόδου.

Πρωτεργάτες, θεωρούνται οι Yann LeCun, Yoshua Bengio, και Geoffrey Hinton οι οποίοι στα τέλη της δεκαετίας του 80 πρότειναν την εκπαίδευση ενός νευρωνικού δικτύου με ανακατασκευή των εισόδων του έχοντας ως στόχο μία πιο συμπαγή αναπαράσταση των δεδομένων εισόδου. Ειδικότερα, η κυρίως ιδέα είναι η κωδικοποίηση των δεδομένων εισόδου σε μια πιο χαμηλού επιπέδου αναπαράσταση. Η διαδικασία κωδικοποίησης-αποκωδικοποίησης διενεργείται από το νευρωνικό δίκτυο για τον εντοπισμό των χρήσιμων χαρακτηριστικών της εισόδου. Η κωδικοποιημένη αναπαράσταση αναφέρεται συχνά και ως ένα «bottleneck». (Martens, 2010)

Σημαντικό να τονιστούν κάποιες ενδεικτικές εφαρμογές των «Autoencoders» περιλαμβάνουν την συμπίεση φωτογραφιών, τον εντοπισμό ανωμαλιών και την δημιουργία τέχνης από κάποιο αυτόματο σύστημα «generative art». Με την συμπίεση φωτογραφιών επιτυγχάνεται μικρότερο μέγεθος διατηρώντας τα απαραίτητα χαρακτηριστικά της. Όσον αφορά στον εντοπισμό ανωμαλιών, χρησιμοποιούνται για τον εντοπισμό προτύπων των οποίων τα δεδομένα διαφέρουν αρκετά από τα

συνηθισμένα. Στον τομέα της τέχνης, δημιουργούν νέες εικόνες παρόμοιες με αυτές που έχει εκπαιδευτεί το δίκτυο. (Hinton G. E., 2006)

Παρά το γεγονός ότι οι «autoencoders» παρέχουν αμέτρητα οφέλη είναι σημαντικό να αναφερθούν και κάποιοι περιορισμοί. Ένα πολύ σημαντικό πρόβλημα, είναι ότι δεν παράγουν πάντοτε την καλύτερη δυνατή αναπαράσταση των δεδομένων εισόδου καθώς η διαδικασία κωδικοποίησης-αποκωδικοποίησης διενεργείται μέσω εκτιμήσεων. Ακόμη ένα κοινό πρόβλημα εντοπίζεται στην δομή των «autoencoders» που περιορίζει τον αριθμό των κρυφών επιπέδων και των συναρτήσεων ενεργοποίησης του δικτύου. (Ng, 2008)

2.2.5. Generative Adversarial Networks (GANs)

Τα «Generative Adversarial Networks» γνωστά και ως «GANs» ή στα ελληνικά γνωστά και ως Παραγωγικά Ανταγωνιστικά Δίκτυα αποτελούν ένα είδος μοντέλου βαθιάς εκμάθησης νευρωνικού δικτύου το οποίο εισήχθη πρώτα από τους Ian J. Goodfellow, Jean Pouget-Abadie, MehdiMirza, Bing Xu, David Warde-Farley, SherjilOzair, Aaron Courville, και YoshuaBengio το 2014 στο ακαδημαϊκό άρθρο «Generative Adversarial Nets.». Η κύρια ιδέα πίσω από το συγκεκριμένο τύπο δικτύου είναι ότι χρησιμοποιούνται δύο νευρωνικά δίκτυα, μία γεννήτρια και ένας ταξινομητής που ανταγωνίζονται ο ένας τον άλλον με στόχο την παραγωγή συνθετικών δεδομένων τα οποία θα θυμίζουν πραγματικά δεδομένα. (Goodfellow, 2014)

Η γεννήτρια παράγει συνεχώς συνθετικά δείγματα και το δίκτυο του ταξινομητή αξιολογεί τα δεδομένα προκειμένου να αποφανθεί εάν είναι αληθινά ή όχι. Σημαντικό να αναφερθεί ότι, τα προαναφερθέντα νευρωνικά δίκτυα εκπαιδεύονται ταυτόχρονα, με την γεννήτρια να προσπαθεί να παράξει δεδομένα όσο το δυνατόν πιο κοντά στα πραγματικά και τον ταξινομητή να προσπαθεί με ακρίβεια να διαχωρίσει τα παραγόμενα δεδομένα. (Radford, 2016)

Τα Παραγωγικά Ανταγωνιστικά Δίκτυα εφαρμόζονται σε ένα ευρύ φάσμα προβλημάτων όπως είναι η μη επιβλεπόμενη εκπαίδευση «unsupervised learning», η παραγωγή δεδομένων και η σύνθεση φωτογραφιών. Για παράδειγμα, τα «GANs» χρησιμοποιούνται για την παραγωγή νέων εικόνων ανθρώπινων προσώπων, ζώων και άλλων αντικειμένων όπως επίσης και δημιουργία συνθετικών εικόνων αντικειμένων και σκηνικών. Επίσης, βρίσκουν εφαρμογή στην παραγωγή εικόνων ψηφίων αριθμών γραμμένων με το χέρι. (Mirza, 2014)

Μολονότι, προσφέρουν τόσες λύσεις τα Παραγωγικά Ανταγωνιστικά Δίκτυα έχουν και κάποιους περιορισμούς. Ειδικότερα, είναι ευάλωτα σε κατάρρευση «crash» όταν η γεννήτρια παράγει έναν συγκεκριμένο αριθμό δειγμάτων όπως επίσης όταν επηρεάζονται από αστάθεια εκπαίδευσης («training instability») όπου η γεννήτρια και ο ταξινομητής εγκλωβίζονται σε έναν ατελείωτο κύκλο βελτίωσης. Προκειμένου να αντιμετωπιστούν αυτές οι προκλήσεις ερευνητές πρότειναν διάφορες παραλλαγές της παραδοσιακής δομής δικτύων «GANs», εισάγοντας τις αρχιτεκτονικές «Wasserstein GAN», τα «InfoGAN», και τα «Conditional GAN». (Arjovsky, 2017) (Chen, 2016)

2.3. Χρήση τεχνητών νευρωνικών δικτύων στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης

Τα τεχνητά νευρωνικά δίκτυα είναι ευρέως γνωστά στον τομέα ανάλυσης δεδομένων, ειδικότερα στο κομμάτι των δεδομένων αθλημάτων. Η ικανότητα εκπαίδευσης τους με πολύπλοκα μοντέλα και η παραγωγή αποτελεσμάτων τα καθιστούν ιδιαίτερος χρήσιμα στο πρωτάθλημα του NBA ή του WNBA.

Ειδικότερα, ένα από τα κύρια πλεονεκτήματα αποτελεί η διαδικασία εκμάθησης τους από τεράστιο όγκο δεδομένων. Για το πρωτάθλημα καλαθοσφαίρισης της Αμερικής, σημαίνει ότι είναι δυνατή η εκπαίδευση των νευρωνικών δικτύων με ιστορικά δεδομένα, στατιστικά αθλητών, αποτελέσματα αγώνων και άλλες σχετικές πληροφορίες. Ως αποτέλεσμα, θα είναι σε θέση να αναγνωρίσουν συσχετίσεις μεταξύ δεδομένων και να κάνουν προβλέψεις που να μην είναι προφανείς σε έναν αναλυτή. Οι προβλέψεις είναι απαραίτητες για τον εκάστοτε αθλητικό σύλλογο για να παρατηρηθεί η επαγγελματική επιτυχία όχι μόνο ενός αθλητή αλλά και ενός προπονητή ή ακόμα και ενός παράγοντα αθλητικού συλλόγου.

3. Υλοποίηση σε λογισμικό

3.1. Εισαγωγή

Στο παρακάτω κεφάλαιο θα αναλυθεί εις βάθος το πείραμα της εφαρμογής των τεχνητών νευρωνικών δικτύων στην απόδοση των αθλητών και αθλητριών καλαθοσφαίρισης. Το κεφάλαιο είναι δομημένο ώστε να καλύπτει τα διάφορα κρίσιμα στοιχεία που είναι απαραίτητα για την επιτυχή υλοποίηση του πειράματος.

Σκοπός της εργασίας είναι η πρόβλεψη απόδοσης πόντων καλαθοσφαιριστών και καλαθοσφαιριστριών στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης στο «NBA» και «WNBA». Ταυτόχρονα θα μελετηθεί για τους άνδρες και η απόδοση τους σε συνθήκες πίεσης. Για την επίτευξη των παραπάνω έγινε χρήση των αλγορίθμων Τεχνητού Νευρωνικού δικτύου (ΤΝΔ) και του Πλησιέστερου γείτονα («RBF») με την χρήση της γλώσσας PYTHON (στο Google Colab) και στην εφαρμογή της MATLAB (μόνο ο αλγόριθμος ΤΝΔ)

Αρχικά, θα αναλυθούν τα δεδομένα και πιο συγκεκριμένα οι διαδικασίες και τεχνικές που χρησιμοποιήθηκαν για την προετοιμασία του συνόλου των δεδομένων για ανάλυση. Έπειτα θα παρουσιαστεί η αρχιτεκτονική και τα είδη των νευρωνικών δικτύων που χρησιμοποιήθηκαν συμπεριλαμβανομένων των συναρτήσεων, των αλγορίθμων και των κρυφών επιπέδων που έγινε χρήση για την δημιουργία του δικτύου.

3.2. Υπολογιστής που χρησιμοποιήθηκε

Για τις ανάγκες της εργασίας χρησιμοποιήθηκε ο προσωπικός υπολογιστής του φοιτητή. Ειδικότερα, έγινε χρήση του υπολογιστή ASUS με τα ακόλουθα χαρακτηριστικά:

- Intel core i5 5200u
- 8gb RAM DDR4
- 1TB SSD Hard Drive
- Windows 10 Home
- NVIDIA GeForce 720 MX graphics card

3.3. Δεδομένα

Η διαδικασία συλλογής ακριβών και συνολικών δεδομένων αποτελεί ένα κρίσιμο στοιχείο σε κάθε στατιστική ανάλυση. Αντίστοιχα και στην παρακάτω έρευνα επιλέχθηκαν συγκεκριμένες ιστοσελίδες από τις οποίες συλλέχθηκαν τα αντίστοιχα δεδομένα στατιστικών αθλητών και αθλητριών του NBA και WNBA αντίστοιχα. Οι ιστοσελίδες που επιλέχθηκαν αξιολογήθηκαν βάσει μιας σειράς κριτηρίων, περιλαμβανομένων της ακρίβειας και της αξιοπιστίας των δεδομένων που παρέχονται, της ευκολίας πρόσβασης στα δεδομένα και της έκτασης κάλυψης των δεδομένων.

Συγκεκριμένα, επιλέχθηκαν ως κύριες πηγές δεδομένων η επίσημη ιστοσελίδα του NBA, του WNBA το basketball-reference.com και το stats.nba.com. Αυτές οι ιστοσελίδες επιλέχθηκαν λόγω της συνολικής κάλυψης των στατιστικών των αθλητών και αθλητριών συμπεριλαμβανομένων ευρέως φάσματος μετρικών, όπως το «Player Efficiency Rating» (PER) και το «true shooting percentage» (TS%). Επιπλέον, αυτές οι ιστοσελίδες παρέχουν εύκολη πρόσβαση σε δεδομένα δομημένης μορφής, επιτρέποντας την εύκολη ροή εξαγωγής και προετοιμασίας των δεδομένων για ανάλυση. Αποτυπώνεται στην παρακάτω εικόνα η ευκολία άντλησης στατιστικών αθλητών, στην προκειμένη περίπτωση για τον πιο γνωστό καλαθοσφαιριστή LeBron James.

Per Game

Regular Season

Playoffs

Bold indicates league leader

Share & Export

Glossary

Modify, Export & Share Table

Get as Excel Workbook

Get table as CSV (for Excel)

Get Link to Table

About Sharing Tools

Video: SR Sharing Tools & How-to

Video: Stats Table Tips & Tricks

Data Usage Terms

Season	Age	Tm	Lg	Pos	G	GS	FT	FTA	FT%	ORB	DRB	TRB	AST	STL	BLK	TOV	PF	PTS
2003-04	19	CLE	NBA	SG	79	79	4.4	5.8	.754	1.3	4.2	5.5	5.9	1.6	0.7	3.5	1.9	20.9
2004-05 ★	20	CLE	NBA	SF	80	80	6.0	8.0	.750	1.4	6.0	7.4	7.2	2.2	0.7	3.3	1.8	27.2
2005-06 ★	21	CLE	NBA	SF	79	79	7.6	10.3	.738	0.9	6.1	7.0	6.6	1.6	0.8	3.3	2.3	31.4
2006-07 ★	22	CLE	NBA	SF	78	78	6.3	9.0	.698	1.1	5.7	6.7	6.0	1.6	0.7	3.2	2.2	27.3
2007-08 ★	23	CLE	NBA	SF	75	74	7.3	10.3	.712	1.8	6.1	7.9	7.2	1.8	1.1	3.4	2.2	30.0
2008-09 ★	24	CLE	NBA	SF	81	81	7.3	9.4	.780	1.3	6.3	7.6	7.2	1.7	1.1	3.0	1.7	28.4
2009-10 ★	25	CLE	NBA	SF	76	76	7.8	10.2	.767	0.9	6.4	7.3	8.6	1.6	1.0	3.4	1.6	29.7
2010-11 ★	26	MIA	NBA	SF	79	79	.541	6.4	8.4	.759	1.0	6.5	7.5	7.0	1.6	0.6	3.6	2.1
2011-12 ★	27	MIA	NBA	SF	62	62	.554	6.2	8.1	.771	1.5	6.4	7.9	6.2	1.9	0.8	3.4	1.5
2012-13 ★	28	MIA	NBA	PF	76	76	.603	5.3	7.0	.753	1.3	6.8	8.0	7.3	1.7	0.9	3.0	1.4
2013-14 ★	29	MIA	NBA	PF	77	77	.610	5.7	7.6	.750	1.1	5.9	6.9	6.3	1.6	0.3	3.5	1.6
2014-15 ★	30	CLE	NBA	SF	69	69	.535	5.4	7.7	.710	0.7	5.3	6.0	7.4	1.6	0.7	3.9	2.0
2015-16 ★	31	CLE	NBA	SF	76	76	.551	4.7	6.5	.731	1.5	6.0	7.4	6.8	1.4	0.6	3.3	1.9
2016-17 ★	32	CLE	NBA	SF	74	74	.594	4.8	7.2	.674	1.3	7.3	8.6	8.7	1.2	0.6	4.1	1.8
2017-18 ★	33	CLE	NBA	PF	82	82	.590	4.7	6.5	.731	1.2	7.5	8.6	9.1	1.4	0.9	4.2	1.7
2018-19 ★	34	LAL	NBA	SF	55	55	.560	5.1	7.6	.665	1.0	7.4	8.5	8.3	1.3	0.6	3.6	1.7
2019-20 ★	35	LAL	NBA	PG	67	67	.550	3.9	5.7	.693	1.0	6.9	7.8	10.2	1.2	0.5	3.9	1.8
2020-21 ★	36	LAL	NBA	PG	45	45	.576	4.0	5.7	.698	0.6	7.0	7.7	7.8	1.1	0.6	3.7	1.6
2021-22 ★	37	LAL	NBA	C	56	56	.590	4.5	6.0	.756	1.1	7.1	8.2	6.2	1.3	1.1	3.5	2.2
2022-23 ★	38	LAL	NBA	PF	47	47	.549	4.8	6.3	.759	1.2	7.2	8.4	6.9	0.9	0.6	3.1	1.7

Εικόνα 4: Στατιστικά LeBron James

(Στατιστικά καριέρας LeBron James από την ιστοσελίδα [basketball-reference.com](#))

Είναι σημαντικό να σημειωθεί ότι η ποιότητα των δεδομένων που χρησιμοποιούνται σε στατιστική ανάλυση έχει άμεση επίδραση στην ακρίβεια και στην εγκυρότητα των αποτελεσμάτων που προκύπτουν. Συνεπώς, η επιλογή αξιόπιστων και έμπιστων πηγών είναι ζωτικής σημασίας σε κάθε μελέτη που βασίζεται σε δεδομένα. Ως εκ τούτου, οι επιλεγμένες ιστοσελίδες αξιολογήθηκαν για

την καταλληλότητα τους στην παροχή αξιόπιστων και ολοκληρωμένων δεδομένων, εξασφαλίζοντας την ακρίβεια και την αξιοπιστία των αποτελεσμάτων της έρευνας.

Πιο συγκεκριμένα, τα δεδομένα που χρησιμοποιήθηκαν για την υλοποίηση της εργασίας περιλαμβάνουν στατιστικά αθλητών ανδρών και γυναικών της καλαθοσφαίρισης του Αμερικάνικου πρωταθλήματος καλαθοσφαίρισης ή αλλιώς NBA για τους άνδρες και WNBA για τις γυναίκες. Περιλαμβάνονται στοιχεία για:

1. Ηλικία
2. Θέση αθλητή
3. Ποσοστό αγώνων συμμετοχής για την μελέτη του επηρεασμού των τραυματισμών
4. Λεπτά συμμετοχής σε κανονική περίοδο πρωταθλήματος
5. Ποσοστό ευστοχίας προσπαθειών για σουτ FG%
6. Πραγματικό ποσοστό ευστοχίας σουτ eFG%
7. Ποσοστό ευστοχίας βολών FT%
8. Λάθη TOV
9. Μ.Ο.¹⁶ πόντων ανά παιχνίδι στην τρέχουσα κανονική περίοδο πρωταθλήματος
10. Μ.Ο. πόντων ανά παιχνίδι στην τρέχουσα κανονική περίοδο πρωταθλήματος, αλλά κάτω από συνθήκες πίεσης (clutch time)

Όσον αφορά την βάση δεδομένων του NBA, περιέχονται συνολικά 77 αθλητές καθ' όλη την πορεία της καριέρας τους διαμορφώνοντας ένα δείγμα 710 γραμμών. Περιέχονται αθλητές οι οποίοι έχουν ολοκληρώσει την καριέρα τους, αθλητές στην ενεργό δράση, γνωστοί και μη, από διαφορετικές εθνικότητες και όσον γίνεται από διαφορετικές θέσεις.

Επιπλέον της προαναφερθείσας βάσης δεδομένων υπάρχει και μία βάση με στοιχεία καλαθοσφαιριστών του NBA κάτω από συνθήκες πίεσης. Σε έναν αγώνα καλαθοσφαίρισης συνθήκη πίεσης ή αλλιώς «clutch time» ορίζουμε τα τελευταία 5 λεπτά ενός αγώνα όταν η διαφορά μεταξύ δύο ομάδων είναι 5 πόντοι. Επειδή τα δεδομένα αυτά καταγράφονται από το 1994 και μετά η βάση περιέχει ένα δείγμα 26 αθλητών ενεργών είτε με ολοκληρωμένη καριέρα, διαμορφώνοντας ένα δείγμα 226 γραμμών.

¹⁶ Μ.Ο.: Μέσος Όρος

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG	AH	AI	AJ	AK				
	PLAYER	AGE	POS	season	Total	machines	per cent	MP	MP	PER FG	3P%	FT%	TRB	TREB	WAST	AST	M	STL	TOV	TOV	M	PF	PF	PTS	PTS	MIN	PTS	PTS	CONF	3P	FT	REB	REB	INST	AG	STL	BLK	PF	C		
1	Karl Lee	21 SF	2011-12	66	64	0.97	31.2	0.65	0.84	0.374	0.825	6	0.19	1.6	0.05	1.7	0.05	1.1	0.04	1.7	0.05	11.9	0.38	1.8	0.4	0.2222	40	0	50	0.5	0.27778	0	0	0.1	0	0	0	0	0	0	0
2	Karl Lee	22 SF	2012-13	82	58	0.71	28.1	0.61	0.522	0.379	0.802	6.2	0.21	2	0.07	1.7	0.06	1.2	0.04	1.9	0.07	12.8	0.44	3.5	1.5	0.4222	43	37.5	76.9	0.9	0.25714	0.2	0.1	0.3	0.1	0.3	0.1	0.3	0.1	0.3	0.1
3	Karl Lee	23 SF	2013-14	82	66	0.8	31.8	0.68	0.479	0.349	0.802	7.2	0.23	2.5	0.08	2.3	0.07	1.5	0.05	2	0.06	16.5	0.52	2.9	1	0.34483	42.9	37.5	75	0.8	0.2069	0.2	0.1	0.1	0.1	0.2	0.1	0.2	0.1	0.2	0.1
4	Karl Lee	24 SF	2014-15	82	64	0.76	33.1	0.69	0.508	0.443	0.874	6.8	0.21	2.8	0.08	1.8	0.05	1.5	0.05	1.8	0.05	21.2	0.64	3.7	1.4	0.37038	28	0	76.2	0.8	0.21622	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
5	Karl Lee	25 SF	2015-16	82	72	0.86	33.4	0.7	0.465	0.38	0.88	5.8	0.17	3.5	0.1	1.8	0.05	2.1	0.06	1.8	0.05	25.5	0.76	3.7	2.3	0.82182	41.9	30	86.5	1	0.27027	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
6	Karl Lee	26 SF	2016-17	82	74	0.9	23.3	0.49	0.468	0.314	0.816	4.7	0.2	2.3	0.1	2	0.09	1.8	0.08	1	0.04	16.2	0.7	3.7	3.8	1.02703	41.2	27.3	80.3	0.9	0.24324	0.4	0.2	0.3	0.1	0.1	0.1	0.1	0.1	0.1	0.1
7	Karl Lee	27 SF	2017-18	82	60	0.73	34	0.71	0.468	0.374	0.854	7.3	0.21	3.3	0.1	1.8	0.05	2	0.08	1.5	0.04	28.6	0.78	4.5	4.8	1.02222	48.6	31	84.1	0.8	0.17778	0.4	0.3	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
8	Karl Lee	28 SF	2018-19	72	57	0.79	32.4	0.68	0.47	0.376	0.866	7.1	0.22	4.3	0.15	1.8	0.06	2.6	0.08	2	0.06	27.1	0.8	3.6	2.8	0.77778	38.6	14.3	92.6	0.7	0.19444	0.6	0.3	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
9	Karl Lee	29 SF	2019-20	72	52	0.72	34.1	0.71	0.512	0.396	0.865	6.5	0.19	5.2	0.15	1.6	0.06	2	0.06	1.8	0.05	24.8	0.73	2.7	2.8	0.77778	31.4	20	85.5	0.9	0.33333	0.3	0.4	0	0.1	0.1	0.1	0.1	0.1	0.1	
10	Karl Lee	30 SF	2020-21	72	52	0.72	34.1	0.71	0.512	0.396	0.865	6.5	0.19	5.2	0.15	1.6	0.06	2	0.06	1.8	0.05	24.8	0.73	2.7	2.8	0.77778	31.4	20	85.5	0.9	0.33333	0.3	0.4	0	0.1	0.1	0.1	0.1	0.1	0.1	
11	Karl Lee	31 SF	1997-98	82	41	0.98	37.4	0.78	0.53	0.333	0.761	10.3	0.28	3.9	0.1	1.2	0.03	3	0.09	2.7	0.07	23.8	0.64	4.6	3.1	0.67581	39.3	0	75.7	1.3	0.26261	0.4	0.2	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
12	Karl Lee	32 SF	1998-99	82	49	0.96	37.4	0.78	0.53	0.333	0.761	10.3	0.28	3.9	0.1	1.2	0.03	3	0.09	2.7	0.07	23.8	0.64	4.6	3.1	0.67581	39.3	0	75.7	1.3	0.26261	0.4	0.2	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
13	Karl Lee	33 SF	1999-00	82	82	1	35.9	0.75	0.509	0.25	0.797	9.5	0.26	3.7	0.1	1	0.03	2.8	0.08	2.8	0.08	25.5	0.71	3.3	2.7	0.61818	49.4	0	80.5	1	0.30003	0.4	0.4	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
14	Karl Lee	34 SF	2000-01	82	81	0.99	35.7	0.74	0.498	0.4	0.793	8.3	0.23	4.3	0.1	1	0.03	3	0.08	2.7	0.08	23.2	0.66	3.4	2.8	0.82353	58.4	0	81.5	1	0.28412	0.4	0.4	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
15	Karl Lee	35 PF	2001-02	82	80	0.98	38	0.79	0.54	0.36	0.797	8.6	0.23	4.3	0.1	1.9	0.05	3.3	0.09	2.9	0.08	22.4	0.59	4.2	2.5	0.5824	41.9	40	87.1	0.9	0.21429	0.3	0.2	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
16	Karl Lee	36 PF	2002-03	82	81	0.99	38.2	0.75	0.462	0.214	0.763	7.8	0.22	4.7	0.1	1.7	0.05	2.6	0.07	2.5	0.07	20.6	0.57	4	2.6	0.65	55.2	0	72.2	1.1	0.275	0.4	0.1	0.3	0.1	0.3	0.1	0.3	0.1	0.3	0.1
17	Karl Lee	37 PF	2003-04	82	42	0.51	32.7	0.68	0.403	0	0.747	8.7	0.27	3.9	0.12	1.2	0.04	2.5	0.08	2.8	0.09	13.2	0.4	3.7	1.1	0.2973	35.3	0	80	0.8	0.21622	0.2	0.2	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1
18	Karl Lee	38 PF	2004-05	75	61	0.81	33.6	0.7	0.463	0.316	0.758	9.4	0.26	8.8	0.26	1	0.03	4.3	0.13	2.5	0.07	26.8	0.66	3.6	3.2	0.88889	44.6	30	86.7	0.9	0.25	0.6	0.3	0.1	0.1	0.1	0.1	0.1	0.1		
19	Karl Lee	39 PF	2005-06	72	68	0.92	34.3	0.71	0.479	0.35	0.723	8	0.23	8.8	0.25	1.2	0.03	4.3	0.13	2.3	0.07	27.7	0.61	3.1	2.6	0.90203	47.6	26.1	83.3	0.9	0.26072	0.7	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
20	Karl Lee	40 PF	2006-07	82	65	0.79	35.4	0.74	0.457	0.353	0.744	9.1	0.26	8.7	0.25	1.2	0.03	4.5	0.13	2.2	0.08	26.4	0.6	3.2	2.7	0.84035	48.4	23.1	85.7	0.8	0.1875	0.5	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
21	Karl Lee	21 C	2017-18	82	63	0.77	30.3	0.63	0.403	0.308	0.769	11	0.36	3.2	0.11	0.7	0.02	3.5	0.1	3.3	0.11	22.9	0.78	3.3	3.2	0.9467	40.6	25	85.7	0.9	0.22773	0.1	0.8	0.2	0.4	0.6	0.4	0.6	0.4	0.6	0.4
22	Karl Lee	22 C	2018-19	82	64	0.76	33.7	0.7	0.464	0.3	0.804	13.6	0.4	3.7	0.11	0.7	0.02	3.5	0.1	3.3	0.11	27.5	0.82	3.4	2.4	0.76666	47.2	33.3	72.2	1.3	0.30205	0.6	0.3	0	0.1	0.1	0.1	0.1	0.1	0.1	0.1
23	Karl Lee	23 C	2019-20	73	51	0.7	29.5	0.61	0.477	0.331	0.807	11.6	0.39	3	0.1	0.9	0.03	3.1	0.11	3.4	0.12	23	0.78	3.1	3.8	1.22581	53.2	46.2	87.5	1	0.32258	0.3	0.5	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
24	Karl Lee	24 C	2020-21	72	51	0.71	31.1	0.65	0.513	0.377	0.859	10.8	0.34	2.8	0.09	1	0.03	3.1	0.11	2.4	0.08	26.5	0.92	3.7	3.9	1.05405	42.9	33.3	87	1.4	0.37638	0.3	0.4	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
25	Karl Lee	25 C	2021-22	82	68	0.83	33.8	0.7	0.469	0.371	0.814	11.7	0.36	4.2	0.12	1.1	0.03	3.1	0.09	2.7	0.08	30.8	0.91	4.1	4.4	1.07317	47	45.8	76.8	1.3	0.31707	0.5	0.3	0.2	0.4	0.6	0.6	0.6	0.6	0.6	0.6
26	Karl Lee	26 C	2022-23	82	64	0.78	35.2	0.73	0.519	0.222	0.791	10	0.28	1.6	0.05	1.3	0.04	1.6	0.05	3	0.09	20.8	0.59	3.1	1.4	0.45161	57.1	0	80	0.9	0.26032	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
27	Karl Lee	27 C	2023-24	82	67	0.82	38.1	0.75	0.535	0.383	0.805	10.2	0.28	2.2	0.06	1.5	0.04	1.4	0.04	2.1	0.06	24.4	0.68	3.6	2.1	0.58333	48.2	0	87.1	1.5	0.41667	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
28	Karl Lee	28 C	2024-25	82	68	0.83	35.5	0.74	0.493	0.324	0.798	10.3	0.29	1.9	0.05	1.3	0.04	2.4	0.07	2.2	0.06	28	0.78	4.4	3.5	0.79455	41.6	20	74.1	2	0.45455	0.1	0.3	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
29	Karl Lee	29 C	2025-26	82	75	0.91	38.4	0.78	0.534	0.34	0.828	11.1	0.3	2.3	0.06	1.5	0.04	2.2	0.06	2.1	0.06	28.1	0.77	4.6	3.4	0.79513	51.6	0	84.6	1.5	0.38889	0.2	0.2	0.2	0.3	0.2	0.3	0.2	0.3	0.2	0.3
30	Karl Lee	30 C	2026-27	82	75	0.91	33	0.69	0.517	0.331	0.794	12	0.36	3.9	0.12	1.6	0.05	2	0.06	2.4	0.07	25.9	0.78	2.8	2	0.76923	44.4	7.7	84.3	0.9	0.34615	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
31	Karl Lee	31 C	2027-28	82	58	0.69	34.4	0.72	0.503	0.33	0.748	9	0.27	3.2	0.09	1.5	0.04	2.5	0.07	2.5	0.07	26.1	0.76	3.7	3.4	0.91692	40.3	38.4	77.3	1	0.27027	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
32	Karl Lee	32 C	2028-29	71	62	0.87	32.3	0.67	0.461	0.28	0.738	7.9	0.24	3.1	0.07	1.3	0.04	2.1	0.07	1.7	0.05	21.8	0.67	3.8	2.2	0.57965	36.5	42.9	100	0.9	0.26884	0.4	0.2	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
33	Karl Lee	33 C	2029-30	72	38	0.5	35.1	0.73	0.532	0.186	0.713	9.9	0.28	3.1	0.09	1.2	0.03	2.1	0.06	2.4	0.07	23.2	0.66	5	3	0.6	54.2	0	70.8	1.8	0.38	0.5	0.1	0.2	0.3	0.5	0.1	0.2	0.3	0.5	0.1
34	Karl Lee	34 C																																							

Προς συμπλήρωση αυτής της ανάλυσης, περιλαμβάνεται επίσης μια ομάδα από 20 αθλήτριες του WNBA, διαμορφώνοντας ένα σύνολο με 149 δείγματα. Αντίστοιχα δεδομένα για συνθήκες πίεσης στο WNBA δεν καταγράφονται.

	J	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG	AH	AI	AJ		
1	NAME	Year	Total m	mat	per	cent	Age	MP	MP	PER	FG	M	FG	3P	3P	M	3P	2P	2P	eFG	FT	FT	M	FT	TRB	TRB	AST	AST	STL	STL	BLK	BLK	TOV	TOV	M	FF	FF	PTS	PTS
2	Liz Cam	2011	36	33	0.9167	19	20	0.5	4.1	0.122	0.511	0	0	0	0	4.1	0.205	0.521	0.511	3.4	0.17	0.794	4.7	0.235	0.5	0.025	0.8	0.04	0.9	0.045	2.4	0.12	2.9	0.145	11.5	0.575			
3	Liz Cam	2013	36	20	0.5556	21	25	0.625	5.3	0.1179	0.561	0	0	0	0	5.3	0.212	0.661	0.661	5.9	0.228	0.776	8.3	0.332	1.1	0.044	0.5	0.02	2.4	0.086	3.1	0.124	2.9	0.116	16.3	0.652			
4	Liz Cam	2018	36	32	0.8889	26	29.5	0.7375	8.7	0.0848	0.588	0.4	0.136	0.324	0.3	8.3	0.2949	0.611	0.602	3.9	0.197	0.738	9.7	0.3288	0.7	0.078	0.5	0.0169	1.7	0.0576	2.8	0.0949	2.8	0.0949	28.0	0.939	23.0	0.797	
5	Liz Cam	2019	36	32	0.8889	27	25.2	0.63	6.1	0.1033	0.564	0.1	0.004	0.167	0.1	6.1	0.2421	0.615	0.615	3.6	0.1429	0.748	8.2	0.3254	2.1	0.0833	0.8	0.0238	1.6	0.0636	2.3	0.0913	2.8	0.1111	15.9	0.631			
6	Liz Cam	2021	32	25	0.7813	29	23.8	0.595	5.6	0.1093	0.543	0.2	0.0084	0.357	0.2	5.4	0.2363	0.563	0.552	3.6	0.1176	0.731	8.2	0.3445	1.4	0.0546	0.9	0.0376	1.6	0.0672	1.8	0.0756	3.1	0.1261	14.2	0.5966			
7	Liz Cam	2022	36	25	0.6944	30	23.4	0.585	4.7	0.1245	0.509	0.2	0.0085	0.266	0.2	4.5	0.2009	0.623	0.617	3.5	0.1486	0.794	8.4	0.2735	2.1	0.0897	0.8	0.0256	1.6	0.0694	2.3	0.0883	3.2	0.1368	13.0	0.5568			
8	Breanna	2016	36	34	0.9444	21	34.7	0.8675	6.1	0.1422	0.457	1.3	0.0375	0.338	1.3	6.8	0.1758	0.508	0.507	4.7	0.1394	0.833	9.3	0.268	3.4	0.098	1.2	0.0046	1.9	0.0548	2.4	0.0692	2.4	0.0692	18.3	0.5274			
9	Breanna	2017	36	33	0.9167	22	32.9	0.8225	6.7	0.1238	0.475	1.5	0.0456	0.371	1.5	6.2	0.2036	0.516	0.528	4.9	0.1489	0.787	8.7	0.2644	2.7	0.0821	1.2	0.0365	1.6	0.0480	2.4	0.0729	3.2	0.0973	19.9	0.6049			
10	Breanna	2018	36	34	0.9444	23	31.6	0.79	7.9	0.1	0.529	1.8	0.057	0.415	1.8	6.1	0.25	0.576	0.589	4.1	0.1297	0.82	8.4	0.2658	2.5	0.0791	1.4	0.0443	1.4	0.0443	1.8	0.057	2.1	0.0633	21.8	0.6939			
11	Breanna	2020	20	20	1	25	30.4	0.78	6.7	0.1134	0.451	1.8	0.0582	0.368	1.8	4.9	0.2204	0.49	0.51	4.7	0.1546	0.894	8.3	0.273	3.6	0.1184	1.7	0.0559	1.3	0.0428	2.6	0.0855	2.3	0.0757	19.7	0.648			
12	Breanna	2021	32	28	0.875	26	33.4	0.835	6.9	0.121	0.439	1.7	0.0509	0.336	1.7	5.2	0.2066	0.488	0.483	4.8	0.1437	0.847	9.6	0.2874	2.7	0.0808	1.2	0.0359	1.7	0.0539	1.8	0.0479	1.8	0.0539	20.3	0.8078			
13	Breanna	2022	36	34	0.9444	27	30.9	0.7725	7.5	0.103	0.472	2	0.0647	0.379	2	6.6	0.2427	0.518	0.534	4.8	0.1563	0.837	7.6	0.246	2.9	0.0939	1.6	0.0518	0.9	0.0291	1.3	0.0421	2.1	0.068	21.8	0.7055			
14	Jocquel	2016	36	34	0.9444	22	14.1	0.3525	2.5	0.141	0.531	0.3	0.0213	0.333	0.3	2.2	0.1773	0.583	0.568	1.5	0.1084	0.739	3.7	0.2624	0.6	0.0436	0.8	0.0428	1.1	0.078	0.7	0.0498	2.1	0.1489	6.8	0.4823			
15	Jocquel	2017	36	34	0.9444	23	28.5	0.7125	5.3	0.1344	0.534	0.7	0.0246	0.46	0.7	4.6	0.188	0.551	0.571	4	0.1404	0.818	11.9	0.4715	1.5	0.0526	0.9	0.0316	1.5	0.0526	1.7	0.0596	3.4	0.1193	15.4	0.5404			
16	Jocquel	2018	36	34	0.9444	24	20.5	0.5125	4.4	0.1065	0.45	1.5	0.0732	0.467	1.5	2.9	0.2146	0.604	0.642	1.6	0.078	0.671	5.5	0.2683	1.7	0.0829	0.9	0.0195	1.2	0.0585	1.6	0.078	2.9	0.1415	11.8	0.7558			
17	Jocquel	2019	36	34	0.9444	25	28.8	0.72	5.1	0.1412	0.448	1.3	0.0451	0.309	1.3	3.8	0.1771	0.626	0.504	3.2	0.1111	0.818	9.7	0.3368	1.5	0.0521	1.3	0.0451	2	0.0694	1.9	0.066	2.8	0.0972	14.6	0.5069			
18	Jocquel	2021	32	27	0.8438	27	31.7	0.7925	7.1	0.1118	0.515	1.6	0.0505	0.362	1.6	5.6	0.224	0.584	0.571	3.6	0.1136	0.802	11.2	0.3533	2.8	0.0893	1.3	0.041	1.3	0.041	2.9	0.0915	3.1	0.0978	19.4	0.612			
19	Jocquel	2022	36	33	0.9167	28	26.4	0.68	5.3	0.1245	0.513	1.2	0.0456	0.369	1.2	4.1	0.2008	0.582	0.573	2.7	0.1023	0.802	8.6	0.3258	1.8	0.0682	1.1	0.0417	1.2	0.0456	2.6	0.0885	2.7	0.1023	14.6	0.553			
20	Aja Wils	2018	36	33	0.9167	21	30.6	0.765	7.4	0.1034	0.482	0	0	0	0	7.4	0.2418	0.462	0.462	5.8	0.1895	0.774	8	0.2614	2.2	0.0719	0.8	0.0261	1.7	0.0566	1.4	0.0458	2.1	0.0686	20.7	0.765			
21	Aja Wils	2019	36	28	0.7722	22	28.5	0.725	6.1	0.1168	0.479	0	0	0	0	6.1	0.214	0.46	0.479	4.4	0.1544	0.792	8.5	0.2281	1.8	0.0632	0.5	0.0175	1.7	0.0586	2.2	0.0772	2	0.0702	16.5	0.5789			
22	Aja Wils	2020	20	20	1	23	31.7	0.7925	7.5	0.1057	0.48	0	0	0	0	7.5	0.2368	0.48	0.48	5.4	0.1703	0.781	8.5	0.2281	2	0.0631	1.2	0.0379	2	0.0631	1.8	0.0505	2.2	0.0694	20.5	0.467			
23	Aja Wils	2021	32	32	1	24	31.9	0.7975	6.5	0.1227	0.444	0	0	1.000	0	6.4	0.2038	0.443	0.445	5.3	0.1681	0.876	9.3	0.2915	3.1	0.0972	0.9	0.0282	1.3	0.0408	1.4	0.0439	1.5	0.047	18.3	0.6737			
24	Aja Wils	2022	36	36	1	25	30	0.75	7.2	0.1042	0.501	0.9	0.03	0.373	0.9	6.4	0.24	0.525	0.531	4.2	0.14	0.813	9.4	0.3133	2.1	0.07	1.4	0.0467	1.9	0.0633	1.7	0.0567	2.1	0.07	19.5	0.65			
25	Diana Ti	2004	36	34	0.9444	22	33.2	0.83	6.1	0.1361	0.416	1.8	0.0542	0.33	1.8	4.3	0.1837	0.467	0.477	2.9	0.0873	0.76	4.4	0.1325	3.9	0.1175	1.3	0.0392	0.7	0.0211	2.6	0.0783	3.4	0.1024	17	0.512			
26	Diana Ti	2005	36	33	0.9167	23	33	0.825	5.3	0.1557	0.41	1.7	0.0515	0.313	1.7	3.6	0.1606	0.48	0.475	3.7	0.1121	0.801	4.2	0.1273	4.5	0.1364	1.2	0.0364	0.8	0.0242	3.4	0.103	3.4	0.103	16	0.4848			
27	Diana Ti	2006	36	34	0.9444	24	33.9	0.8475	8.8	0.0983	0.462	3.6	0.062	0.397	3.6	5.2	0.2596	0.499	0.543	4.2	0.1239	0.781	3.6	0.1052	4.1	0.1209	1.2	0.0354	0.8	0.0236	2.3	0.0878	2.9	0.0855	25.3	0.7463			
28	Diana Ti	2007	36	32	0.8889	25	32	0.8	6.4	0.125	0.44	3	0.0938	0.367	3	5	0.2	0.531	0.542	3.3	0.1031	0.835	4.2	0.1913	4.3	0.1344	1.4	0.0438	1.1	0.0344	2.6	0.0813	3.3	0.1031	19.2	0.6			
29	Diana Ti	2008	36	34	0.9444	26	31.9	0.7975	7.6	0.1049	0.446	2.6	0.0815	0.36	2.6	5	0.2382	0.509	0.522	6.3	0.1975	0.87	5.1	0.1999	3.6	0.1129	1.4	0.0439	1.4	0.0439	2.4	0.0752	3.7	0.116	24.1	0.7655			
30	Diana Ti	2009	36	31	0.8811	27	31.5	0.7875	6.6	0.1512	0.461	2.5	0.0794	0.367	2.5	3.9	0.2083	0.504	0.552	4.9	0.1566	0.894	5.7	0.181	3.6	0.1111	1.2	0.0381	1.4	0.0444	2.6	0.0825	3.1	0.0984	20.4	0.6476			
31	Diana Ti	2010	36	31	0.8811	28	32.2	0.805	6.8	0.1184	0.427	2.6	0.0807	0.374	2.6	4.3	0.2112	0.466	0.507	6.4	0.1988	0.912	4.3	0.1335	4.7	0.146	1.2	0.0373	0.6	0.0186	3.5	0.1087	3.5	0.1087	22.6	0.7019			
32	Diana Ti	2011	36	32	0.8889	29	30.2	0.755	6.5	0.1162	0.449	2.5	0.0828	0.395	2.5	4	0.2152	0.492	0.537	6.1	0.202	0.903	3.2	0.106	3.6	0.1152	0.8	0.0265	0.6	0.0189	3	0.0953	3.5	0.1159	21.6	0.7152			
33	Diana Ti	2012	36	8	0.2222	30	20.8	0.52	4.3	0.1209	0.436	2.1	0.101	0.395	2.1	2.1	0.2067	0.486	0.545	3.4	0.1635	0.9	1.6	0.0769	2.3	0.1106	0.5	0.024	0.5	0.024	1.8	0.0865	2	0.0962	14	0.6731			
34	Diana Ti	2013	36	32	0.8889	31	32.3	0.8075	6.3	0.1282	0.466	2.2	0.0881	0.347	2.2	4.1	0.195	0.546	0.534	5.7	0.1765	0.854	4.2	0.13	6.2	0.192	0.7	0.0217	0.5	0.0155	3.6	0.1115	3.2	0.0981	20.3	0.6385			
35	Diana Ti	2014	36	33	0.9167	32	30.8	0.77	5.2	0.1481	0.454	1.9	0.0817	0.365	1.9	3.3	0.1888	0.527	0.536	4	0.1289	0.874	3.8	0.1324	5.6	0.1818	0.7	0.0227	0.3	0.0097	2.6	0.0844	3	0.0974	18.2	0.528			
36	Diana Ti	2016	36	33	0.9167	34	29.8	0.745	5.5	0.1355	0.396	2.7	0.0908	0.35	2.7	2.8	0.1846	0.424	0.451	4.2	0.1409	0.909	3	0.1007															

Η επιλογή αυτών των συνόλων δεδομένων και η παρουσίαση των αντιπροσωπευτικών αθλητών εξασφαλίζει μια ικανοποιητική αναπαράσταση της απόδοσης των αθλητών και αθλητριών του NBA και WNBA αντίστοιχα, βελτιώνοντας την ακρίβεια και την αξιοπιστία των αποτελεσμάτων που παρουσιάζονται σε αυτήν τη μελέτη.

3.3.1. Προεπεξεργασία δεδομένων

Έπειτα τα δεδομένα συγκεντρώθηκαν σε μια ενιαία βάση δεδομένων για να είναι δυνατή η εισαγωγή τους στο πρόγραμμα. Έγινε αναγωγή των στατιστικών ανά αγωνιστικό λεπτό καθώς όπως γίνεται αντιληπτό δεν αγωνίζονται όλοι αθλητές το ίδιο κατά την διάρκεια ενός αγώνα. Λόγου χάρη, ο Μ.Ο. πόντων έγινε Μ.Ο. πόντων ανά αγωνιστικό λεπτό, πετυχαίνοντας ισότιμη μεταχείριση στο δείγμα των αθλητών που συγκεντρώθηκαν.

Τα δεδομένα έτυχαν επεξεργασίας στο Microsoft Excel για να διασφαλιστεί η συνέπεια και η ακρίβεια. Για να γίνουν τα δεδομένα κατάλληλα για ανάλυση, μετατράπηκαν σε μορφή αρχείου CSV. Στο πλαίσιο της συλλογής δεδομένων, πολλά από τα στατιστικά των αθλητών και αθλητριών προσαρμόστηκαν βάση λεπτού συμμετοχής προκειμένου να διασφαλιστεί η ίση μεταχείριση όλων των αθλητών. Η διαδικασία αυτής της κανονικοποίησης είναι κρίσιμη για την παροχή ακριβών και συγκρίσιμων στατιστικών μετρήσεων ανάμεσα σε αθλητές και αθλήτριες με διαφορετικά επίπεδα χρόνου συμμετοχής. Με την κανονικοποίηση των δεδομένων ανά λεπτό συμμετοχής, διευκολύνεται μια πιο εξειδικευμένη ανάλυση της απόδοσης του αθλητή και της αθλήτριας επιτρέποντας τον εντοπισμό προτύπων που θα ήταν δυσδιάκριτα σε περίπτωση που δεν γινόταν χρήση αυτής της μεθόδου. Συνολικά, αυτή η προσέγγιση βελτιώνει την αξιοπιστία και την εγκυρότητα των ευρημάτων που παρουσιάζονται στην παρούσα μελέτη.

3.4. Τεχνητά νευρωνικά δίκτυα που χρησιμοποιήθηκαν

Η χρήση αλγορίθμων τεχνητών νευρωνικών δικτύων (ANN) και των Δικτύων Συναρτησιακών Βάσεων (RBF) βασίστηκε στην ικανότητά τους να αναπαράγουν πολύπλοκες συσχετίσεις μεταξύ των μεταβλητών εισόδου και εξόδου, διαμορφώνοντας τα ιδιαίτερα χρήσιμα για την πρόβλεψη της απόδοσης των παικτών μπάσκετ στο NBA και WNBA.

Ειδικότερα, τα ΤΝΔ σχεδιάζονται για να μιμούνται τη συμπεριφορά του ανθρώπινου εγκεφάλου, καθιστώντας τα ικανά να μαθαίνουν από μεγάλα και πολύπλοκα σύνολα δεδομένων μέσω της διαδικασίας της δοκιμής και του σφάλματος. Επιτρέπουν τη γενίκευση μοτίβων και πρόβλεψης μελλοντικών αποτελεσμάτων βασιζόμενα σε ιστορικά δεδομένα. Τα μοντέλα ANN που χρησιμοποιήθηκαν στην παρούσα μελέτη υλοποιήθηκαν χρησιμοποιώντας βιβλιοθήκες όπως η TensorFlow και η Keras, παρέχοντας ισχυρά εργαλεία για τη δημιουργία, εκπαίδευση και αξιολόγηση νευρωνικών δικτύων.

Από την άλλη πλευρά, ο αλγόριθμος των RBF δικτύων αποτελεί μια εναλλακτική μέθοδο μηχανικής μάθησης που επιδέχεται ευρεία εφαρμογή σε προβλήματα πρόβλεψης. Συνδυάζεται ένας αριθμός RBF συναρτήσεων για την παραγωγή της εξόδου, ενώ ταυτόχρονα προσαρμόζεται το βάρος τους για κάθε ενδεχόμενη είσοδο, χρησιμοποιώντας μια συνάρτηση κατανομής «Gauss» για τον υπολογισμό του βάρους.

Σημαντικό να αναφερθεί, ότι η επιλογή των δικτύων RBF στην παρούσα έρευνα βασίστηκε στο γεγονός ότι είναι ικανά να προβλέψουν την απόδοση των αθλητών και αθλητριών με αξιοπιστία, ενώ παράλληλα αποτελούν λιγότερο περίπλοκο αλγόριθμο από άλλα μοντέλα νευρωνικών δικτύων, όπως τον αλγόριθμο ANN. Επιπλέον, επιτρέπεται η αποδοτική εκπαίδευση των αλγορίθμων και η βελτιστοποίηση των παραμέτρων τους.

Συνολικά, με την χρήση των δύο αυτών ειδών νευρωνικών δικτύων εξασφαλίστηκε ότι το μοντέλο θα είναι ικανό να προβλέψει με ακρίβεια την απόδοση των αθλητών και αθλητριών σε NBA και WNBA αντίστοιχα, παρέχοντας τη βάση για την περαιτέρω ανάλυση και εκμετάλλευση των δεδομένων για τη βελτίωση της απόδοσης τους. Ακόμα, η χρήση της PYTHON μαζί με τις βιβλιοθήκες TensorFlow και άλλες επέτρεψε την εύκολη ανάπτυξη και εκτέλεση του μοντέλου, ενώ η χρήση του Google Colaboratory για τα δίκτυα ANN και RBF και του MATLAB για το ANN¹⁷ επέτρεψε την γρήγορη εκτέλεση και την βελτιστοποίηση των παραμέτρων του μοντέλου μας.

3.5. Εργαλεία υλοποίησης

Για την ανάπτυξη του μοντέλου πρόβλεψης για αθλητές και αθλήτριες του NBA και WNBA, χρησιμοποιήθηκαν τα εξής δύο εργαλεία: Google Colaboratory (για την υλοποίηση σε PYTHON) και MATLAB. Ο κύριος λόγος απόφασης αποτελεί ότι και τα δύο εργαλεία χρησιμοποιούνται ευρέως στον τομέα των τεχνητών νευρωνικών δικτύων και της μηχανικής μάθησης.

3.5.1. Google Colaboratory

Το Google Colaboratory είναι μια πλατφόρμα βασισμένη στο «cloud» που προσφέρει ένα εύκολα προσβάσιμο περιβάλλον υπολογισμού για έργα μηχανικής μάθησης και ανάλυσης δεδομένων. Παρέχει στους χρήστες δωρεάν πρόσβαση σε υπολογιστικούς πόρους υψηλής απόδοσης. Το Google Colaboratory προσφέρει επίσης την ευκολία συνεργατικών χαρακτηριστικών, επιτρέποντας στους χρήστες να δημιουργούν και να μοιράζονται σημειωματάρια μορφής «Jupyter» που περιλαμβάνουν κώδικα, σχόλια και εικόνες. Επιπλέον, εξαλείφει την ανάγκη για ακριβό υλικό, καθιστώντας το μια οικονομική λύση για ερευνητές και φοιτητές που απαιτούν υπολογιστική ισχύ για τα έργα τους. Συνολικά, η προσβασιμότητα και η

¹⁷ ANN: Artificial Neural Networks

ευκολία χρήσης της πλατφόρμας κατατάσσουν το Google Colaboratory μια δημοφιλή επιλογή για άτομα και ομάδες που εργάζονται σε εργασίες μηχανικής μάθησης και ανάλυσης δεδομένων. (Google Colab)

3.5.1.1. PYTHON

Η PYTHON (χρησιμοποιήθηκε η έκδοση 3.9.16), με την εκτενή σειρά βιβλιοθηκών και εργαλείων της, παρέχει μια ευέλικτη και ισχυρή πλατφόρμα για εφαρμογές μηχανικής μάθησης. Ειδικότερα, χρησιμοποιήθηκε η βιβλιοθήκη TensorFlow της PYTHON, η οποία είναι μια ανοιχτού κώδικα βιβλιοθήκη λογισμικού για δεδομένα και προγραμματισμό διαφοροποιήσιμων ροών σε μια σειρά από εργασίες, συμπεριλαμβανομένων και των νευρωνικών δικτύων. Ο κώδικας της PYTHON υλοποιήθηκε στην πλατφόρμα του Google Colaboratory, η οποία αποτελεί ένα περιβάλλον ανάπτυξης της Google το οποίο παρέχει πρόσβαση σε ισχυρούς υπολογιστικούς πόρους ενώ ταυτόχρονα επιτρέπεται η ανεμπόδιστη συνεργασία και η κοινή χρήση κώδικα.

Παράλειψη θα ήταν να μην αναφερθεί ότι ένας άλλος σημαντικός λόγος που επιλέχθηκε η PYTHON (Python) ως γλώσσα υλοποίησης είναι η διαθεσιμότητα μιας τεράστιας ποικιλίας βιβλιοθηκών που υποστηρίζουν την υλοποίηση των Νευρωνικών Δικτύων επιτρέποντας στον προγραμματιστή να επικεντρωθεί στην ανάπτυξη του μοντέλου αντί να ανακαλύπτει και να υλοποιεί βασικές λειτουργίες από την αρχή. Οι βιβλιοθήκες αυτές μεταξύ άλλων περιλαμβάνουν το TensorFlow (Tensorflow), το Keras και το PyTorch. Τέλος, οι βιβλιοθήκες, που αναφέρθηκαν όπως η TensorFlow, επιτρέπουν την εύκολη υλοποίηση των αλγορίθμων μηχανικής μάθησης.

3.5.1.2. Βιβλιοθήκη Tensorflow

Έγινε χρήση της βιβλιοθήκης TensorFlow (χρησιμοποιήθηκε η έκδοση 2.12.0) για την υλοποίηση των αλγορίθμων των ANN και του RBF, λόγω των πολλαπλών πλεονεκτημάτων που προσφέρει. Καταρχάς, η βιβλιοθήκη TensorFlow αποτελεί μια από τις πλέον διαδεδομένες βιβλιοθήκες που χρησιμοποιούνται για την εκπαίδευση των ANN, παρέχοντας πληθώρα πόρων και εργαλείων για τη βελτιστοποίηση των αλγορίθμων. Επιπλέον, η TensorFlow αποδίδει εξαιρετικά στην εκτέλεση του κώδικα της, εξασφαλίζοντας με αυτόν τον τρόπο ότι η εκπαίδευση του προγράμματος μπορεί να εκτελεστεί σε σύντομο χρονικό διάστημα. Επιπλέον, η TensorFlow επιτρέπει στους χρήστες να εκτελέσουν τον κώδικά τους σε διάφορες πλατφόρμες, όπως στο Google Colaboratory, προσφέροντας μεγαλύτερη ευελιξία στη διαχείριση του κώδικα. (Tensorflow)

3.5.2. MATLAB

Η MATLAB (Matlab, 2023) είναι ένα ευρέως χρησιμοποιούμενο εργαλείο στον τομέα της έρευνας των τεχνητών νευρωνικών δικτύων. Όταν επιλέγεται μια γλώσσα προγραμματισμού για χρήση στην έρευνα των ΤΝΔ, λαμβάνονται υπόψιν πολλοί παράγοντες όπως η ευκολία χρήσης, η διαθεσιμότητα βιβλιοθηκών, η υπολογιστική απόδοση και η λειτουργικότητα. Στην παρούσα εργασία, η MATLAB επιλέχθηκε ως εργαλείο υλοποίησης των ΤΝΔ λόγω της πληθώρας πλεονεκτημάτων που προσφέρει.

Γενικώς, ένα από τα κύρια πλεονεκτήματα της χρήσης της MATLAB αποτελεί η φιλική προς τον χρήστη διεπαφή και η πληθώρα ενσωματωμένων συναρτήσεων και εργαλείων που την καθιστούν ιδανική επιλογή για έρευνα που αφορά μαθηματική και υπολογιστική μοντελοποίηση.

Επιπλέον, η MATLAB παρέχει εκτενή υποστήριξη για την έρευνα στα ΤΝΔ, μέσω του «Neural Network Toolbox» που προσφέρει διάφορες λειτουργίες για τον σχεδιασμό, την εκπαίδευση και τον έλεγχο νευρωνικών δικτύων. Το συγκεκριμένο εργαλείο περιλαμβάνει επίσης διάφορα εργαλεία οπτικοποίησης επιτρέποντας την εύκολη ανάλυση και ερμηνεία των αποτελεσμάτων. Όλα τα παραπάνω συμβάλλουν στην σχεδίαση, εκπαίδευση και έλεγχο των νευρωνικών δικτύων και ανάλυση των αποτελεσμάτων τους. Η υψηλή απόδοση που προσφέρει η MATLAB είναι ιδιαίτερα χρήσιμη στην έρευνα των ΤΝΔ, όπου συνήθως απαιτείται η εργασία με μεγάλα σύνολα δεδομένων και πολύπλοκων ΤΝΔ.

Επιπλέον, η ευρεία επιτυχία της επίσης διασφαλίζει την ύπαρξη πολλών διαδικτυακών κοινοτήτων, εκπαιδευτικά υλικά και παραδείγματα διαθέσιμα στους ερευνητές. Οι ερευνητές μπορούν να χρησιμοποιήσουν αυτούς τους πόρους για την καλύτερη κατανόηση της γλώσσας και την υλοποίηση των νευρωνικών δικτύων.

Συνολικά, η επιλογή της MATLAB αποδείχθηκε επιτυχής στην υλοποίηση των ΤΝΔ για την πρόβλεψη των απόδοσης των αθλητών και αθλητριών του NBA και WNBA. Η ευκολία χρήσης, η υποστήριξη του «Neural Network Toolbox», η υψηλή απόδοση και η δημοφιλία της MATLAB την καθιστούν ένα από τα κορυφαία εργαλεία για την έρευνα στα ΤΝΔ. (Matlab, 2023)

3.6. Σημαντικότεροι παράμετροι προγραμμάτων νευρωνικών δικτύων

Παράμετρος 1: Εκπαίδευση-Δοκιμή («Train – Test»)

Στη μηχανική μάθηση, είναι συνηθισμένη πρακτική να διενεργείται διαίρεση των δεδομένων σε δύο μέρη, ένα για την εκπαίδευση του μοντέλου και το άλλο για τον έλεγχο της ακρίβειάς του. Το μέρος εκπαίδευσης χρησιμοποιείται για την βελτιστοποίηση των παραμέτρων του μοντέλου ενώ το σετ δοκιμής χρησιμοποιείται για την αξιολόγηση της απόδοσης του. Με τη χρήση ενός ξεχωριστού μέρους δοκιμής, είναι δυνατόν να προσδιοριστεί πόσο καλά θα επιδοθεί το μοντέλο σε νέα, ανεξάρτητα δεδομένα. Αυτή η διαδικασία ονομάζεται διαίρεση εκπαίδευσης-δοκιμής.

Παράμετρος 2: Κρυφά Επίπεδα («Hidden layers»)

Στα νευρωνικά δίκτυα, το κρυφό επίπεδο αποτελείται από επίπεδα κόμβων μεταξύ των επιπέδων εισόδου και εξόδου. Κάθε κόμβος σε ένα κρυφό επίπεδο λαμβάνει είσοδο από το προηγούμενο επίπεδο κόμβων, εκτελεί μια υπολογιστική διαδικασία χρησιμοποιώντας βάρη και αποκλίσεις περνώντας την έξοδο στο επόμενο επίπεδο. Τα κρυφά επίπεδα επιτρέπουν στα νευρωνικά δίκτυα να μάθουν πολύπλοκες σχέσεις μεταξύ εισόδων και εξόδων εισάγοντας μη γραμμικούς μετασχηματισμούς.

Παράμετρος 3: Εποχές («Epochs»)


Οι εποχές αναφέρονται στον αριθμό των επαναλήψεων όπου το σύνολο εκπαίδευσης περνά διαμέσου του νευρωνικού δικτύου κατά τη διάρκεια της εκπαίδευσης. Κάθε «epoch» αποτελείται από πολλαπλές επαναλήψεις, όπου το μοντέλο ενημερώνει τα βάρη και τις τιμές κατωφλίων του για να ελαχιστοποιήσει την απώλεια εκπαίδευσης («train loss»). Ο αριθμός των «epochs» που απαιτούνται για την εκπαίδευση ενός μοντέλου εξαρτάται από την πολυπλοκότητα του προβλήματος και το μέγεθος του συνόλου δεδομένων.

Παράμετρος 4: Συναρτήσεις ενεργοποίησης («Activation functions»)

Οι συναρτήσεις ενεργοποίησης χρησιμοποιούνται στα νευρωνικά δίκτυα για την εισαγωγή της μη γραμμικότητας στην έξοδο ενός κόμβου. Υπάρχουν διάφορες συναρτήσεις ενεργοποίησης διαθέσιμες, συμπεριλαμβανομένων των δημοφιλών συναρτήσεων «Relu» («Rectified Linear Unit») και «Sigmoid», «Tanh» (υπερβολικής εφαστομένης). Πιο συγκεκριμένα:

Συνάρτηση «Relu»


Η «Relu» είναι μια διαδεδομένη συνάρτηση ενεργοποίησης στον τομέα της βαθιάς μάθησης («deep learning»). Παρουσιάστηκε από τον Hahnloser το 2000 και είναι μια μη γραμμική συνάρτηση που επιστρέφει την τιμή εισόδου σε περίπτωση που είναι θετική, διαφορετικά επιστρέφει μηδέν. Αποτελεί μία αποτελεσματική συνάρτηση με αρκετά πλεονεκτήματα έναντι άλλων συναρτήσεων ενεργοποίησης, όπως η ικανότητά της να αντιμετωπίζει το πρόβλημα της εξαφάνισης της κλίσης («gradient descent») και να επιταχύνει την εκπαίδευση βαθιών νευρωνικών δικτύων. Επιπλέον, η συνάρτηση «Relu» έχει αποδειχθεί ότι ξεπερνά άλλες δημοφιλείς συναρτήσεις ενεργοποίησης, όπως οι συναρτήσεις σιγμοειδούς «sigmoid» και υπερβολικής εφαστομένης, όσον αφορά την ταχύτητα σύγκλισης και την απόδοση γενίκευσης. Έχουν επίσης προταθεί αρκετές παραλλαγές της συνάρτησης «Relu» προκειμένου να αντιμετωπιστούν οι περιορισμοί της, όπως η «leaky Relu», η οποία εισάγει μια μικρή αρνητική κλίση για αρνητικές τιμές εισόδου προκειμένου να αποφευχθεί το πρόβλημα του «dying Relu». Παρόλο που είναι μια απλή συνάρτηση, η «Relu» παραμένει ένα ισχυρό εργαλείο στη βαθιά μάθηση και χρησιμοποιείται συχνά ως η προεπιλεγμένη συνάρτηση ενεργοποίησης σε πολλές αρχιτεκτονικές. (Hahnloser, 2000)



Εικόνα 7: Relu figure (Γραφική παράσταση Relu)

Συνάρτηση «sigmoid»


Η συνάρτηση «sigmoid» είναι μια δημοφιλής μη γραμμική συνάρτηση ενεργοποίησης που χρησιμοποιείται στην βαθιά εκμάθηση («Deep Learning»). Η συνάρτηση αντιστοιχίζει οποιαδήποτε είσοδο σε μια τιμή μεταξύ 0 και 1, καθιστώντας την ιδιαίτερα χρήσιμη σε προβλήματα δυαδικής ταξινόμησης. Η συνάρτηση «sigmoid» εισήχθη για πρώτη φορά στη δεκαετία του 50 από ψυχολόγους που ενδιαφέρονταν να μοντελοποιήσουν διαδικασίες λήψης αποφάσεων. Η δυνατότητα της συνάρτησης να μοντελοποιήσει τον τρόπο με τον οποίο ο εγκέφαλος επεξεργάζεται πληροφορίες την καθιστά μια ελκυστική επιλογή για υλοποίηση σε τεχνητά νευρωνικά δίκτυα. Παρόλη τη δημοφιλία της, η συνάρτηση «sigmoid» έχει αρκετούς περιορισμούς, όπως η τάση των κλίσεων («gradient») της να εξαφανίζονται ή να κορεστούν όταν η είσοδος είναι πολύ μικρή ή πολύ μεγάλη. Ενδέχεται να οδηγήσει σε αργή σύγκλιση κατά τη διάρκεια της εκπαίδευσης περιορίζοντας το δίκτυο να μάθει πολύπλοκες αναπαραστάσεις. Επιπλέον, η συνάρτηση «sigmoid» δεν είναι «zero centered» (είτε είναι θετική είτε αρνητική), προκαλώντας παραμόρφωση του διανύσματος εισόδου και έτσι μπορεί να οδηγήσει τα βάρη του δικτύου να παραμορφωθούν κατά τη διάρκεια της εκπαίδευσης. Παρόλα αυτά, η συνάρτηση «sigmoid» παραμένει ένα χρήσιμο εργαλείο στην βαθιά εκμάθηση («Deep Learning»), ιδίως σε προβλήματα όπου η έξοδος είναι δυαδική ή πιθανοτικής φύσης (Bengio Y. S., 1994).



Εικόνα 8: Sigmoid figure (Γραφική παράσταση Sigmoid)

Συνάρτηση εκθετικής γραμμικής μονάδας («elu»)

Η συνάρτηση εκθετικής γραμμικής μονάδας («exponential linear unit») ή αλλιώς «ELU» είναι μια μη γραμμική συνάρτηση ενεργοποίησης που είναι ιδιαίτερα δημοφιλής στην βαθιά εκμάθηση λόγω της ικανότητάς της να ξεπερνά μερικούς από τους περιορισμούς της ευρέως χρησιμοποιούμενης συνάρτησης «Relu». Εισήχθη από τον Clevert το 2015, η συνάρτηση ELU ορίζεται ως η εκθετική της τιμής της εισόδου μείον ένα αν η είσοδος είναι αρνητική, αλλιώς δίνει την είσοδο σαν έξοδο. Η συνάρτηση ELU χαρακτηρίζεται από αρκετά πλεονεκτήματα σε σχέση με τη συνάρτηση «Relu», όπως η ικανότητά της να αποτρέπει το πρόβλημα της «dying Relu» επιτρέποντας αρνητικές τιμές, καθώς και η βελτίωση της απόδοσης γενίκευσης. Επιπλέον, η συνάρτηση «ELU» έχει αποδειχθεί ότι υπερέρχει άλλων δημοφιλών συναρτήσεων ενεργοποίησης, όπως οι συναρτήσεις «sigmoid» και υπερβολικής εφασπτομένης, όσον αφορά την ακρίβεια και την ταχύτητα σύγκλισης. Ωστόσο, η συνάρτηση ELU μπορεί να είναι υπολογιστικά ακριβή λόγω της χρήσης εκθετικών συναρτήσεων και μπορεί να μην είναι πάντα η καλύτερη επιλογή για κάθε πρόβλημα. Παρά τα περιορισμούς της, η συνάρτηση «ELU» παραμένει ένα ισχυρό εργαλείο στην βαθιά εκμάθηση και χρησιμοποιείται συχνά ως εναλλακτική στη συνάρτηση «Relu» σε πολλές αρχιτεκτονικές. (Clevert, 2016).




Εικόνα 9: Elu figure (Γραφική παράσταση Elu)

Συνάρτηση «softmax»

Η συνάρτηση «softmax» αποτελεί μια ευρέως χρησιμοποιούμενη συνάρτηση ενεργοποίησης στον τομέα της βαθιάς εκμάθησης, ιδίως σε προβλήματα ταξινόμησης. Η συνάρτηση χρησιμοποιείται για τον μετασχηματισμό της εξόδου ενός νευρωνικού δικτύου σε μια κατανομή πιθανοτήτων πολλών κατηγοριών. Η συνάρτηση «softmax» εισήχθη πρώτη φορά στη δεκαετία του 50 από στατιστικούς και έκτοτε έχει υιοθετηθεί στον τομέα της μηχανικής μάθησης. Η συνάρτηση λαμβάνει ως είσοδο ένα διάνυσμα πραγματικών αριθμών κανονικοποιώντας τα σε μια κατανομή πιθανοτήτων. Τα πλεονεκτήματα σε σχέση με άλλες συναρτήσεις ενεργοποίησης, είναι ότι παράγει ερμηνεύσιμα αποτελέσματα και χρησιμοποιείται στους αλγόριθμους βελτιστοποίησης. Επιπλέον, η συνάρτηση «softmax» μπορεί να επεκταθεί για την αντιμετώπιση πιο περίπλοκων κατανομών εξόδου. Ωστόσο,

ενδέχεται να αντιμετωπίσει προβλήματα αστάθειας στους υπολογισμούς όταν οι τιμές των εισόδων είναι πολύ μεγάλες ή πολύ μικρές. Αρκετές παραλλαγές της συνάρτησης έχουν προταθεί για την αντιμετώπιση του συγκεκριμένου προβλήματος. Συνολικά, η συνάρτηση «softmax» παραμένει ένα πολύτιμο εργαλείο στον τομέα της βαθιάς εκμάθησης και χρησιμοποιείται συχνά σε αρχιτεκτονικές νευρωνικών δικτύων για προβλήματα κατηγοριοποίησης. (Ioffe, 2015)




Εικόνα 10: Softmax figure (Γραφική παράσταση Softmax)

Συνάρτηση «softsign»

Η συνάρτηση «softsign» είναι μια μη γραμμική συνάρτηση ενεργοποίησης που χρησιμοποιείται συχνά σε αρχιτεκτονικές νευρωνικών δικτύων. Εισήχθη από τον Jean-Guillaume Fages το 1997 και αντιστοιχεί κάθε πραγματικό αριθμό σε μια τιμή ανάμεσα στο -1 και 1. Ορίζεται ως ο αριθμός εισόδου διαιρούμενος με το απόλυτο της τιμής της εισόδου συν ένα. Η συνάρτηση «softsign» είναι παρόμοια με τη συνάρτηση υπερβολικής εφαπτομένης («tanh») στη μορφή, αλλά είναι πιο αποδοτική υπολογιστικά λόγω της απουσίας πράξεων εκθετικών συναρτήσεων.

Η συνάρτηση «softsign» έχει αρκετά πλεονεκτήματα σε σχέση με άλλες συναρτήσεις ενεργοποίησης, όπως η δυναμική εύρεση εκθέτη και το ότι είναι διαφορίσιμη. Επιπλέον, έχει αποδειχθεί ότι βελτιώνει την απόδοση των νευρωνικών δικτύων σε ορισμένες εφαρμογές, όπως η κατηγοριοποίηση εικόνων και η επεξεργασία φυσικής γλώσσας. Ωστόσο, η συνάρτηση «softsign» ενδέχεται να μην είναι η καλύτερη επιλογή για όλα τα προβλήματα. Χαρακτηρίζεται από ορισμένα μειονεκτήματα, όπως η πρόκληση της εκπαίδευσης του δικτύου σε μεγάλα δεδομένα, καθώς η μεταβλητή μεταβάλλεται γραμμικά με την είσοδο, επιβάλλοντας περιορισμούς στην απόδοση του μοντέλου. Επιπλέον, η «softsign» μπορεί να προκαλέσει αργή σύγκλιση σε μερικές περιπτώσεις λόγω της καμπυλότητάς της σε σύγκριση με άλλες συναρτήσεις ενεργοποίησης. Παρόλα αυτά, παραμένει ένα εξαιρετικό εργαλείο για πολλά προβλήματα μηχανικής μάθησης και χρησιμοποιείται συχνά ως εναλλακτική στις πιο κλασικές συναρτήσεις ενεργοποίησης, όπως είναι η σιγμοειδής («sigmoid») και η υπερβολική εφαπτομένη («tanh»). (LeCun Y. B., 1998)



Εικόνα 11: Softsign (Γραφική παράσταση Softsign)

Συναρτήσεις βελτιστοποίησης - απώλειας (Optimizer - Loss function)

Ο βελτιστοποιητής είναι μια συνάρτηση που ενημερώνει τα βάρη και τις παραμέτρους του νευρωνικού δικτύου κατά τη διάρκεια της εκπαίδευσης προκειμένου να ελαχιστοποιήσει την συνάρτηση απώλειας. Η συνάρτηση απώλειας μετρά τη διαφορά ανάμεσα στην προβλεπόμενη έξοδο και την πραγματική έξοδο. Υπάρχουν διάφοροι αλγόριθμοι βελτιστοποίησης διαθέσιμοι, συμπεριλαμβανομένων του «stochastic gradient descent» («SGD») και του «Adam». Η επιλογή του βελτιστοποιητή και της συνάρτησης απώλειας εξαρτάται από το πρόβλημα που αντιμετωπίζεται και την αρχιτεκτονική του νευρωνικού δικτύου. Συνολικά, ο βελτιωτής αποτελεί ένα κρίσιμο εργαλείο για την επίτευξη υψηλής απόδοσης στα μοντέλα μάθησης και τη βελτίωση της δυνατότητας τους για γενίκευση σε νέα δεδομένα. Αναλυτικότερα,

Αλγόριθμος βελτιστοποίησης SGD

Η SGD (Stochastic Gradient Descent) είναι ένας δημοφιλής αλγόριθμος βελτιστοποίησης στην μηχανική μάθηση, που χρησιμοποιείται για την ελαχιστοποίηση της συνάρτησης αντικειμένου («objective function») ενός μοντέλου με τη διαδοχική ενημέρωση των παραμέτρων του μοντέλου με βάση την κλίση της συνάρτησης αντικειμένου. Εισήχθη στη δεκαετία του 60 από τους Robbins και Monro, και αποτελεί μια παραλλαγή του αλγορίθμου καθόδου κλίσης (gradient descent) που επιλέγει τυχαία ένα υποσύνολο των δεδομένων εκπαίδευσης, το οποίο ονομάζεται αλλιώς και «mini-batch», για την εκτίμηση της κλίσης σε κάθε επανάληψη. Επιτρέπει την ταχύτερη σύγκλιση και καλύτερη γενίκευση από την κλασική μέθοδο κλίσης («gradient descent»), η οποία χρησιμοποιεί ολόκληρο το σετ εκπαίδευσης για την εκτίμηση της κλίσης. Η SGD έχει αρκετά πλεονεκτήματα σε σχέση με άλλους αλγορίθμους βελτιστοποίησης, όπως η δυνατότητά της να χειριστεί μεγάλα σετ δεδομένων, η απλότητά της, και η ευελιξία της στην επιλογή των παραμέτρων μάθησης, όπως ο ρυθμός μάθησης και η ορμή. Ωστόσο, η μέθοδος ενδέχεται να χαρακτηριστεί από υψηλή διακύμανση λόγω της στοχαστικότητας που εισάγεται από τη δειγματοληψία των mini-batches, και έχουν προταθεί διάφορες παραλλαγές της, όπως οι μέθοδοι «momentum» και «adaptive learning rate», για την αντιμετώπιση αυτού του προβλήματος. Συνολικά, η SGD παραμένει μια ισχυρή και ευρέως χρησιμοποιούμενη μέθοδος βελτιστοποίησης στον χώρο της μηχανικής μάθησης. (Robbins, 1951)

Αλγόριθμος βελτιστοποίησης Adam

Ο Adaptive Moment Estimation («Adam») είναι ένας αλγόριθμος βελτιστοποίησης που χρησιμοποιείται συνήθως στον τομέα της βαθιάς μάθησης για την ενημέρωση παραμέτρων ενός μοντέλου με βάση την κλίση της συνάρτησης απώλειας. Εισήχθη το 2014 από τους Diederik P. Kingma και Jimmy Lei Ba, και είναι μια παραλλαγή του αλγορίθμου στοχαστικής κατάβασης κλίσης («SGD») που χρησιμοποιεί προσαρμοζόμενους ρυθμούς μάθησης για κάθε παράμετρο, βασισμένους σε εκτιμήσεις των πρώτων και δεύτερων στιγμιότυπων της κλίσης. Συγκεκριμένα, ο «Adam» υπολογίζει έναν εκθετικά κινητό μέσο όρο κλίσεων και των τετραγώνων των κλίσεων, τα οποία χρησιμοποιούνται για την ενημέρωση του ρυθμού μάθησης για κάθε παράμετρο, επιτρέποντας στον «Adam» να συγκλίνει πιο γρήγορα από τους παραδοσιακούς αλγόριθμους βελτιστοποίησης, όπως «SGD» και «Adagrad», ενώ παράλληλα είναι πιο ανθεκτικός σε θορυβώδεις ή αραιές κλίσεις. Επιπλέον, ο «Adam» περιλαμβάνει όρους διόρθωσης βαρών που ρυθμίζουν τις εκτιμήσεις των πρώτων και δεύτερων στιγμών, με σκοπό τη μείωση της επίδρασης αρχικών παραμέτρων. Ωστόσο, ο «Adam» μπορεί να είναι ευαίσθητος στην επιλογή των υπερ-παραμέτρων του, όπως του ρυθμού μάθησης και της εκπέμπουσας παραμέτρου βήματος. Συνεπώς, οι επιλογές αυτές θα πρέπει να εξετάζονται με προσοχή για κάθε συγκεκριμένο πρόβλημα. Παρόλα αυτά, ο «Adam» παραμένει μια αποτελεσματική και δημοφιλής επιλογή για τη βελτιστοποίηση μοντέλων σε βαθιά μάθηση επιτυγχάνοντας εντυπωσιακά αποτελέσματα σε πολλές εφαρμογές. (Kingma D. P., 2014)

Αλγόριθμος βελτιστοποίησης Rmsprop

Ο Rmsprop («Root Mean Square Propagation») είναι ένας αλγόριθμος βελτιστοποίησης που χρησιμοποιείται συχνά στην μηχανική μάθηση για την προσαρμογή του ρυθμού εκπαίδευσης κατά τη διάρκεια της φάσης εκπαίδευσης. Ο αλγόριθμος παρουσιάστηκε από τον Geoffrey Hinton σε διάλεξη το 2012 και δημοσιεύθηκε σε τεχνική αναφορά το 2013 (Hinton G. , 2013). Ο «Rmsprop» αποτελεί έναν προσαρμοστικό αλγόριθμο ρυθμού μάθησης που υπολογίζει έναν μεταβλητό μέσο των τετραγώνων των κλίσεων για να κλιμακώσει τον ρυθμό μάθησης κάθε παραμέτρου. Συγκεκριμένα, ο «Rmsprop» διαιρεί τον ρυθμό μάθησης με τον τετραγωνικό μέσο όρο («RMS») των πρόσφατων κλίσεων για κάθε παράμετρο. Αυτή η τεχνική επιτρέπει στον Rmsprop να προσαρμόζει τον ρυθμό μάθησης για κάθε παράμετρο και να αποφεύγει την αργή σύγκλιση λόγω των ανακλάσεων ή του θορύβου των κλίσεων. Ο «Rmsprop» έχει αποδειχθεί αποτελεσματικός σε μια ποικιλία από εργασίες μηχανικής μάθησης, συμπεριλαμβανομένης της αναγνώρισης εικόνας και της φυσικής γλώσσας. Επιπλέον, η μέθοδος «Rmsprop» είναι απλή στην υλοποίηση και επιτρέπει στον χρήστη να επιλέξει μια αρχική τιμή της μεταβλητής μείωσης του ρυθμού μάθησης και έναν παράγοντα εκπαίδευσης, που επηρεάζει τη σταθερότητα του αλγορίθμου. Ωστόσο, παρόλο που ο «Rmsprop» έχει αποδειχθεί αποτελεσματικός σε πολλές εργασίες, η απόδοσή του εξαρτάται από τη σύνθεση των υπερ-παραμέτρων του αλγορίθμου και τις συγκεκριμένες ιδιότητες των δεδομένων εκπαίδευσης. Παρ' όλα αυτά, ο «Rmsprop» εξακολουθεί να είναι μια δημοφιλής μέθοδος βελτιστοποίησης που χρησιμοποιείται ευρέως σε πολλές εφαρμογές μηχανικής μάθησης. (Hinton G. , 2013)

Αλγόριθμος βελτιστοποίησης Adagrad

Ο αλγόριθμος Adagrad (Προσαρμοστικής Κλίσης) χρησιμοποιείται στη μηχανική μάθηση για να προσαρμόσει το ρυθμό εκμάθησης κατά τη διάρκεια της εκπαίδευσης. Παρουσιάστηκε από τους Duchi το 2011 και ο ρυθμός εκμάθησης για κάθε παράμετρο βάσει της συχνότητας των ενημερώσεών της. Συγκεκριμένα, ο «Adagrad» διαιρεί τον ρυθμό εκμάθησης με τη ρίζα του μέσου τετραγωνικού (RMS) των κλίσεων για κάθε παράμετρο. Αυτή η τεχνική επιτρέπει στον «Adagrad» να προσαρμόζει δυναμικά το ρυθμό εκμάθησης για κάθε παράμετρο και να δίνει προτεραιότητα στις ενημερώσεις των χαρακτηριστικών που εμφανίζονται συχνότερα. Ο «Adagrad» είναι ιδιαίτερα χρήσιμος για τα αραιά σύνολα δεδομένων ή προβλήματα με θορυβώδεις κλίσεις, όπως η επεξεργασία φυσικής γλώσσας και οι συστάσεις. Ωστόσο, έχειδειχθεί ότι ο «Adagrad» δυσκολεύεται να αντιμετωπίσει βαθιά νευρωνικά δίκτυα, καθώς η συσσώρευση των τετραγωνικών κλίσεων με τον χρόνο μπορεί να οδηγήσει σε υπερβολικά μικρό ρυθμό μάθησης. Προκειμένου να αντιμετωπιστεί το συγκεκριμένο πρόβλημα έχουν προταθεί αρκετές παραλλαγές του «Adagrad». Μια από αυτές τις παραλλαγές είναι ο «Adam» και ο «Adadelta», όπου αντικαθιστά την σταθερά εκμάθησης με μια προσαρμοστική σταθερά, που διατηρεί μια ισορροπία μεταξύ του ρυθμού μάθησης και του μεγέθους της ενημέρωσης των παραμέτρων. (Duchi, 2011)

4. Περιγραφή Προγράμματος

Τα τρία προγράμματα που θα αναλυθούν παρακάτω εφαρμόζονται στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης και πιο συγκεκριμένα, τα δύο αφορούν το πρωτάθλημα των ανδρών (NBA) και το τελευταίο το πρωτάθλημα των γυναικών (WNBA). Υπάρχουν πειράματα με εισόδους διαφορετικών στατιστικών στοιχείων από την βάση δεδομένων που έχει δημιουργηθεί με βάση επίσημα στατιστικά στοιχεία του εκάστοτε πρωταθλήματος.

4.1.1. Πρόβλεψη απόδοσης κανονικής περιόδου NBA

Το πρώτο πρόγραμμα που θα περιγραφεί αφορά στην πρόβλεψη απόδοσης καλαθοσφαιριστών στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης ανδρών ή αλλιώς NBA.

Ειδικότερα, θα αποδειχθεί ότι είναι δυνατή η πρόβλεψη απόδοσης αθλητών στον τομέα επίτευξης πόντων γνωρίζοντας κάποια συγκεκριμένα ατομικά στατιστικά όπως ηλικία, θέση, χρόνο συμμετοχής κ.α. Θα αποδειχθεί σε τρεις διαφορετικές περιπτώσεις με την βοήθεια της γλώσσας PYTHON (δύο αλγόριθμοι) και της εφαρμογής MATLAB (ένας αλγόριθμος). Σε όλες τις περιπτώσεις για καλύτερη σύγκριση θα δίνονται οι ίδιες εισοδοί και θα παίρνουμε την ίδια έξοδο για την καλύτερη σύγκριση μεταξύ των προγραμμάτων. Ως έξοδος θα δίνεται σε όλες τις περιπτώσεις ο μέσος όρος επίτευξης πόντων του εκάστοτε αθλητή.

Επιπλέον, είναι σημαντικό να σημειωθεί ότι τα πειράματα στα οποία εξετάζεται η ακρίβεια του προγράμματος δεν ανήκουν στην βάση δεδομένων προκειμένου να εξασφαλιστεί η εγκυρότητα του προγράμματος.

Τα στατιστικά αφορούν πάλι στην κανονική περίοδο του NBA. Θα αναλυθούν διαφορετικές περιπτώσεις με διαφορετικές εισόδους σε κάθε περίπτωση.

4.1.1.1. Υλοποίηση σε γλώσσα PYTHON

Το πρόγραμμα της συγκεκριμένης ενότητας αφορά την υλοποίηση του αλγορίθμου ΤΝΔ και ΣΒΑ ¹⁸σε γλώσσα προγραμματισμού PYTHON χρησιμοποιώντας την βιβλιοθήκη «Keras» της «TensorFlow». Αρχικά, εισάγονται οι απαραίτητες βιβλιοθήκες για την ορθή λειτουργία του προγράμματος όπως: «numpy, pandas, Tensorflow». Έπειτα, γίνεται ανάγνωση της βάσης δεδομένων από το πρόγραμμα και προετοιμάζεται κατάλληλα για την εκπαίδευση από τον αντίστοιχο αλγόριθμο. Ακολουθεί η δημιουργία του ΤΝΔ μέσω της βιβλιοθήκης της «TensorFlow» και αντίστοιχα η δημιουργία της συνάρτησης RBF χρησιμοποιώντας τις ανάλογες παραμέτρους που έχουν επιλεγθεί. Έπειτα το πρόγραμμα εκπαιδεύεται

¹⁸ ΣΒΑ: Συνάρτηση Βάσης Ακτίνας

με το «train set» και ελέγχεται η εγκυρότητα του από το «test set», και τέλος γίνονται κάποια πειράματα από πραγματικά στατιστικά αθλητών εκτός βάσης δεδομένων.

Αρχικά, στα παρακάτω προγράμματα θα εξεταστούν με τις ίδιες παραμέτρους για την άμεση σύγκριση των αποτελεσμάτων. Έπειτα θα μελετηθούν διαφορετικές παράμετροι, διαφορετικές εισοδοι, διαφορετικά τμήματα «test-train splits» και διαφορετικές παράμετροι όσον αφορά συναρτήσεις ενεργοποίησης, νευρώνες, κρυφά επίπεδα και επαναλήψεις.

Ειδικότερα, η μεγαλύτερη ακρίβεια που επιτεύχθηκε στις προβλέψεις ήταν 84% για τον ANN αλγόριθμο και 82% για τον RBF αλγόριθμο, ποσοστό το οποίο μας δείχνει ότι είναι δυνατή η πρόβλεψη απόδοσης αθλητών με στατιστικά που είναι διαθέσιμα στο κοινό διαμορφώνοντας μια διαφορετική οπτική πάνω στους τρόπους με τους οποίους αντιλαμβανόμαστε το άθλημα της καλαθοσφαίρισης. Όπως γίνεται αντιληπτό η εφαρμογή του συγκεκριμένου προγράμματος θα μπορούσε να έχει ανάλογη εφαρμογή και σε άλλα αθλήματα όπου καταγράφεται πληθώρα στοιχείων για την επίδοση αθλητών και αθλητριών.

4.1.1.1.1. Πειράματα μέγιστης ακρίβειας

Η μεγαλύτερη ακρίβεια όπως θα αποδειχθεί και παρακάτω επιτεύχθηκε με τις παρακάτω εισόδους:

1. θέση
2. ηλικία
3. ποσοστό αγώνων συμμετοχής
4. λεπτά συμμετοχής
5. FG%
6. eFG%
7. FT%
8. TOV

Και έξοδος:

1. M.O. πόντων

Παρακάτω φαίνονται ενδεικτικές εικόνες δομής των αλγόριθμων νευρωνικών δικτύων για τον ANN και RBF αντίστοιχα.


```

Initializing the ANN

[11] 1 ann = tf.keras.models.Sequential()

Adding the input layer

[12] 1 ann.add(tf.keras.layers.Dense(units=8, activation='relu'))

Add 1st hidden layer

[13] 1 ann.add(tf.keras.layers.Dense(units=8, activation='relu'))

Add 2nd hidden layer

[14] 1 ann.add(tf.keras.layers.Dense(units=8, activation='relu'))

Add 3rd hidden layer

[15] 1 ann.add(tf.keras.layers.Dense(units=8, activation='relu'))

Adding the output layer

[16] 1 ann.add(tf.keras.layers.Dense(units=1, activation='sigmoid'))

```

Εικόνα 12: Δομή TNA NBA

```

1 %time
2 from tensorflow.python.ops.init_ops_v2 import Initializer
3 from keras import backend as K
4 from keras.models import Sequential
5 from keras.optimizers import RMSprop
6 from keras.layers import Activation, Dense
7
8 model = Sequential()
9
10 rbf_layer = RBFLayer(8,
11                     initializer=InitCentersKMeans(X_train)
12                     betas=1.0,
13                     input_shape=((8,))
14                     )
15 model.add(rbf_layer)
16 model.add(Dense(8))
17 model.add(Dense(8))
18 model.add(Dense(8))
19 model.add(Dense(8))
20 model.add(Dense(8))
21 model.add(Dense(8))
22 model.add(Dense(8))
23 model.add(Dense(1))
24 model.add(Dense(1))
25
26 tf.keras.optimizers.RMSprop(
27     learning_rate=0.001,
28     rho=0.9,
29     momentum=0.0,
30     epsilon=1e-07,
31     centered=False,
32     name="RMSprop",
33     clipvalue=1.0
34 )
35
36 model.compile(
37     loss='mse',
38     optimizer=RMSprop()
39 )
40 model.fit(X_train, y_train, batch_size=10, epochs = 1000)

```

Εικόνα 13: Δομή RBF NBA

Παράμετροι πειραμάτων με τα καλύτερα αποτελέσματα

Αξίζει να σημειωθούν οι διάφοροι παράμετροι που αφορούν τα δεδομένα εκπαίδευσης, τα επίπεδα, τον αριθμό των επαναλήψεων καθώς και οι διάφορες συναρτήσεις και αλγόριθμοι που χρησιμοποιήθηκαν και μας έδωσαν τα καλύτερα αποτελέσματα.

Train: 80% - Test: 20%

Η επιλογή του 80% για τα δεδομένα εκπαίδευσης και 20% για τα δεδομένα ελέγχου είναι μια συνηθισμένη αναλογία για τις εργασίες μηχανικής μάθησης. Επιτρέπει στο μοντέλο να μάθει από την πλειονότητα των δεδομένων ενώ ταυτόχρονα διαθέτει αρκετά δεδομένα ελέγχου για να αξιολογήσει την απόδοσή του. Επιπλέον, το δείγμα στην βάση δεδομένων έχει ικανοποιητικό μέγεθος για την ικανοποιητική αποτελεσματικότητα του ΤΝΔ.

Κρυφά επίπεδα («hidden layers»)

Η επιλογή τριών κρυφών επιπέδων είναι μια συνήθης πρακτική για τα νευρωνικά δίκτυα. Η ύπαρξη πολλών κρυφών επιπέδων επιτρέπει στο μοντέλο να μάθει πιο περίπλοκες σχέσεις ανάμεσα στην είσοδο και την έξοδο. Παράλληλα, η επιλογή περισσότερων κρυφών επιπέδων δεν βελτιώνει την ακρίβεια του δικτύου συνεπώς ο αριθμός τρία κρίθηκε ιδανική επιλογή.

Επαναλήψεις («epochs»)

Επιλέχθηκαν 1000 εποχές, καθώς αποδείχθηκε ότι είναι ένας κατάλληλος αριθμός επαναλήψεων για να επιτευχθεί μια καλή ισορροπία μεταξύ της ακρίβειας του μοντέλου και της υπερ-εκπαίδευσης.

Συναρτήσεις ενεργοποίησης («activation functions»)

Στο ANN «Relu» στο πρώτο επίπεδο και στα κρυφά επίπεδα, Sigmoid στο επίπεδο εξόδου.

Η επιλογή των συναρτήσεων ενεργοποίησης «Relu» και «Sigmoid» βασίζεται στην αποτελεσματικότητά τους σε προηγούμενες μελέτες για παρόμοιες εργασίες. Η «Relu» είναι γνωστή για την ικανότητά της να χειρίζεται το πρόβλημα της εξαφανιζόμενης κλίσης και χρησιμοποιείται συχνά σε νευρωνικά δίκτυα βαθιάς εκμάθησης. Η «Sigmoid» χρησιμοποιείται στο επίπεδο εξόδου για την κανονικοποίηση της εξόδου μεταξύ 0 και 1.

Συνάρτηση ενεργοποίησης στο δίκτυο Συνάρτησης Βάσης ακτίνας

Η Συνάρτηση Βάσης Ακτίνας (RBF) είναι ένας τύπος τεχνητού νευρωνικού δικτύου που χρησιμοποιείται εκτενώς σε διάφορες εφαρμογές, όπως η προσέγγιση συναρτήσεων, η ταξινόμηση και η ομαδοποίηση. Ένα από τα χαρακτηριστικά της ΣΒΑ είναι ότι δεν απαιτεί μια συνάρτηση ενεργοποίησης. Σε αντίθεση με άλλες αρχιτεκτονικές νευρωνικών δικτύων που χρησιμοποιούν συναρτήσεις ενεργοποίησης για να εισαγάγουν την μη γραμμικότητα στο δίκτυο, η ΣΒΑ βασίζεται στη μέτρηση απόστασης μεταξύ της εισόδου και του κέντρου της συνάρτησης βάσης για να προσδιορίσει την έξοδο. Αυτή η μοναδική ιδιότητα της ΣΒΑ την καθιστά ιδιαίτερα χρήσιμη για προβλήματα που περιλαμβάνουν πολύπλοκες σχέσεις εισόδου-εξόδου, καθώς απλοποιεί τη δομή του δικτύου και μειώνει τον κίνδυνο υπερ-εκπαίδευσης. Επιπλέον, η απουσία συνάρτησης ενεργοποίησης στη RBF μειώνει την υπολογιστική πολυπλοκότητα του δικτύου και το καθιστά πιο αποδοτικό σε πραγματικό χρόνο εφαρμογών.

Optimizers: SGD στο ANN

Ο στοχαστικός κατεβαστής κλίσης («SGD») είναι ένας ευρέως χρησιμοποιούμενος αλγόριθμος βελτιστοποίησης για νευρωνικά δίκτυα. Λειτουργεί προσαρμόζοντας τα βάρη και τις αποκλίσεις του μοντέλου βάσει της κλίσης της συνάρτησης απώλειας. Ο βελτιωτικός αλγόριθμος «Adam» είναι ένας άλλος δημοφιλής αλγόριθμος που συνδυάζει τα πλεονεκτήματα των αλγορίθμων «Adagrad» και «RMSprop». Ωστόσο, στη συγκεκριμένη περίπτωση επιλέχθηκε ο SGD καθώς αποδείχθηκε ο ιδανικός για την επίτευξη καλών αποτελεσμάτων.

Optimizers: Rmsprop στο RBF

Ο προσαρμοστικός ρυθμός μάθησης βοηθά τον αλγόριθμο να συγκλίνει ταχύτερα και να αποφύγει τις αλλεπάλληλες διακυμάνσεις που προκαλούνται από υψηλή διακύμανση στις κλίσεις. Επιπλέον, ο αλγόριθμος RMSprop αντιμετωπίζει αποτελεσματικά το πρόβλημα των εξαφανιζόμενων και απότομων κλίσεων που είναι συνηθισμένο στα «deep learning» δίκτυα. Αυτό επιτυγχάνεται με την κλιμάκωση των

κλίσεων εγκαθιστώντας έναν κινούμενο μέσο όρο των τετραγωνικών τιμών τους, ο οποίος βοηθά σταθεροποιώντας τη διαδικασία εκμάθησης και βελτιώνοντας τη συνολική απόδοση του δικτύου.


Loss function: Mean squared error

Η συνάρτηση απώλειας Mean squared error (MSE¹⁹) είναι μια κοινή συνάρτηση απώλειας που χρησιμοποιείται σε προβλήματα παλινδρόμησης. Μετρά τη διαφορά των προβλεπόμενων και των πραγματικών τιμών υψωμένων στο τετράγωνο. Επιλέχθηκε στη συγκεκριμένη περίπτωση καθώς είναι κατάλληλη για την πρόβλεψη συνεχών τιμών και αποδείχθηκε αποτελεσματική στην ελαχιστοποίηση του σφάλματος πρόβλεψης.

Διαγράμματα καλύτερου πειράματος

Παρακάτω, ακολουθούν τα διαγράμματα των πειραμάτων με τα καλύτερα αποτελέσματα.

- **Train: 80% Test: 20% - ANN- Ακρίβεια προβλέψεων: 87.86%**




Εικόνα 14: ANN Train - Test loss (80%-20% train-test)

Pos	Name	Age	Actual PPG	ANN Prediction	Accuracy
PG	Trae Young	22	25.3	[[24.413813]]	[[96.497284]]%
PG	Trae Young	20	19.1	[[21.56735]]	[[87.08194]]%
PG	Lonzo Ball	23	14.6	[[17.364992]]	[[81.0617]]%
PG	Shaun livingston	28	8.3	[[10.636344]]	[[71.85128]]%
PF	John Collins	20	10.5	[[10.815396]]	[[96.99622]]%
PF	John Collins	21	19.5	[[16.077673]]	[[82.44961]]%
PF	John Collins	23	17.6	[[14.436341]]	[[82.024666]]%
PF	John Collins	25	12.3	[[13.778692]]	[[87.97811]]%
SG	Donte DiVincenzo	22	4.9	[[5.5175734]]	[[87.39646]]%
SG	Donte DiVincenzo	23	9.2	[[9.97558]]	[[91.56978]]%
SG	Donte DiVincenzo	23	10.4	[[11.651255]]	[[87.968704]]%
SG	Donte DiVincenzo	25	9	[[9.859745]]	[[99.33617]]%
SG	Donte DiVincenzo	26	5	[[6.919869]]	[[61.602623]]%
SF	Trevor Ariza	33	12.5	[[15.685131]]	[[74.51895]]%

Εικόνα 15: ANN Πειράματα (80%-20% train-test) και ακρίβεια

Train: 80% Test: 20% - RBF - Ακρίβεια προβλέψεων: 82.70%



Εικόνα 16: RBF Train - Test loss (80%-20% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
PG	Trae Young	22	25.3	[[24.816446]]	[[98.08872]]%
PG	Trae Young	20	19.1	[[18.438555]]	[[96.536934]]%
PG	Lonzo Ball	23	14.6	[[18.264872]]	[[74.89815]]%
PG	Shaun Livingston	28	6.6	[[8.684519]]	[[69.628494]]%
PG	Shaun Livingston	28	8.3	[[12.11351]]	[[54.0541]]%
PF	John Collins	20	10.5	[[12.727651]]	[[78.78428]]%
PF	John Collins	21	19.5	[[17.810617]]	[[91.3365]]%
PF	John Collins	23	17.6	[[13.716587]]	[[77.93515]]%
PF	John Collins	25	12.3	[[13.159171]]	[[93.01487]]%
SG	Donte DiVincenzo	22	4.9	[[5.3956485]]	[[89.88473]]%
SG	Donte DiVincenzo	23	9.2	[[10.519677]]	[[85.65568]]%
SG	Donte DiVincenzo	23	10.4	[[12.116354]]	[[83.49659]]%
SG	Donte DiVincenzo	25	9	[[11.347639]]	[[73.91512]]%
SG	Donte DiVincenzo	26	5	[[6.986573]]	[[60.268536]]%
SF	Trevor Ariza	33	12.5	[[16.283928]]	[[69.72858]]%

Εικόνα 17: RBF Πειράματα(80%-20% train-test) και ακρίβεια

Πίνακας 5: Αποτελέσματα βέλτιστων πειραμάτων κανονικής περιόδου NBA

¹⁹ MSE: Mean Squared Error

Όπως φαίνεται και στις εικόνες παρατηρείται μείωση του σφάλματος εκπαίδευσης («train loss») και ελέγχου («test loss») καθώς αυξάνεται ο αριθμός των εποχών. Αυτή η τάση μπορεί να εξηγηθεί από το γεγονός ότι όσο αυξάνεται ο αριθμός των εποχών, το μοντέλο έχει περισσότερες ευκαιρίες να προσαρμόσει τις παραμέτρους του για να ταιριάζουν καλύτερα με τα δεδομένα εκπαίδευσης. Η συγκεκριμένη διαδικασία προσαρμογής διενεργείται συνήθως μέσω αλγορίθμων βελτιστοποίησης, του «SGD» και «RMSprop», που ενημερώνουν τις παραμέτρους του μοντέλου προκειμένου να ελαχιστοποιηθεί η συνάρτηση απώλειας.

Καθώς το μοντέλο συνεχίζει να εκπαιδεύεται με περισσότερες εποχές, μαθαίνει να γενικεύει καλύτερα τα ανεξάρτητα δεδομένα, με αποτέλεσμα την μείωση του σφάλματος ελέγχου. Το γεγονός αυτό συμβαίνει διότι το μοντέλο μαθαίνει σταδιακά να αντιλαμβάνεται τα υποκείμενα μοτίβα στα δεδομένα εκπαίδευσης και είναι δυνατόν να γίνει χρήση τους για επίτευξη ακριβέστερων προβλέψεων σε νέα δεδομένα.

Ωστόσο, είναι σημαντικό να προσέχουμε το φαινόμενο της υπερ-εκπαίδευσης, («overfitting») το οποίο συμβαίνει όταν το μοντέλο προσαρμόζεται υπερβολικά στα δεδομένα εκπαίδευσης και αδυνατεί να γενικευθεί σε νέα δεδομένα. Για να αποφευχθεί το γεγονός αυτό, είναι δυνατόν να γίνει χρήση μια σειράς από τεχνικές, όπως η πρόωρη διακοπή της εκπαίδευσης, η ρύθμιση των παραμέτρων και η χρήση τεχνικών αύξησης δεδομένων.


4.1.1.1.2. Πρόσθετα Πειράματα

Για τον χαρακτηρισμό των παραπάνω αποτελεσμάτων ως βέλτιστα θα αναλυθούν στις επόμενες ενότητες περαιτέρω πειράματα με διαφορετικές παραμέτρους.

4.1.1.1.2.1. Πειράματα με διαφορετικά train-test splits

Όπως φαίνεται και παρακάτω, η επιλογή διαχωρισμού του δείγματος εκπαίδευσης – ελέγχου σε 80%-20% αντίστοιχα είναι η καλύτερη καθώς σε όλες τις περιπτώσεις έχουμε την μέγιστη ακρίβεια και τα καλύτερα αποτελέσματα όσον αφορά το «training» και «test loss». Η μόνη περίπτωση που υπάρχουν ελαφρώς χειρότερα αποτελέσματα είναι με 60% - 40% «train – test split» στον αλγόριθμο ANN.

- **Train: 70% Test: 30% - ANN - Ακρίβεια προβλέψεων: 83.38%**




Εικόνα 18: ANN Train loss- Test loss (70%-30% train-test)

Pos	Name	Age	Actual PPG	ANN Prediction	Accuracy
PG	Trae Young	22	25.3	[[23.691448]]	[[93.64209]]%
PG	Trae Young	20	19.1	[[19.404408]]	[[98.40624]]%
PG	Lonzo Ball	23	14.6	[[19.101843]]	[[69.16547]]%
PG	Shaun Livingston	28	8.3	[[11.70467]]	[[58.97988]]%
PF	John Collins	20	10.5	[[11.192095]]	[[93.40862]]%
PF	John Collins	21	19.5	[[18.675873]]	[[95.773705]]%
PF	John Collins	23	17.6	[[16.301792]]	[[92.62382]]%
PF	John Collins	25	12.3	[[14.128138]]	[[85.13709]]%
SG	Donte DiVincenzo	22	4.9	[[5.5630827]]	[[86.467705]]%
SG	Donte DiVincenzo	23	9.2	[[10.011304]]	[[91.1806]]%
SG	Donte DiVincenzo	23	10.4	[[12.031747]]	[[84.31012]]%
SG	Donte DiVincenzo	25	9	[[10.167898]]	[[87.02335]]%
SG	Donte DiVincenzo	26	5	[[6.450915]]	[[70.981705]]%
SF	Trevor Ariza	33	12.5	[[17.399405]]	[[60.004764]]%

The accuracy of the net is : [[83.382164]] %

Εικόνα 19: ANN Πειράματα (70%-30% train-test) και ακρίβεια

- **Train: 70% Test: 30% - RBF - Ακρίβεια προβλέψεων: 81.3%**




Εικόνα 20: RBF Train loss- Test loss (70%-30% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
PG	Trae Young	22	25.3	[[24.428087]]	[[96.55371]]%
PG	Trae Young	20	19.1	[[19.499243]]	[[97.90973]]%
PG	Lonzo Ball	23	14.6	[[18.763851]]	[[71.48048]]%
PG	Shaun Livingston	20	6.6	[[8.235561]]	[[75.218765]]%
PG	Shaun Livingston	20	8.3	[[12.304196]]	[[51.75667]]%
PF	John Collins	20	10.5	[[12.461940]]	[[81.314766]]%
PF	John Collins	21	19.5	[[18.249481]]	[[93.58708]]%
PF	John Collins	23	17.6	[[14.101475]]	[[80.12201]]%
PF	John Collins	25	12.3	[[15.123085]]	[[77.048096]]%
SG	Donte DiVincenzo	22	4.9	[[5.653227]]	[[84.62802]]%
SG	Donte DiVincenzo	23	9.2	[[10.53264]]	[[85.507996]]%
SG	Donte DiVincenzo	23	10.4	[[12.56405]]	[[79.191826]]%
SG	Donte DiVincenzo	25	9	[[10.889201]]	[[79.00887]]%
SG	Donte DiVincenzo	26	5	[[7.3097843]]	[[52.20431]]%
SF	Trevor Ariza	33	12.5	[[16.292180]]	[[60.66249]]%

The accuracy of the net is : [[81.357005]] %

Εικόνα 21: RBF Πειράματα (70%-30% train-test) και ακρίβεια

- Train: 90% Test: 10% - ANN - Ακρίβεια προβλέψεων: 84.88%**




Εικόνα 22: ANN Train loss- Test loss (90%-10% train-test)

Pos	Name	Age	Actual PPG	ANN Prediction	Accuracy
PG	Trae Young	22	25.3	[[25.374035]]	[[99.70737]]%
PG	Trae Young	20	19.1	[[19.072917]]	[[95.953316]]%
PG	Lonzo Ball	23	14.6	[[18.61675]]	[[72.48801]]%
PG	Shaun livingston	28	8.3	[[11.963047]]	[[55.866905]]%
PF	John Collins	20	10.5	[[11.985877]]	[[85.84879]]%
PF	John Collins	21	19.5	[[16.433546]]	[[84.2746]]%
PF	John Collins	23	17.6	[[13.195753]]	[[74.97587]]%
PF	John Collins	25	12.3	[[14.381121]]	[[83.08032]]%
SG	Donte DiVincenzo	22	4.9	[[5.323834]]	[[91.35033]]%
SG	Donte DiVincenzo	23	9.2	[[9.3288765]]	[[98.59917]]%
SG	Donte DiVincenzo	23	10.4	[[11.042818]]	[[93.01905]]%
SG	Donte DiVincenzo	25	9	[[10.411095]]	[[84.32117]]%
SG	Donte DiVincenzo	26	5	[[6.732316]]	[[65.35368]]%
SF	Trevor Ariza	33	12.5	[[15.867613]]	[[73.0591]]%

Εικόνα 23: ANN Πειράματα (90%-10% train-test) και ακρίβεια

- Train: 90% Test: 10% - RBF - Ακρίβεια προβλέψεων: 77.68%**




Εικόνα 24: RBF Train loss- Test loss (90%-10% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
PG	Trae Young	22	25.3	[[22.218128]]	[[87.818095]]%
PG	Trae Young	20	19.1	[[17.205112]]	[[90.07912]]%
PG	Lonzo Ball	23	14.6	[[18.388762]]	[[74.04958]]%
PG	Shaun livingston	28	8.3	[[9.943109]]	[[40.346084]]%
PG	Shaun livingston	28	8.3	[[14.021425]]	[[31.06717]]%
PF	John Collins	20	10.5	[[14.174605]]	[[65.003]]%
PF	John Collins	21	19.5	[[10.174658]]	[[93.20338]]%
PF	John Collins	23	17.6	[[14.032379]]	[[79.72942]]%
PF	John Collins	25	12.3	[[15.551407]]	[[73.5658]]%
SG	Donte DiVincenzo	22	4.9	[[5.6653447]]	[[84.38072]]%
SG	Donte DiVincenzo	23	9.2	[[10.539746]]	[[85.437874]]%
SG	Donte DiVincenzo	23	10.4	[[12.040662]]	[[84.2244]]%
SG	Donte DiVincenzo	25	9	[[9.831837]]	[[90.75737]]%
SG	Donte DiVincenzo	26	5	[[6.988388]]	[[60.23224]]%
SF	Trevor Ariza	33	12.5	[[16.748524]]	[[66.01181]]%

Εικόνα 25: RBF Πειράματα (90%-10% train-test) και ακρίβεια

- Train: 60% Test: 40% - ANN - Ακρίβεια προβλέψεων: 83.77%**




Εικόνα 26: ANN Train loss- Test loss (60%-40% train-test)

Pos	Name	Age	Actual PPG	ANN Prediction	Accuracy
PG	Trae Young	22	25.3	[[22.672377]]	[[89.614136]]%
PG	Trae Young	20	19.1	[[19.058426]]	[[99.78233]]%
PG	Lonzo Ball	23	14.6	[[17.957989]]	[[77.00008]]%
PG	Shaun livingston	28	8.3	[[11.640641]]	[[59.751316]]%
PF	John Collins	20	10.5	[[11.408108]]	[[91.35136]]%
PF	John Collins	21	19.5	[[16.031607]]	[[82.21336]]%
PF	John Collins	23	17.6	[[13.552542]]	[[77.003075]]%
PF	John Collins	25	12.3	[[13.826956]]	[[87.585724]]%
SG	Donte DiVincenzo	22	4.9	[[6.268591]]	[[72.06957]]%
SG	Donte DiVincenzo	23	9.2	[[9.428728]]	[[97.513824]]%
SG	Donte DiVincenzo	23	10.4	[[12.1385975]]	[[83.282715]]%
SG	Donte DiVincenzo	25	9	[[12.114832]]	[[65.39076]]%
SG	Donte DiVincenzo	26	5	[[6.876647]]	[[62.46706]]%
SF	Trevor Ariza	33	12.5	[[15.759007]]	[[73.92794]]%

Εικόνα 27: ANN Train loss- Test loss (60%-40% train-test) και ακρίβεια

- **Train: 60% Test: 40% - RBF - Ακρίβεια προβλέψεων: 82.56%**



Εικόνα 28: RBF Train loss- Test loss (60%-40% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
PG	Trae Young	22	25.3	[[24.914518]]	[[98.47636]]%
PG	Trae Young	28	19.1	[[19.496536]]	[[97.9239]]%
PG	Lonzo Ball	23	14.6	[[18.481773]]	[[73.96846]]%
PG	Shaun Livingston	28	6.6	[[8.3239765]]	[[73.87914]]%
PG	Shaun Livingston	28	8.3	[[10.358215]]	[[75.298615]]%
PF	John Collins	28	18.5	[[18.618902]]	[[95.41811]]%
PF	John Collins	21	19.5	[[16.88599]]	[[86.18456]]%
PF	John Collins	23	17.6	[[14.596313]]	[[82.93359]]%
PF	John Collins	25	12.3	[[11.814719]]	[[96.85463]]%
SG	Donte DiVincenzo	22	4.9	[[5.3268845]]	[[91.38683]]%
SG	Donte DiVincenzo	23	9.2	[[10.352544]]	[[87.47235]]%
SG	Donte DiVincenzo	23	10.4	[[12.152529]]	[[83.14876]]%
SG	Donte DiVincenzo	25	9	[[11.794454]]	[[68.958516]]%
SG	Donte DiVincenzo	26	5	[[7.3599863]]	[[52.888274]]%
SF	Trevor Ariza	33	12.5	[[15.671389]]	[[74.629524]]%

Εικόνα 29: RBF Πειράματα (60%-40% train-test) και ακρίβεια

Πίνακας 6: Περαιτέρω πειράματα για την κανονική περίοδο NBA

Επιπλέον, όπως φαίνεται στις εικόνες παραπάνω η μόνη αξιολόγηση περίπτωση είναι η εκπαίδευση με 60%-40 train-test του αλγόριθμου ANN καθώς επιτυγχάνεται η μείωση του σφάλματος εκπαίδευσης («train loss») και ελέγχου («test loss») με ταυτόχρονα αξιολόγηση ακρίβεια προβλέψεων. Στις υπόλοιπες περιπτώσεις όπως παρατηρείται δεν μειώνεται πάντα το σφάλμα εκπαίδευσης και ελέγχου που μεταφράζεται σε μία τάση προς υπερ-εκπαίδευση δηλαδή «overfitting».

4.1.1.1.2.2. Πειράματα με διαφορετικό αριθμό epochs

Όπως φαίνεται και παρακάτω στην παρούσα εργασία, η επιλογή των 1000 εποχών βασίστηκε στην αξιολόγηση της απόδοσης του μοντέλου σε ένα σύνολο δεδομένων επικύρωσης (validation set). Διαπιστώθηκε ότι η αύξηση του αριθμού των εποχών πέραν των 1000 δεν οδήγησε σε σημαντική βελτίωση της απόδοσης του μοντέλου. Επιπλέον, παρατηρήθηκε τάση προς υπερ-εκπαίδευση («overfitting») όσο αυξανόταν ο αριθμός των εποχών πέραν των 1000 «epochs». Συνεπώς, τα 1000 «epochs» ήταν επαρκή για να επιτευχθεί μια καλή ισορροπία μεταξύ της ακρίβειας του μοντέλου και της υπερ-εκπαίδευσης. Η απόφαση αυτή βασίστηκε σε προηγούμενες μελέτες στον τομέα και σε πειράματα όπως φαίνεται και πιο πάνω.

Ακολουθεί συγκριτικός πίνακας για τα δυο είδη των ΤΝΔ:

Τεχνητό νευρωνικό δίκτυο με ANN

Epochs	Χρόνος εκτέλεσης	Loss	Ακρίβεια
100	18.2 δευτ.	0.0215	66.21%
1000	2 λ. 23 δευτ.	0.007	87.86%
10000	19 λ. 56 δευτ.	0.0089	80.64%

Πίνακας 7: Πειράματα ANN με διαφορετικά Epochs

Τεχνητό νευρωνικό δίκτυο με RBF

Epochs	Χρόνος εκτέλεσης	loss	Ακρίβεια
100	25δευτ.	0,01	75%
1000	3λ. 17δευτ.	0,0055	82,7%
10000	34λ. 55δευτ.	0,0039	81,47%

Πίνακας 8: Πειράματα RBF με διαφορετικά Epochs

4.1.1.1.2.3. Πειράματα με περισσότερες Loss functions

Επιλέχθηκε η συνάρτηση απώλειας «Mean Squared Error» για την εκπαίδευση και αξιολόγηση του νευρωνικού δικτύου. Η χρήση της «MSE» είναι κατάλληλη για το πρόβλημα της πρόβλεψης καθώς η πρόβλεψη πόντων είναι μια συνεχής μεταβλητή που μπορεί να λάβει μια ευρεία ποικιλία τιμών. Επιπλέον, η «MSE» είναι μια διαφορίσιμη συνάρτηση, καθιστώντας την συμβατή με αλγόριθμους βελτιστοποίησης βασισμένους στην κλίση, όπως η στοχαστική κλίση καθώς και οι παραλλαγές της, που συνήθως χρησιμοποιούνται για την εκπαίδευση νευρωνικών δικτύων.

Η επιλογή της «MSE» βασίστηκε επίσης σε προηγούμενα πειράματα, τα οποία έχουν αποδείξει την αποτελεσματικότητά της για παρόμοιες προβλέψεις που αφορούν την παλινδρόμηση. Ωστόσο, αξίζει να σημειωθεί ότι η επιλογή της συνάρτησης απώλειας εξαρτάται από το συγκεκριμένο πρόβλημα και τον τύπο των δεδομένων που χρησιμοποιούνται. Σε ορισμένες περιπτώσεις, εναλλακτικές συναρτήσεις απώλειας, όπως η μέση απόλυτη σφάλματος ή η συνάρτηση Huber, μπορεί να είναι πιο κατάλληλες.

Optimizer ANN	Optimizer RBF	Loss function	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
SGD	RMSprop	Mean Squared Error	0.007	0,0055	87.86%	82.7%
SGD	SGD	Mean Squared Error	0.007	0.022	87.86%	65.6%
SGD	RMSprop	Mean Absolute Error	0.1213	0.0054	69.121%	74.48%
SGD	SGD	Mean Squared Logarithmic Error	0.0038	0.095 σταθερό	83.233 %	67.9%

Πίνακας 9: Πειράματα ANN- RBF με διαφορετικές loss functions

Επιπλέον, όπως φαίνεται και στον πίνακα παραπάνω και η συνάρτηση «Mean Squared Logarithmic Error» πετυχαίνει ένα ακόμα χαμηλότερο «loss» αλλά κρατήθηκε η επιλογή της «MSE» διότι η ακρίβεια μειώθηκε σημαντικά με οποιαδήποτε άλλη συνάρτηση.

4.1.1.1.2.4. Διαφορετική επιλογή κρυφών επίπεδων

Η επιλογή του αριθμού των κρυφών στρωμάτων σε ένα πρόγραμμα νευρωνικού δικτύου αποτελεί μία σημαντική παράμετρο που μπορεί να επηρεάσει σημαντικά την απόδοση του μοντέλου. Ελάχιστα κρυφά στρώματα μπορεί να οδηγήσουν σε ελλιπή εκπαίδευση («underfitting»), όπου το μοντέλο αποτυγχάνει να αποτυπώσει τα υποκείμενα μοτίβα των δεδομένων, ενώ πολλά κρυφά στρώματα μπορεί να οδηγήσουν σε υπερ-εκπαίδευση («overfitting»), όπου το μοντέλο γίνεται εξειδικευμένο στα δεδομένα εκπαίδευσης αποτυγχάνοντας σε νέα δεδομένα.

Στην συγκεκριμένη εργασία, αξιολογήθηκε η απόδοση του συγκεκριμένου προγράμματος με διαφορετικό αριθμό κρυφών στρωμάτων, που κυμαίνεται από τρία έως δεκα-πέντε. Μέσω πειραματισμού και ανάλυσης, βρέθηκε ότι το πρόγραμμα νευρωνικού δικτύου με τρία κρυφά επίπεδα επέδειξε την καλύτερη απόδοση σε όρους της ακρίβειας και ταυτόχρονα αρκετά μικρής απώλειας.

Κρυφά επίπεδα	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
3	0.007	0,0055	87.86%	82.7%
5	0.0040	0.0567	85.54%	79.23%
10	0.0040	0.1246	81.54%	60.36%
15	0.0058	0.1247	72.88%	63.58%

Πίνακας 10: Πειράματα ANN-RBF με διαφορετικό αριθμό κρυφών επιπέδων

Το γεγονός αυτό οφείλεται στο ότι με τρία κρυφά επίπεδα το δίκτυο χαρακτηρίζεται από μια ισορροπία μεταξύ της πολυπλοκότητας του μοντέλου και της ικανότητας να ανιχνεύσει πολύπλοκα πρότυπα στα δεδομένα. Η αύξηση του αριθμού των κρυφών επιπέδων πέρα από τα τρία μπορεί να οδηγήσει σε υπερ-εκπαίδευση («overfitting»), ενώ η μείωση του αριθμού των κρυφών επιπέδων μπορεί να οδηγήσει σε ελλιπή εκπαίδευση («underfitting»).

Επιπροσθέτως, η αξιολόγηση της απόδοσης του μοντέλου βασίζεται σε ένα σύνολο επικύρωσης ώστε να διασφαλιστεί ότι ο αριθμός των επιπέδων που επιλέχθηκε ήταν βέλτιστος. Επιπλέον, με βάση τα πειράματα κρίθηκε η ιδανική επιλογή για να υπάρχει ταυτόχρονα η μέγιστη ακρίβεια και η μικρότερη απώλεια.

4.1.1.1.2.5. Διαφορετική επιλογή συναρτήσεων ενεργοποίησης

Όσον αφορά στον αλγόριθμο ANN βασιζόμενοι στα πειραματικά αποτελέσματα που προέκυψαν από το πρόγραμμα του νευρωνικού δικτύου, παρατηρείται ότι η συνδυασμένη χρήση της συνάρτησης ενεργοποίησης «Relu» στα κρυφά επίπεδα και της συνάρτησης ενεργοποίησης «sigmoid» στο επίπεδο εξόδου έχει επιτύχει τη μεγαλύτερη ακρίβεια 87,86% με απώλεια («loss») 0,007.

Το παραπάνω συμπέρασμα βασίζεται σε αρκετούς παράγοντες, συμπεριλαμβανομένου του τύπου των δεδομένων, του τύπου της εισόδου και της

εξόδου και των τιμών που έχουν μετρηθεί για τα αποτελέσματα απώλειας και ακρίβειας. Το σύνολο δεδομένων αποτελείται από αριθμητικά δεδομένα όπου εκφράζεται μη γραμμικότητα, συνεπώς η «Relu» αποτελεί μία καλή επιλογή καθώς μπορεί να μοντελοποιήσει αποτελεσματικά τις μη γραμμικές σχέσεις. Επιπλέον αφού δεν γίνεται επεξεργασία αρνητικών τιμών η σιγμοειδής («sigmoid») αποτελεί μία καλή επιλογή για το επίπεδο εξόδου διότι είναι κατάλληλη περιορίζοντας τις τιμές της εξόδου μεταξύ 0 και 1.

Με βάση τα παραπάνω είναι λογικό το συμπέρασμα ότι ο συνδυασμός της συνάρτησης ενεργοποίησης «Relu» στα κρυφά επίπεδα και της συνάρτησης ενεργοποίησης «sigmoid» στο επίπεδο εξόδου είναι η πιο αποτελεσματική διαμόρφωση για το συγκεκριμένο μοντέλο νευρωνικού δικτύου.

Activation functions	Loss	Accuracy
Relu- sigmoid	0.007	87.86%
elu-sigmoid	0.0037	83.85%
elu-softmax	Σταθερό	-
Relu-softmax	Σταθερό	-
Relu-softsign	0.0039	82.33%
Relu-tanh	0.0037	82.88%
Relu-Relu	0.1821 Σταθερό	-

Πίνακας 11: Πειράματα ANN-RBF με διαφορετικές activation functions

Επιπλέον, η χρήση συναρτήσεων ενεργοποίησης στα δίκτυα RBF ενδέχεται να επηρεάσει αρνητικά την απόδοσή τους εισάγοντας περιττή πολυπλοκότητα στο δίκτυο. Ελλοχεύει ο κίνδυνος της υπερ-εκπαίδευσης και μειωμένης απόδοσης στην γενίκευση απόδοσης του δικτύου.

4.1.1.1.2.6. Διαφορετική επιλογή εισόδων

Όπως φαίνεται και παρακάτω, όσον αφορά τον αλγόριθμο ANN, η επιλογή εισόδων που έχει επιλεγεί σύμφωνα με τον παρακάτω πίνακα αποτελεί την βέλτιστη καθώς με μείωση των εισόδων μειώνεται αρκετά η ακρίβεια και αυξάνεται η τιμή της απώλειας ελαφρώς. Ωστόσο, παρατηρείται ότι εάν παραλειφθεί η είσοδος αναφορικά με τους τραυματισμούς ενός αθλητή η τιμή της απώλειας βελτιώνεται και η ακρίβεια του προγράμματος πλησιάζει την καλύτερη τιμή που βρέθηκε πριν. Το συγκεκριμένο αποτέλεσμα οφείλεται στο ότι οι παράγοντες που επηρεάζουν την απόδοση ενός αθλητή εξαρτάται από την ευστοχία του κυρίως και τα λεπτά συμμετοχής. Φυσικά, είναι άμεσα συνδεδεμένα όλα αυτά μεταξύ τους δηλαδή ένας αθλητής με αρκετούς τραυματισμούς ενδέχεται να έχει μειωμένα ποσοστά ευστοχίας.

Όσον αφορά τον αλγόριθμο RBF παρατηρείται ότι όταν σαν είσοδο υπάρχει μόνο το στατιστικό ευστοχίας «eFG%» επιτυγχάνεται μεγαλύτερη ακρίβεια, κάτι το οποίο θα ήταν λογικό αν αναλογιστεί κανείς ότι το στατιστικό «eFG%» έχει μεγαλύτερο αντίκτυπο στην επίτευξη πόντων καθώς είναι μία μετρική η οποία αντιμετωπίζει πιο αποτελεσματικά τον αντίκτυπο που έχει η επίτευξη ενός «τρίποντου» ή ενός «δίποντου» στην διάρκεια του παιχνιδιού.

Είσοδοι	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
	0.007	0,0055	87.86%	82.7%
Χωρίς FG%	0.0079	0.0055	86.39%	87.51%
Χωρίς FG% και TOV (λάθη)	0.0062	0.0088	69.64%	75.28%
Χωρίς τραυματισμούς	0.0037	0.0059	84.78%	79,18%

Πίνακας 12: Διαφορετική επιλογή εισόδων

Συνολικά, ενδεχομένως θα ήταν προτιμότερο να μειωθεί ο αριθμός των εισόδων και η αφαίρεση της μετρικής «FG%» και από τα δύο προγράμματα καθώς υπάρχει πολύ μικρή μείωση ακρίβειας στον αλγόριθμο ANN και αύξηση ακρίβειας στον RBF.

4.1.1.2. Υλοποίηση με MATLAB

Στην ενότητα αυτή, θα μελετηθεί η υλοποίηση του προγράμματος πρόβλεψης απόδοσης πόντων αθλητών NBA με την βοήθεια του εργαλείου της MATLAB. Το παρακάτω πρόγραμμα υλοποιήθηκε σύμφωνα με τον αλγόριθμο ANN. Θα πραγματοποιηθεί εκπαίδευση με τις ίδιες εισόδους όπως και πριν και ταυτοχρόνως θα γίνει χρήση παρόμοιων παραμέτρων. Για την υλοποίηση του προγράμματος στην MATLAB έγινε χρήση της διεπαφής «Neural Network Toolbox» η οποία προσφέρει όλες τις απαραίτητες συναρτήσεις για την υλοποίηση ενός ANN δικτύου.

Κατά τη διάρκεια του κεφαλαίου, θα διενεργηθούν πειράματα όσον αφορά στον αριθμό των εποχών, των εισόδων και των κρυφών επιπέδων προκειμένου να ερευνηθεί η επίδραση των παραγόντων αυτών στην ακρίβεια του δικτύου. Σκοπός της ενότητας είναι να δοθεί μια πληρέστερη εικόνα στο κατά πόσο είναι δυνατόν να γίνει πρόβλεψη απόδοσης αθλητών του NBA και ποιο εργαλείο είναι πιο αξιόπιστο.

4.1.1.2.1. Πείραμα μέγιστης ακρίβειας


Η μεγαλύτερη ακρίβεια όπως θα αποδειχθεί και παρακάτω επιτεύχθηκε με τις παρακάτω εισόδους οι οποίες είναι οι ίδιες όπως και στις υλοποιήσεις σε γλώσσα PYTHON:

1. θέση
2. ηλικία
3. ποσοστό αγώνων συμμετοχής
4. λεπτά συμμετοχής
5. FG%
6. eFG%
7. FT%
8. TOV

Και έξοδος:

1. M.O. πόντων

Παρακάτω φαίνεται η δομή του δικτύου στην MATLAB με 3 κρυφά επίπεδα από 8 εισόδους το κάθε ένα.




Εικόνα 30: Δομή ΤΝΔ MATLAB

- **Train: 80% Test: 20%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	8.355	1 δευτ.	83.81%
Mean Absolute Error (MAE)	2.4748	1 δευτ.	83.81%
Root Mean Squared Error (RMSE)	3.3228	1 δευτ.	83.81%

Πίνακας 13: Βέλτιστα αποτελέσματα MATLAB



Εικόνα 31: Πειράματα MATLAB 80%train-20%test splits

Όπως φαίνεται στις παραπάνω εικόνες το πρόγραμμα του αλγόριθμου ANN στην MATLAB επιτυγχάνει 83.81% ακρίβεια προβλέψεων με τις ίδιες παραμέτρους που χρησιμοποιήθηκαν και στην γλώσσα PYTHON ενώ ταυτόχρονα τερματίζει με σφάλμα εκπαίδευσης 8.35 με συνάρτηση ενεργοποίησης την «MSE» και υψηλή ακρίβεια στις προβλέψεις του, ωστόσο όπως φαίνεται σε άλλες συναρτήσεις όπως οι «Mean Absolute Error» και «Root Mean Squared Error» το σφάλμα εκπαίδευσης είναι εμφανώς χαμηλότερο. Όπως φαίνεται και στο διάγραμμα το πρόγραμμα σταματάει έπειτα από 16 εποχές («epochs») καθώς επιτυγχάνει την ελάχιστη τιμή σφάλματος. Ο σκοπός της διακοπής αυτής είναι η αποτροπή του δικτύου από την υπερ-εκπαίδευση, συνεπώς δεν έχει και νόημα η δοκιμή περισσότερων εποχών όπως στην PYTHON καθώς το πρόγραμμα διακόπτεται έπειτα από το μέγιστο 25 εποχές. Δοκιμάστηκαν επίσης και τεχνικές κανονικοποίησης, διαφορετικών παραμέτρων όπως διαφορετικών train-test splits αλλά όπως θα αποδειχθεί και παρακάτω με 80%train-20%test πάρθηκαν τα καλύτερα αποτελέσματα.

4.1.1.2.2. Πρόσθετα Πειράματα

Παρακάτω θα αναλυθούν περαιτέρω πειράματα για την απόδειξη του ισχυρισμού, ότι παραπάνω πάρθηκαν τα καλύτερα αποτελέσματα.


4.1.1.2.2.1. Πειράματα με διαφορετικά test-train splits

Αρχικά, θα εξεταστεί το πρόγραμμα όσον αφορά στον διαχωρισμό δειγμάτων δεδομένων εκπαίδευσης – επαλήθευσης. Θα εξεταστούν οι περιπτώσεις 90%-10%, 70%-30%, 60%-40%.

- **Train: 90% Test: 10%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	9.9156	2 δευτ.	77.72%
Mean Absolute Error (MAE)	2.2175	2 δευτ.	77.72%
Root Mean Squared Error (RMSE)	2.8668	2 δευτ.	77.72%

Πίνακας 14: Ενδεικτικά πειράματα 90%-10% train-test




Εικόνα 32: Πειράματα MATLAB 90% train-10% splits

- **Train: 70% Test: 30%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	11.6572	2 δευτ.	82.93%
Mean Absolute Error (MAE)	2.4383	2 δευτ.	82.93%
Root Mean Squared Error (RMSE)	3.4143	2 δευτ.	82.93%

Πίνακας 15: Ενδεικτικά πειράματα 70%-30% train-test




Εικόνα 33: Πειράματα MATLAB 70% train-30%test splits

- **Train: 60% Test: 40%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	14.7371	1 δευτ.	80.99%
Mean Absolute Error (MAE)	2.7883	1 δευτ.	80.99%
Root Mean Squared Error (RMSE)	3.8389	1 δευτ.	80.99%

Πίνακας 16: Ενδεικτικά πειράματα 60%-40% train-test



Εικόνα 34: Πειράματα MATLAB 60% train-40%test split

Όπως φαίνεται στους πίνακες παραπάνω υπάρχει πτώση της ακρίβειας του δικτύου σε οποιαδήποτε περίπτωση διαχωρισμού των στοιχείων εκπαίδευσης και επαλήθευσης με ταυτόχρονη αύξηση του σφάλματος συναρτήσεων. Με αυτόν τον τρόπο γίνεται αντιληπτό ότι το δίκτυο έχει τάση προς την υπερ-εκπαίδευση δηλαδή έχει την δυνατότητα πρόβλεψης μόνο σε στοιχεία της βάσης δεδομένων και όχι σε νέα. Με άλλα λόγια ενδέχεται να μην γίνεται να εκτελεστεί ορθά σε δεδομένα εκτός της βάσης δεδομένων. Συνεπώς, επιλέγεται ο διαχωρισμός 80%-20% ως βέλτιστη επιλογή.

4.1.1.2.2. Διαφορετική επιλογή κρυφών επιπέδων

Κρυφά επίπεδα	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
3	8.355	2.4748	3.3228	83.81%
5	22.9538	3.8995	4.791	79.09%
10	12.1414	2.6632	3.4845	77.31%
15	8.4811	2.2318	2.9122	82.14%

Πίνακας 17: Διαφορετική επιλογή κρυφών επιπέδων MATLAB

Έπειτα από τη διεξαγωγή διαφορετικών πειραμάτων προκειμένου να δοκιμαστεί η αποτελεσματικότητα διαφορετικών αριθμών κρυφών επιπέδων έγινε φανερό ότι η χρήση τριών κρυφών επιπέδων είναι η βέλτιστη επιλογή. Τα πειράματά έδειξαν ότι η αύξηση του αριθμού των κρυφών στρωμάτων πέραν των τριών δεν οδήγησε σε σημαντικές βελτιώσεις στην απόδοση του δικτύου. Αντιθέτως, η συνάρτηση απώλειας είχε την τάση να αυξάνεται με την προσθήκη περισσότερων κρυφών επιπέδων, και η ακρίβεια του δικτύου μειώνεται.

Συνεπώς, συνιστάται η χρήση τριών κρυφών επιπέδων στο παρόν μοντέλο του νευρωνικού δικτύου καθώς αυτός ο αριθμός παρέχει την ιδανική ισορροπία μεταξύ της πολυπλοκότητας του μοντέλου και της πρόβλεψης απόδοσης των καλαθοσφαιριστών στο NBA.

4.1.1.2.2.3. Διαφορετική επιλογή εισόδων

Είσοδοι	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
-	8.355	2.4748	3.3228	83.81%
Χωρίς FG%	7.5551	2.0244	2.7487	80.49%
Χωρίς FG% και TOV (λάθη)	16.2796	3.0332	4.0348	63.56%
Χωρίς τραυματισμούς	10.143	2.5132	3.1848	83.02%

Πίνακας 18: Διαφορετική επιλογή εισόδων MATLAB

Με βάση τον παραπάνω πίνακα όπου δοκιμάστηκε η επίδραση διαφορετικού αριθμού εισόδων στην εγκυρότητα του παρόντος μοντέλου νευρωνικού δικτύου για την απόδοση αθλητή του πρωταθλήματος NBA, αποφανθήκαμε ότι η χρήση του τρέχοντος συνόλου μεταβλητών εισόδου είναι η βέλτιστη επιλογή. Τα πειράματά μας, δείχνουν ότι η αφαίρεση μεταβλητών εισόδου δεν οδήγησε σε σημαντικές βελτιώσεις στην απόδοση του δικτύου. Ωστόσο ενδιαφέρον παρουσιάζει το γεγονός ότι όταν έγινε αφαίρεση της εισόδου τραυματισμών ενός αθλητή του NBA από τις μεταβλητές εισόδου, η ακρίβεια του δικτύου δεν επηρεάστηκε σημαντικά.

Παρόλο που αυτό το αποτέλεσμα υποδηλώνει ότι οι τραυματισμοί μπορεί να μην είναι ένας κύριος παράγοντας στην πρόβλεψη της απόδοσης των παικτών του NBA, πρέπει να είμαστε προσεκτικοί στο να βγάλουμε απολύτως συμπεράσματα μόνο βασιζόμενοι σε αυτό το αποτέλεσμα. Είναι δυνατόν οι τραυματισμοί να έχουν μεγαλύτερη επίδραση στην απόδοση ορισμένων παικτών ή σε ορισμένες καταστάσεις, και ενδέχεται να χρειαστεί περαιτέρω έρευνα για να κατανοήσουμε πλήρως το ρόλο τους στην απόδοση των αθλητών. Παρόλα αυτά, πιστεύουμε ότι η τρέχουσα συλλογή μας από μεταβλητές εισόδου παρέχει μια ισχυρή βάση για την πρόβλεψη της απόδοσης των παικτών του NBA, και τα ευρήματά μας μπορούν να είναι χρήσιμα για τους ερευνητές και τους επαγγελματίες στον τομέα της αθλητικής ανάλυσης που ενδιαφέρονται να αναπτύξουν ακριβή προβλεπτικά μοντέλα για την απόδοση στον αθλητισμό.

4.1.1.3. Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων PYTHON -MATLAB

Σε αυτό το κεφάλαιο, θα συγκρίνουμε τις υλοποιήσεις των νευρωνικών δικτύων. Υπάρχουν αξιοσημείωτες διαφορές όσον αφορά το loss, την ακρίβεια καθώς και τους χρόνους εκτέλεσης.

Συγκεντρωτικοί πίνακες μεταξύ των υλοποιήσεων ακολουθούν:

Train – Test splits	Ακρίβεια ANN (PYTHON)	ANN loss	Ακρίβεια RBF (PYTHON)	RBF loss	Ακρίβεια ANN MATLAB	MATLAB loss
80%-20%	87.86%	0.007	82,7%	0,0055	83.81%	8.355 2.4748 3.3228
60%-40%	83.77%	0.0055	82.56%	0.0049	80.99%	14.7371 2.7883 3.8389

Πίνακας 19: Συγκεντρωτικά αποτελέσματα πειραμάτων

Όσο για τους χρόνους υλοποίησης, φαίνονται στον ακόλουθο πίνακα:

Χρόνος εκτέλεσης ANN (PYTHON)	Χρόνος εκτέλεσης RBF (PYTHON)	Χρόνος εκτέλεσης ANN MATLAB
2 λ. 23 δευτ.	3λ. 17δευτ.	1 δευτ.

Πίνακας 20: Χρόνοι εκτελέσεων μεταξύ εργαλείων

Τα αποτελέσματα όπως φαίνονται και στους πίνακες παραπάνω αποδεικνύουν ότι ο αλγόριθμος του Τεχνητού Νευρωνικού Δικτύου (ANN) που υλοποιήθηκε σε PYTHON ξεπέρασε και τον αλγόριθμο RBF και την υλοποίηση σε MATLAB ως προς την ακρίβεια των προβλέψεων. Η υψηλότερη ακρίβεια του αλγορίθμου ANN μπορεί να αποδοθεί στην ικανότητά του να μάθει πολύπλοκα πρότυπα και σχέσεις μεταξύ των δεδομένων. Σημαντικό να σημειωθεί ότι όλα τα προγράμματα πέτυχαν αξιοσημείωτη ακρίβεια και σε μικρότερο όγκο δεδομένων εκπαίδευσης-επαλήθευσης (60%-40% train-test splits) κάτι το οποίο να ενδείκνυται προκειμένου να αποφευχθεί ο κίνδυνος υπερ-εκπαίδευσης και να υπάρξει μία ισορροπία μεταξύ των δεδομένων εκπαίδευσης-επαλήθευσης.

Παρόλο που ο αλγόριθμος ANN που υλοποιήθηκε σε PYTHON ήταν ο πιο ακριβής, αξίζει να σημειωθεί ότι η υλοποίηση σε MATLAB ήταν η ταχύτερη από όλες τις υλοποιήσεις. Επομένως, αν η ταχύτητα αποτελεί το κριτήριο επιλογής στην διαδικασία πρόβλεψης, η συγκεκριμένη υλοποίηση ενδείκνυται ως η ιδανική επιλογή.

Πίνακας χωρίς την είσοδο των τραυματισμών ενός αθλητή

Ακρίβεια ANN (PYTHON)	ANN loss	Ακρίβεια RBF (PYTHON)	RBF loss	Ακρίβεια ANN MATLAB	MATLAB loss
84.78%	0.0037	79,18%	0.0059	83.02%	10.143

Πίνακας 21: Χωρίς τραυματισμούς MATLAB

Τέλος, όπως γίνεται αντιληπτό σύμφωνα με τον παραπάνω πίνακα οι τραυματισμοί ενός αθλητή ενδεχομένως να ήταν δυνατόν να παραλειφθούν σαν είσοδος στο πρόγραμμα μας καθώς δεν έχουν ιδιαίτερη δυναμική ώστε να επηρεάσουν σημαντικά την ακρίβεια του προγράμματος. Προσοχή, αυτό δεν σημαίνει ότι αν ένας αθλητής έχει πολλούς τραυματισμούς θα έχει την μέγιστη απόδοση είτε τραυματίζεται είτε όχι, αλλά ότι οι τραυματισμοί είναι ανάλογοι της απόδοσης του αθλητή μέσα στην χρονιά. Με άλλα λόγια, αν ένας αθλητής τραυματίζεται τότε θα επηρεαστεί η γενικότερη εικόνα του δηλαδή η ευστοχία του σε σουτ, ελεύθερες βολές και σε άλλες μετρικές κάτι το οποίο φυσικά θα έχει αντίκτυπο και στο σκοράρισμα του.

4.1.2. Πρόβλεψη σε συνθήκες clutch NBA

Το επόμενο πρόγραμμα που θα περιγραφεί αφορά στην πρόβλεψη απόδοσης καλαθοσφαιριστών στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης ανδρών ή αλλιώς NBA. Η διαφορά με το προαναφερθέν πρόγραμμα είναι ότι η πρόβλεψη διενεργείται όσον αφορά στις κρίσιμες στιγμές ενός αγώνα δηλαδή την περίοδο «clutch». Ως «clutch» ορίζεται τα τελευταία 5 λεπτά του αγώνα όταν η διαφορά στο σκορ είναι πέντε πόντοι μίας ομάδας από την άλλη.

Αναλυτικότερα, θα αποδειχθεί ότι είναι δυνατή η πρόβλεψη απόδοσης αθλητών στον τομέα επίτευξης πόντων στην περίοδο «clutch» γνωρίζοντας κάποια συγκεκριμένα ατομικά στοιχεία και στατιστικά όπως ηλικία, θέση, χρόνος συμμετοχής κ.α.

Απαραίτητο να ειπωθεί, ότι όλα τα δεδομένα που θα δίνονται σαν είσοδο αφορούν στοιχεία και επιδόσεις του αθλητή καθ' όλη την διάρκεια ενός αγώνα και όχι από τις επιδόσεις του στις κρίσιμες στιγμές («clutch»). Ωστόσο, σαν έξοδο θα έχουμε τον Μ.Ο. πόντων του στον χρόνο («clutch»).

Όπως γίνεται αντιληπτό η περίοδος «clutch» κρύβει την μεγαλύτερη πίεση για έναν αθλητή διότι εκείνες τις χρονικές στιγμές κρίνεται το αποτέλεσμα ενός αγώνα. Αποτελεί έναν εξαιρετικά χρήσιμο παράγοντα σύγκρισης αθλητών καθώς όλοι οι αθλητικοί οργανισμοί επιθυμούν να διαθέτουν «clutch» αθλητές διότι από αυτούς εξαρτώνται οι εκφάνσεις των αποτελεσμάτων. Για τον συγκεκριμένο λόγο κρίνεται ιδιαίτερος χρήσιμο η εφαρμογή των αλγορίθμων μας στην συγκεκριμένη χρονική περίοδο.

Συμπερασματικά, θα αποτελέσει τεράστιο όπλο για την εκάστοτε ομάδα καθώς γνωρίζοντας την απόδοση ενός αθλητή καθ' όλη την διάρκεια μίας αγωνιστικής περιόδου θα μπορεί να αποφανθεί με μία ικανοποιητική ακρίβεια εάν μπορεί να είναι εξίσου αποτελεσματικός και στο πιο σημαντικό χρονικό διάστημα του αγώνα

Όπως και προηγουμένως, θα αποδειχθεί σε τρεις διαφορετικές περιπτώσεις με την βοήθεια της γλώσσας PYTHON (δύο αλγόριθμοι) και της εφαρμογής MATLAB (ένας αλγόριθμος). Σε όλες τις περιπτώσεις θα δίνονται οι ίδιες είσοδοι και θα παίρνουμε την ίδια έξοδο για καλύτερη σύγκριση των αποτελεσμάτων μας

Τα στατιστικά αφορούν την κανονική περίοδο του NBA και όχι «playoffs» ή αγώνες «preseason». Θα αναλυθούν διαφορετικές περιπτώσεις με διαφορετικές εισόδους σε κάθε περίπτωση. Η μεγαλύτερη ακρίβεια όπως θα αποδειχθεί και παρακάτω επιτεύχθηκε με τις παρακάτω εισόδους.

4.1.2.1. Υλοποίηση σε γλώσσα PYTHON

Όπως προηγήθηκε στο προηγούμενο πρόγραμμα θα υλοποιηθεί σε δύο αλγόριθμους σε γλώσσα προγραμματισμού PYTHON και πιο συγκεκριμένα στον αλγόριθμο ΤΝΔ και ΣΒΑ. Θα ακολουθηθούν παρόμοια βήματα, ειδικότερα θα εισαχθούν πρώτα οι απαραίτητες βιβλιοθήκες, έπειτα θα εισαχθεί η βάση δεδομένων, θα πραγματοποιηθεί εκπαίδευση του δικτύου και τέλος θα διενεργηθούν πειράματα για να επαληθευθεί η εγκυρότητα του δικτύου.

Τα πειράματα θα πραγματοποιηθούν κάτω από τις ίδιες παραμέτρους για την καλύτερη σύγκριση αποτελεσμάτων. Θα υπάρξει μία σημαντική διαφορά των συγκεκριμένων πειραμάτων με αυτών της προηγούμενης ενότητας. Γενικά, όπως γίνεται αντιληπτό όταν ένας αθλητής έχει υψηλά ποσοστά ευστοχίας και αγωνίζεται αρκετά λεπτά κατά την διάρκεια ενός αγώνα θα έχει και υψηλό μέσο όρο πόντων. Αυτό όμως δεν ισχύει σε περιόδους αυξημένης πίεσης («clutch»), καθώς είναι οι πιο κρίσιμες στιγμές ενός αγώνα από τις οποίες κρίνεται η νίκη. Για τον συγκεκριμένο λόγο, στο πρόγραμμα που θα ακολουθήσει παρακάτω διενεργούνται πειράματα και σε αθλητές οι οποίοι αν και έχουν υψηλά ποσοστά ευστοχίας, δεν έχουν ανάλογη απόδοση στις κρίσιμες στιγμές. Με άλλα λόγια, θα διενεργηθούν πειράματα και σε καλαθοσφαιριστές οι οποίοι αν και διανύουν μία καλή αγωνιστικά χρονιά με καλά ποσοστά ευστοχίας, με μεγάλο μέσο όρο σκοραρίσματος δεν αποδίδουν αναλόγως στις κρίσιμες στιγμές. Ως κακή εμφάνιση αθλητή θα θεωρηθεί όταν έχει ποσοστό ευστοχίας σουτ («FG%») 32% και λιγότερο.

Ειδικότερα, η μεγαλύτερη ακρίβεια που επιτεύχθηκε στις προβλέψεις ήταν 80.11% για τον ANN αλγόριθμο και 80.82% για τον RBF αλγόριθμο, ποσοστά τα οποία μας δείχνουν ότι είναι δυνατή η πρόβλεψη απόδοσης αθλητών όχι μόνο στην φυσιολογική ροή του αγώνα αλλά και σε περιόδους αυξημένης πίεσης.

4.1.2.1.1. Πειράματα μέγιστης ακρίβειας

Αναλυτικότερα, θα εξεταστεί το πρόγραμμα με τις ίδιες παραμέτρους για να συγκριθεί αργότερα η παρούσα υλοποίηση με τις προηγούμενες

1. θέση
2. ηλικία
3. ποσοστό αγώνων συμμετοχής
4. λεπτά συμμετοχής
5. λεπτά συμμετοχής στον χρόνο «clutch»
6. ποσοστό ευστοχίας σουτ FG% (Μ.Ο. σεζόν όχι χρόνοι «clutch»)
7. ποσοστό ευστοχίας στις βολές FT% (Μ.Ο. σεζόν όχι χρόνοι «clutch»)
8. λάθη TOV
9. Μ.Ο πόντοι ανά αγώνα (γενικά όχι χρόνοι «clutch»)

Και Έξοδος:

1. Πόντοι ανά ματς σε χρόνο «clutch»

Απαραίτητο να ειπωθεί, ότι οι είσοδοι που δίνονται στο πρόγραμμα είναι στατιστικά στο σύνολο της διάρκειας ενός αγώνα και όχι μόνο των τελευταίων κρίσιμων στιγμών και η έξοδος αφορά στον μέσο όρο σκοραρίσματος στον χρόνο «clutch».

Το πρόγραμμα παρακάτω ακολουθεί την ίδια δομή με το προηγούμενο όσον αφορά στην δομή. Ωστόσο λόγω της διαφορετικής φύσης κάποιων δεδομένων χρησιμοποιούνται διαφορετικές παράμετροι. Με άλλα λόγια το πρόγραμμα που αναπτύχθηκε σε προηγούμενη ενότητα χρησιμοποιήθηκε με κάποιες μικρές διαφορές για τους σκοπούς πρόβλεψης του νέου προγράμματος.

Αναλυτικότερα, παράμετροι πειραμάτων με τα καλύτερα αποτελέσματα περιλαμβάνουν:

Παράμετροι	ANN	RBF
Train-Test split	75% - 25%	80% - 20%
Κρυφά επίπεδα («hidden layers»)	3	3
Επαναλήψεις («epochs»)	300	300
Activation functions	Relu - Sigmoid	
Optimizers	SGD	SGD
Loss function	Mean squared error	Mean squared error

Πίνακας 22: Παράμετροι βέλτιστων πειραμάτων clutch

Όπως γίνεται αντιληπτό από τον παραπάνω πίνακα οι διαφορές με το προηγούμενο πρόγραμμα βρίσκονται:


- Αριθμό επαναλήψεων («epochs»): Έχουμε 300 αντί για 1000
- Train test splits: ANN 75%-25% αντί για 80%-20%
- Optimizer: RBF: SGD αντί για RMSprop

Όπως θα αποδειχθεί και στην συνέχεια οι συγκεκριμένοι παράμετροι επιλέχθηκαν καθώς σε οποιαδήποτε άλλη περίπτωση το δίκτυο παρουσίαζε μία αστάθεια κάτι το οποίο μαρτυρά την τάση του δικτύου προς την υπερ-εκπαίδευση και τις μη έγκυρες προβλέψεις.

Διαγράμματα καλύτερου πειράματος

Ακολουθούν τα διαγράμματα των πειραμάτων με τα καλύτερα αποτελέσματα:

- **Train: 75% - Test: 25% ANN Ακρίβεια προβλέψεων: 80.11%**



Εικόνα 35: ANN Train - Test loss (75%-25% train-test)

Pos	Name	Age	Actual PPG	NN Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.3126098]]	[[75.48073]]%
SF	Tracy McGrady	34	3	[[3.2254894]]	[[92.48369]]%
C	Jaren Jackson Jr.	23	1	[[0.92184335]]	[[92.18433]]%
PF	Tim Duncan	32	2.7	[[3.4349876]]	[[73.51898]]%
PF	John Collins	28	8.9	[[0.6841962]]	[[76.8218]]%
PG	Tony Parker	30	3.4	[[3.6884163]]	[[93.87811]]%
SG	Manu Ginobili	33	3	[[2.8237998]]	[[94.12666]]%
SF	Andre Iguodala	25	2.6	[[1.7912213]]	[[65.81621]]%
C	Javale McGee	31	1	[[0.7577745]]	[[75.77745]]%

Pos	Name	Age	FG% in clutch time	Actual PPG	ANN Prediction	Accuracy
SG	Bradley Beal	24	38.6%	2.8	[[2.6028922]]	[[92.968434]]%
PG	John Wall	22	28%	1.5	[[2.2886673]]	[[47.94218]]%
SF	Khris Middleton	31	27.3%	2.2	[[2.4361167]]	[[89.267426]]%
C	Nikola Jokic	27	31.4%	3.4	[[3.2678813]]	[[96.1118]]%
PF	Jaren Jackson Jr.	22	38.4%	1.4	[[1.4086179]]	[[92.955864]]%

The accuracy of the net is : [[80.11518]] %


Εικόνα 36: ANN Πειράματα (80%-20% train-test) και ακρίβεια

Pos	Name	Age	FG% in clutch time	Actual PPG	ANN Prediction	Accuracy
SG	Bradley Beal	24	38.6%	2.8	[[2.6028922]]	[[92.968434]]%
PG	John Wall	22	28%	1.5	[[2.2886673]]	[[47.94218]]%
SF	Khris Middleton	31	27.3%	2.2	[[2.4361167]]	[[89.267426]]%
C	Nikola Jokic	27	31.4%	3.4	[[3.2678813]]	[[96.1118]]%
PF	Jaren Jackson Jr.	22	38.4%	1.4	[[1.4086179]]	[[92.955864]]%

Εικόνα 37: ANN Πειράματα αθλητών με κακά ποσοστά στον χρόνο clutch αλλά υψηλούς Μ.Ο.

Πίνακας 23: Αποτελέσματα βέλτιστων πειραμάτων ANN clutch

- **Train: 80% - Test: 20% RBF-Ακρίβεια προβλέψεων: 80.82%**



Εικόνα 38: RBF Train - Test loss (80%-20% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.491112]]	[[85.74537]]%
SF	Tracy McGrady	24	3	[[2.4715543]]	[[82.38514]]%
C	Jaren Jackson Jr	23	1	[[1.2317746]]	[[76.82254]]%
PF	Tim Duncan	32	2.7	[[3.0467517]]	[[87.35734]]%
PF	John Collins	28	0.9	[[1.2966882]]	[[55.932415]]%
PG	Tony Parke	30	3.4	[[3.2422595]]	[[95.36857]]%
SG	Manu Ginobili	33	3	[[2.4633102]]	[[82.110344]]%
SF	Andre Iguodala	25	2.6	[[2.5281475]]	[[97.23644]]%
C	Javale McGee	31	1	[[1.2965884]]	[[70.341156]]%

Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	RBF Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.6604831]]	[[95.01726]]%
PG	John Wall	22	28%	1.5	[[2.01011]]	[[65.992676]]%
SG	Terry Rozier	29	28.4%	2.2	[[2.3983388]]	[[90.984604]]%
C	Karl Anthony Towns	27	26.7%	1.6	[[2.2042372]]	[[62.235176]]%
C	Nikola Jokic	27	31.4%	3.4	[[2.8524408]]	[[83.89532]]%

The accuracy of the net is : [[80.82421]] %

Εικόνα 39: RBF Πειράματα(80%-20% train-test) και ακρίβεια

Pos	Name	Age	FG% in clutch time	Actual PPG	RBF Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.6604831]]	[[95.01726]]%
PG	John Wall	22	28%	1.5	[[2.01011]]	[[65.992676]]%
SG	Terry Rozier	29	28.4%	2.2	[[2.3983388]]	[[90.984604]]%
C	Karl Anthony Towns	27	26.7%	1.6	[[2.2042372]]	[[62.235176]]%
C	Nikola Jokic	27	31.4%	3.4	[[2.8524408]]	[[83.89532]]%

Εικόνα 40: RBF Πειράματα αθλητών με κακά ποσοστά στον χρόνο clutch αλλά υψηλούς Μ.Ο.

Πίνακας 24: Αποτελέσματα βελτιστων πειραμάτων RBF clutch

Όπως φαίνεται και στις εικόνες παραπάνω και θα αποδειχθεί και στην συνέχεια τα συγκεκριμένα πειράματα έδωσαν την μέγιστη ακρίβεια σε συνδυασμό με την ελαχιστοποίηση του σφάλματος εκπαίδευσης («train loss») και ελέγχου («test loss»). Τα αποτελέσματα αυτά θα ήταν δυνατόν να αποδοθούν στον βελτιωτή («optimizer») ο οποίος είναι υπεύθυνος για την ενημέρωση των παραμέτρων του μοντέλου κατά τη διαδικασία εκπαίδευσης, με απώτερο σκοπό την ελαχιστοποίηση της συνάρτησης απώλειας. Η επιλογή του βελτιωτή έχει καθοριστικό ρόλο στην τελική απόδοση του μοντέλου, καθώς ο κάθε βελτιωτής έχει διαφορετικά πλεονεκτήματα και μειονεκτήματα. Όπως στην συγκεκριμένη περίπτωση φαίνεται ότι ο «SGD» αποτελεί την ιδανική λύση διότι αν και αργός στην σύγκλιση, επιτυγχάνει εξέχουσα ακρίβεια σε αντίθεση με τους άλλους όπως θα δούμε παρακάτω.

Επιπλέον, παρατηρείται ότι σε αντίθεση με το πρόγραμμα της προηγούμενης ενότητας ο αλγόριθμος RBF πετυχαίνει μεγαλύτερη ακρίβεια από ότι ο ANN και αυτό οφείλεται στην ικανότητα του συγκεκριμένου αλγορίθμου να εκπαιδευθεί με πιο πολύπλοκα πρότυπα καθώς είναι προφανές ότι η λογική του παρόντος προγράμματος είναι εμφανώς πιο πολύπλοκη.


4.1.2.1.2. Πρόσθετα πειράματα

Σκοπός της ενότητας αυτής είναι η απόδειξη του ισχυρισμού ότι με τις παραπάνω επιλεγμένες παραμέτρους πάρθηκαν τα καλύτερα αποτελέσματα.

4.1.2.1.2.1. Πειράματα με διαφορετικά train-test splits

Παρακάτω ακολουθούν περισσότερα πειράματα όσον αφορά στον διαχωρισμό δειγμάτων εκπαίδευσης - ελέγχου. Όπως φαίνεται η μόνη ενδιαφέρουσα περίπτωση που υπάρχουν ελαφρώς χειρότερα αποτελέσματα είναι στην περίπτωση του αλγορίθμου ANN στο διαχωρισμό 60% - 40% «train – test split».

- **Train: 70% Test: 30% ANN Ακρίβεια προβλέψεων: 77.28%**



Εικόνα 41: ANN Train loss- Test loss (70%-30% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.0472004]]	[[60.21854]]%
SF	Tracy McGrady	24	3	[[3.5738215]]	[[80.87261]]%
C	Jaren Jackson Jr	23	1	[[1.3204439]]	[[67.95561]]%
PF	Tim Duncan	32	2.7	[[2.2368429]]	[[82.84603]]%
PF	John Collins	28	0.9	[[0.72925514]]	[[81.82835]]%
PG	Tony Parke	30	3.4	[[3.5188007]]	[[96.50587]]%
SG	Manu Ginobili	33	3	[[2.482371]]	[[80.07903]]%
SF	Andre Igoudala	25	2.6	[[2.0388832]]	[[78.41859]]%
C	Javale McGee	31	1	[[0.71654224]]	[[71.65422]]%


Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	ANN Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[3.055753]]	[[90.80597]]%
PG	John Wall	22	28%	1.5	[[2.291813]]	[[47.212475]]%
C	Nikola Jokic	27	31.4%	3.4	[[3.1356135]]	[[92.22451]]%

The accuracy of the net is : [[77.28686]] %

Εικόνα 42: ANN Πειράματα (70%-30% train-test)

- **Train: 70% Test: 30% - RBF - Ακρίβεια προβλέψεων: 77.13%**



Εικόνα 43: RBF Train loss- Test loss (70%-30% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.5458721]]	[[88.89432]]%
SF	Tracy McGrady	24	3	[[2.5561745]]	[[85.28582]]%
C	Jaren Jackson Jr	23	1	[[1.2770046]]	[[72.29954]]%
PF	Tim Duncan	32	2.7	[[3.159014]]	[[82.99948]]%
PF	John Collins	28	0.9	[[3.3442286]]	[[50.642147]]%
PG	Tony Parke	30	3.4	[[3.3606834]]	[[98.84363]]%
SG	Manu Ginobili	33	3	[[2.5550134]]	[[85.167114]]%
SF	Andre Igoudala	25	2.6	[[2.618393]]	[[99.29257]]%
C	Javale McGee	31	1	[[1.3436639]]	[[65.633606]]%


Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	RBF Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.7537441]]	[[98.34801]]%
PG	John Wall	22	28%	1.5	[[2.0809999]]	[[61.266678]]%
C	Nikola Jokic	27	31.4%	3.4	[[2.9571424]]	[[86.97477]]%

The accuracy of the net is : [[77.13993]] %

Εικόνα 44: RBF Πειράματα (70%-30% train-test)

- **Train: 90% Test: 10% - ANN - Ακρίβεια προβλέψεων: 78.01%**



Εικόνα 45: ANN Train loss- Test loss (90%-10% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.8161452]]	[[58.43273]]%
SF	Tracy McGrady	24	3	[[3.4249542]]	[[85.83486]]%
C	Jaren Jackson Jr	23	1	[[0.76563376]]	[[76.56338]]%
PF	Tim Duncan	32	2.7	[[2.2932494]]	[[84.93516]]%
PF	John Collins	28	0.9	[[0.52673244]]	[[58.52583]]%
PG	Tony Parke	30	3.4	[[4.185132]]	[[79.268826]]%
SG	Manu Ginobili	33	3	[[3.191488]]	[[93.619736]]%
SF	Andre Igoudala	25	2.6	[[2.8848316]]	[[77.18891]]%
C	Javale McGee	31	1	[[0.47807275]]	[[47.807275]]%


Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	ANN Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.755217]]	[[98.48849]]%
PG	John Wall	22	28%	1.5	[[2.2424538]]	[[58.58388]]%
C	Nikola Jokic	27	31.4%	3.4	[[3.9158765]]	[[84.85869]]%

The accuracy of the net is : [[78.81281]] %

Εικόνα 46: ANN Πειράματα (90%-10% train-test)

- **Train: 90% Test: 10% - RBF - Ακρίβεια προβλέψεων: 77.26%**



Εικόνα 47: RBF Train loss- Test loss (90%-10% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.5299194]]	[[87.97697]]%
SF	Tracy McGrady	24	3	[[2.5272837]]	[[84.243126]]%
C	Jaren Jackson Jr	23	1	[[1.2618259]]	[[73.61741]]%
PF	Tim Duncan	32	2.7	[[3.1264482]]	[[84.28563]]%
PF	John Collins	28	0.9	[[1.3303415]]	[[52.184277]]%
PG	Tony Parke	30	3.4	[[3.20154]]	[[97.82886]]%
SG	Manu Ginobili	33	3	[[2.5278585]]	[[84.26195]]%
SF	Andre Igoudala	25	2.6	[[2.5958263]]	[[99.88871]]%
C	Javale McGee	31	1	[[1.3303488]]	[[56.90596]]%


Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	RBF Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.7287818]]	[[97.453636]]%
PG	John Wall	22	28%	1.5	[[2.8617967]]	[[62.54689]]%
C	Nikola Jokic	27	31.4%	3.4	[[2.926829]]	[[86.483286]]%

The accuracy of the net is : [[77.26621]] %

Εικόνα 48: RBF Πειράματα (90%-10% train-test) και ακρίβεια

- **Train: 60% Test: 40% - ANN - Ακρίβεια προβλέψεων: 79.17%**



Εικόνα 49: ANN Train loss- Test loss (60%-40% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Oladipo	30	1.739	[[1.3948635]]	[[80.438155]]%
SF	Tracy McGrady	24	3	[[3.3896618]]	[[87.43128]]%
C	Jaren Jackson Jr	23	1	[[0.9885731]]	[[98.85711]]%
PF	Tim Duncan	32	2.7	[[2.4238654]]	[[97.18822]]%
PF	John Collins	28	0.9	[[1.4565199]]	[[82.6089]]%
PG	Tony Parke	30	3.4	[[3.9897325]]	[[82.6545]]%
SG	Manu Ginobili	33	3	[[3.4085379]]	[[99.58287]]%
SF	Andre Igoudala	25	2.6	[[2.1078234]]	[[84.5888]]%
C	Javale McGee	31	1	[[0.44178257]]	[[64.178257]]%


Players with high PPG but poor performance in clutch time

Pos	Name	Age	FG% in clutch time	Actual PPG	ANN Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[3.3227348]]	[[84.338866]]%
PG	John Wall	22	28%	1.5	[[2.3823711]]	[[41.175274]]%
C	Nikola Jokic	27	31.4%	3.4	[[3.4688864]]	[[97.97393]]%

The accuracy of the net is : [[79.17634]] %

Εικόνα 50: ANN Πειράματα (60%-40% train-test) και ακρίβεια

- **Train: 60% Test: 40% - RBF - Ακρίβεια προβλέψεων: 77.16%**



Εικόνα 51: RBF Train loss- Test loss (60%-40% train-test)

Pos	Name	Age	Actual PPG	RBF Prediction	Accuracy
SG	Victor Glasipo	38	1.739	[[1.5392581]]	[[89.513985]]%
SF	Tracy McGrady	24	3	[[2.5438892]]	[[84.79364]]%
C	Jaren Jackson Jr	23	1	[[1.2715684]]	[[72.843956]]%
PF	Tim Duncan	32	2.7	[[3.1454113]]	[[83.56255]]%
PF	John Collins	28	8.9	[[1.3384852]]	[[51.279415]]%
PG	Tony Parker	38	3.4	[[3.3461818]]	[[98.41476]]%
SG	Manu Ginobili	33	3	[[2.5431218]]	[[84.77871]]%
SF	Andre Iguodala	25	2.6	[[2.618881]]	[[99.61227]]%
C	Javale McGee	31	1	[[1.3183633]]	[[66.163666]]%

Pos	Name	Age	FG% in clutch time	Actual PPG	RBF Prediction	Accuracy
SG	Bradley Beal	24	30.6%	2.8	[[2.7441933]]	[[98.886095]]%
PG	John Wall	22	28%	1.5	[[2.074671]]	[[61.6886]]%
C	Nikola Jokic	27	31.4%	3.4	[[2.9446177]]	[[86.4864]]%

The accuracy of the net is: [[77.16563]]%

Εικόνα 52: RBF Πειράματα (60%-40% train-test) και ακρίβεια

Πίνακας 25: Περαιτέρω πειράματα clutch

Εάν εξαιρεθεί ο διαχωρισμός 60% - 40% στα δεδομένα εκπαίδευσης - επαλήθευσης («train-test splits») σε όλες τις άλλες περιπτώσεις φαίνεται στα διαγράμματα μία αστάθεια ανάμεσα στα σφάλματα εκπαίδευσης - επαλήθευσης που πιθανότατα οφείλεται στην υπερ-προσαρμογή του αλγορίθμου πάνω στα δείγματα εκπαίδευσης που συνεπάγεται με αδυναμία ορθής πρόβλεψης σε νέα πειράματα.

Επιπλέον, κρίνοντας από το αποτέλεσμα του αλγορίθμου ANN στην περίπτωση 60% - 40% στα δεδομένα εκπαίδευσης - επαλήθευσης («train-test splits») φαίνεται η ικανότητα του αλγορίθμου να προσαρμοστεί σε μικρότερο αριθμό δειγμάτων έχοντας ταυτοχρόνως μία εξέχουσα ακρίβεια αποτελεσμάτων.

4.1.2.1.2.2. Πειράματα με διαφορετικό αριθμό «epochs»

Όπως φαίνεται και παρακάτω, παρόλο που στο προηγούμενο πρόγραμμα κρίθηκε απαραίτητη η επιλογή των 1000 εποχών, στην περίπτωση αυτή κρίθηκε ότι επιλογή των 300 «epochs» είναι αρκετή για την εκπαίδευση του δικτύου. Επιπλέον, είναι σημαντικό να τονίσουμε ότι η βάση δεδομένων του συγκεκριμένου προγράμματος είναι μικρότερη σε σχέση με προηγούμενους (καθώς δεν αγωνίζεται οποιοσδήποτε αθλητής στις κρίσιμες στιγμές), επομένως είναι λογικό η εκπαίδευση του δικτύου να απαιτεί και λιγότερες εποχές. Ακόμη, διαπιστώθηκε ότι η αύξηση του αριθμού των εποχών σε 1000 και πάνω δεν οδήγησε σε καμία απολύτως βελτίωση της απόδοσης του μοντέλου. Επιπλέον, παρατηρήθηκε τάση προς υπερ-εκπαίδευση («overfitting») όσο αυξανόταν ο αριθμός των εποχών.

Ακολουθεί συγκριτικός πίνακας για τα δυο είδη των ΤΝΔ:

Τεχνητό νευρωνικό δίκτυο με ANN

Epochs	Χρόνος εκτέλεσης	loss	Ακρίβεια
100	4.37 δευτ.	0.0317	75.31%
300	14.6 δευτ.	0.0274	80.11 %
1000	49.4 δευτ.	0.0200	77.93%
10000	9 λ. 8 δευτ.	0.0101	78.60%

Πίνακας 26: Αποτελέσματα ANN με διαφορετικό αριθμό epochs

Τεχνητό νευρωνικό δίκτυο με RBF

Epochs	Χρόνος εκτέλεσης	loss	Ακρίβεια
100	7.59 δευτ.	0.0787	77.39%
300	19.5 δευτ.	0.0790	80.82%
1000	1 λ.	0.0789	77.37%
10000	10 λ. 17 δευτ.	0.0227	81.43%

Πίνακας 27: Αποτελέσματα RBF με διαφορετικό αριθμό epochs

4.1.2.1.2.3. Πειράματα με περισσότερες Loss functions

Τα αποτελέσματα των πειραμάτων παραπάνω επιβεβαιώνουν την αποτελεσματικότητα του συνδυασμού «SGD» και «MSE» όχι μόνο στην περίπτωση του αλγόριθμου ANN αλλά και στον RBF καθώς και οι δύο υλοποιήσεις πέτυχαν τον καλύτερο συνδυασμό χαμηλής τιμής απώλειας («loss value») και υψηλής ακρίβειας. Αυτό υποδηλώνει ότι τα δίκτυα κατάφεραν να μάθουν τα πρότυπα στα δεδομένα και ταυτοχρόνως να κάνουν προβλέψεις με ακρίβεια.

Optimizer ANN	Optimizer RBF	Loss function	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
SGD	SGD	Mean Squared Error	0.0274	0.079	80.11 %	80.82%
SGD	RMSprop	Mean Squared Error	0.0274	0.0268	80.11 %	79.03%
SGD	RMSprop	Mean Absolute Error	0.1134	0.1165	75.72%	75.4%
SGD	SGD	Mean Squared Logarithmic Error	0.0076	0.0282 σταθερό	73.69%	74.5%

Πίνακας 28: Πειράματα με διαφορετικές loss functions

Επιπλέον, πραγματοποιήθηκαν πειράματα και με άλλες συναρτήσεις απώλειας, όπως «Mean Absolute Error» και «Mean Squared Logarithmic Error» αλλά και με άλλους βελτιστοποιητές («optimizers»), όπως ο «RMSprop», αλλά διαπιστώθηκε και πάλι ότι ο συνδυασμός «SGD» και «MSE» πέτυχαν τα καλύτερα αποτελέσματα από τους άλλους συνδυασμούς.

4.1.2.1.2.4. Διαφορετική επιλογή κρυφών επιπέδων

Κρυφά επίπεδα	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
3	0.0274	0.079	80.11 %	80.82%
5	0.0238	0.0789	75.45%	80.76%
10	0.0766	0.0791	78.53%	79.77%
15	0.0814	0.0790	77.42%	79.64%

Πίνακας 29: Πειράματα με διαφορετικό αριθμό κρυφών επιπέδων

Όπως φαίνεται και στον παραπάνω πίνακα έπειτα από τη διεξαγωγή διαφορετικών πειραμάτων προκειμένου να βρεθεί η ιδανική ισορροπία μεταξύ αριθμού κρυφών επιπέδων και αποτελεσματικότητας του δικτύου έγινε φανερό ότι η χρήση τριών κρυφών επιπέδων είναι η βέλτιστη επιλογή.

Η περαιτέρω αύξηση σε κάθε περίπτωση είχε ως αποτέλεσμα την μείωση ακρίβειας αλλά και της αύξησης της συνάρτησης σφάλματος κάτι το οποίο είναι ανεπιθύμητο.

Συνεπώς, συνιστάται η χρήση τριών κρυφών επιπέδων στο παρόν μοντέλο του νευρωνικού δικτύου, καθώς επιτυγχάνεται η ιδανική ισορροπία μεταξύ της πολυπλοκότητας του μοντέλου και της πρόβλεψης απόδοσης στον χρόνο αυξημένης πίεσης.

4.1.2.1.2.5. Διαφορετική επιλογή συναρτήσεων ενεργοποίησης

Όπως τονίστηκε και σε προηγούμενη ενότητα εξετάζεται μόνο ο αλγόριθμος ANN σε πειράματα με διαφορετικές συναρτήσεις ενεργοποίησης καθώς στον αλγόριθμο RBF δεν απαιτείται χρήση τους λόγω της φύσης του αλγορίθμου.

Activation functions	Loss	Accuracy
Relu-sigmoid	0.0274	80.11 %
elu-sigmoid	0.0267	75.48%
elu-softmax	σταθερό	-
Relu-softmax	σταθερό	-
Relu-softsign	0.0283	74.69%
Relu-tanh	0.0282	78.85%
Relu-Relu	0.0173	68.52%

Πίνακας 30: Πειράματα διαφορετικών συναρτήσεων ενεργοποίησης

Ειδικότερα, στον αλγόριθμο ANN βασιζόμενοι στην πλειάδα πειραμάτων που διενεργήθηκαν όσον αφορά στις διαφορετικές συναρτήσεις ενεργοποίησης προέκυψε ότι η συνδυασμένη χρήση της συνάρτησης ενεργοποίησης «Relu» στα κρυφά επίπεδα και της συνάρτησης ενεργοποίησης «sigmoid» στο επίπεδο εξόδου έχει επιτύχει την μέγιστη ακρίβεια 80.11% με απώλεια («loss») 0.0274.

Για να καταλήξουμε στο παραπάνω συμπέρασμα πρέπει να συμπεριληφθούν αρκετοί παράγοντες όπως του τύπου των δεδομένων, του τύπου της εισόδου και της εξόδου και των τιμών που έχουν μετρηθεί για τα αποτελέσματα απώλειας και ακρίβειας.

Για αυτό είναι ανάγκη να σημειωθεί, ότι το σύνολο δεδομένων αποτελείται και πάλι από αριθμητικά δεδομένα. Πρέπει να ληφθεί υπόψιν ότι στην περίπτωση αυτή εκφράζεται μη γραμμικότητα, για αυτό τον λόγο καταλήγουμε στην συνάρτηση «Relu» καθώς έχει την δυνατότητα μοντελοποίησης αποτελεσματικά των μη γραμμικών σχέσεων. Επιπροσθέτως, εφόσον δεν τίθεται θέμα επεξεργασίας αρνητικών τιμών η σιγμοειδής («sigmoid») αποτελεί μία καλή επιλογή για το επίπεδο εξόδου.

Τα υπόλοιπα πειράματα αποδεικνύουν στην πράξη τους παραπάνω ισχυρισμούς και όπως γίνεται αντιληπτό δεν υπάρχει άλλος συνδυασμός ο οποίος θα ήταν καλό να ληφθεί υπόψιν καθώς είτε δεν ταιριάζει με την φύση των δεδομένων, είτε με τη λογική του προγράμματος είτε δεν πετυχαίνει αξιόλογα αποτελέσματα.

4.1.2.1.2.6. Διαφορετική επιλογή εισόδων

Όπως φαίνεται και παρακάτω, όσον αφορά στον αλγόριθμο ANN, η επιλογή εισόδων που έχει επιλεγεί σύμφωνα με τον παρακάτω πίνακα αποτελεί την βέλτιστη καθώς με μείωση των εισόδων μειώνεται αρκετά η ακρίβεια και αυξάνεται η τιμή της απώλειας ελαφρώς. Ωστόσο, παρατηρείται ότι εάν παραλειφθεί η είσοδος αναφορικά με τους τραυματισμούς ενός αθλητή η τιμή της απώλειας αυξάνεται ελαφρώς και η ακρίβεια του προγράμματος πλησιάζει την μέγιστη της τιμή που. Το συγκεκριμένο γεγονός ενδεχομένως να οφείλεται στο ότι οι παράγοντες που επηρεάζουν την απόδοση ενός αθλητή στα τελευταία και κρίσιμα λεπτά εξαρτάται από άλλους παράγοντες περισσότερο όπως είναι η γενικότερη ευστοχία.

Όσον αφορά στον αλγόριθμο RBF παρατηρείται ότι εάν παραλειφθεί κάποια είσοδος υπάρχει μία στασιμότητα στην εκπαίδευση και την ορθή πρόβλεψη των αποτελεσμάτων. Δείγμα το οποίο μαρτυρά το γεγονός της υπερ-εκπαίδευσης και προσαρμογής εξ' ολοκλήρου στα συγκεκριμένα δεδομένα και όχι σε νέα.

Είσοδοι	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
Χωρίς θέση	0.0309	0.0791	72.66%	71.25%
Χωρίς θέση και TOV (λάθη)	0.0365	0.0784	77.03%	76.74%
Χωρίς FT%	0.0452	0.0789	76.67%	75.56%
Χωρίς τραυματισμούς	0.0386	0.0787	79.43%	73.25%

Πίνακας 31: Πειράματα διαφορετικής επιλογής εισόδου

Φυσικά, ανάμεσα σε όλα δεν πρέπει να ξεχνάμε και τον ανθρώπινο παράγοντα ο οποίος δεν είναι δυνατόν να αποτυπωθεί σε αριθμούς. Με άλλα λόγια ο κάθε άνθρωπος λειτουργεί διαφορετικά σε συνθήκες πίεσης, ένας αγώνας NBA ενδέχεται να κρίνει την είσοδο μίας ομάδας στα «playoffs» κάτι το οποίο για κάποιους θα είναι μία από τις πιο αγχωτικές καταστάσεις για έναν αθλητή. Όλα αυτά δεν είναι δυνατόν να αποτυπωθούν σε αριθμούς.

4.1.2.2. Υλοποίηση σε MATLAB

Στην ενότητα αυτή, θα μελετηθεί η υλοποίηση του προγράμματος πρόβλεψης απόδοσης πόντων αθλητών NBA στην περίοδο «clutch», ή με άλλα λόγια στην περίοδο αυξημένης πίεσης με τη βοήθεια του εργαλείου της MATLAB. Το παρακάτω πρόγραμμα υλοποιήθηκε σύμφωνα με τον αλγόριθμο ΤΝΔ. Θα πραγματοποιηθεί εκπαίδευση με τις ίδιες εισόδους όπως και πριν και ταυτοχρόνως θα γίνει χρήση παρόμοιων παραμέτρων. Όπως προηγουμένως, για την υλοποίηση του προγράμματος χρησιμοποιήθηκε το «Neural Network Toolbox» από την MATLAB.

Αντικείμενο του κεφαλαίου είναι να αποδειχθεί εάν η MATLAB στην συγκεκριμένη λογική του προγράμματος έχει καλύτερη ή χειρότερη απόδοση και κατά πόσο θα ήταν ιδανικό να βασιστούμε στην συγκεκριμένη εφαρμογή.

4.1.2.2.1. Πείραμα μέγιστης ακρίβειας


Γίνεται χρήση των εισόδων όπως και στην υλοποίηση της PYTHON

1. θέση
2. ηλικία
3. ποσοστό αγώνων συμμετοχής
4. λεπτά συμμετοχής
5. λεπτά συμμετοχής στον χρόνο «clutch»
6. ποσοστό ευστοχίας σουτ FG% (Μ.Ο. σεζόν όχι χρόνοι «clutch»)
7. ποσοστό ευστοχίας στις βολές FT% (Μ.Ο. σεζόν όχι χρόνοι «clutch»)
8. λάθη TOV
9. Μ.Ο πόντοι ανά αγώνα (γενικά όχι χρόνοι «clutch»)

Και Έξοδος

1. Πόντοι ανά ματς σε χρόνο «clutch»

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	0.85119	1 δευτ.	74.78 %
Mean Absolute Error (MAE)	0.81139	1 δευτ.	74.78 %
Root Mean Squared Error (RMSE)	0.9226	1 δευτ.	74.78 %



Εικόνα 53: πειράματα μέγιστης ακρίβειας MATLAB

Όπως φαίνεται στις παραπάνω εικόνες το πρόγραμμα του αλγόριθμου ANN στην MATLAB επιτυγχάνει 74.78% ακρίβεια προβλέψεων με τις ίδιες παραμέτρους που χρησιμοποιήθηκαν και στην γλώσσα PYTHON ενώ ταυτόχρονα τερματίζει με σφάλμα εκπαίδευσης 0.85119 με συνάρτηση ενεργοποίησης την «MSE» και υψηλή ακρίβεια στις προβλέψεις του. Παρόμοια, φαίνεται και σε άλλες συναρτήσεις όπως οι «Mean Absolute Error» και «Root Mean Squared Error» το σφάλμα εκπαίδευσης κινείται και αυτό σε χαμηλά επίπεδα. Όπως αναγράφεται και πάνω και στο διάγραμμα το πρόγραμμα σταματάει έπειτα από 16 εποχές («epochs») καθώς επιτυγχάνει την ελάχιστη τιμή σφάλματος.

Είναι σημαντικό να σημειωθεί ότι το νευρωνικό δίκτυο σταμάτησε την εκπαίδευση του στον συγκεκριμένο αριθμό εποχών, προκειμένου να αποφευχθεί ο κίνδυνος υπερ-εκπαίδευσης των δεδομένων. Θεωρείται λογικό αν αναλογιστεί κανείς ότι το γεγονός αυτό συμβαίνει όταν το μοντέλο μαθαίνει τον θόρυβο στα δεδομένα εκπαίδευσης αντί του υποκείμενου μοτίβου, με άλλα λόγια, τον σκοπό του εκάστοτε μοντέλου.

Για να αποτραπεί ο κίνδυνος υπερ-εκπαίδευσης εφαρμόζονται τεχνικές κανονικοποίησης όπως η πρόωρη διακοπή («early stopping»), ή το λεγόμενο «dropout» ή η κανονικοποίηση L2. Στην παραπάνω περίπτωση εφαρμόστηκε η πρόωρη διακοπή. Η πρόωρη διακοπή παρακολουθεί την απόδοση του δικτύου σε ένα σύνολο επαληθεύσεων και σταματά τη διαδικασία εκπαίδευσης όταν η απόδοση του

δικτύου αρχίζει να υποχωρεί. Έπειτα από αυτήν την εκπαίδευση από 16 εποχές, το νευρωνικό δίκτυο πέτυχε μια καλή ισορροπία μεταξύ της προσαρμογής στα δεδομένα εκπαίδευσης και της γενίκευσης σε νέα, άγνωστα δεδομένα.

4.1.2.2.2. Πρόσθετα Πειράματα


Στις επόμενες παραγράφους, διεξάγονται πειράματα για την απόδειξη του ισχυρισμού ότι τα παραπάνω ήταν τα πειράματα με τα βέλτιστα αποτελέσματα.

4.1.2.2.2.1. Πειράματα με διαφορετικά train-test splits

Παρακάτω φαίνονται περαιτέρω πειράματα όσον αφορά στον διαχωρισμό δειγμάτων εκπαίδευσης – ελέγχου («train-test splits»). Όπως φαίνεται η μόνη ενδιαφέρουσα περίπτωση που πέτυχε αξιόλογη ακρίβεια το ANN στο διαχωρισμό 90% - 10% «train – test split».

- **Train: 90% Test: 10% ANN Ακρίβεια προβλέψεων: 76.34%**


Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	0.43253	1 δευτ.	76.34%
Mean Absolute Error (MAE)	0.5487	1 δευτ.	76.34%
Root Mean Squared Error (RMSE)	0.65767	1 δευτ.	76.34%



Εικόνα 54: MATLAB 90%-10% train - test split

- **Train: 75% Test: 25% ANN Ακρίβεια προβλέψεων: 62.68%**


Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	0.77715	1 δευτ.	62.68%
Mean Absolute Error (MAE)	0.66245	1 δευτ.	62.68%
Root Mean Squared Error (RMSE)	0.88156	1 δευτ.	62.68%



Εικόνα 55: MATLAB 75%-25% train - test split

- **Train: 70% Test: 30% ANN Ακρίβεια προβλέψεων:71.33%**


Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	0.81773	1 δευτ.	71.33%
Mean Absolute Error (MAE)	0.6634	1 δευτ.	71.33%
Root Mean Squared Error (RMSE)	0.90429	1 δευτ.	71.33%



Εικόνα 56: MATLAB 70%-30% train - test split

- **Train: 60% Test: 40% ANN Ακρίβεια προβλέψεων: 67.31%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	1.3286	1 δευτ.	67.31%
Mean Absolute Error (MAE)	0.91284	1 δευτ.	67.31%
Root Mean Squared Error (RMSE)	1.1527	1 δευτ.	67.31%



Εικόνα 57: MATLAB 60%-40% train - test split

Πίνακας 32: Περαιτέρω πειράματα train-test splits

Σύμφωνα με τα παραπάνω είναι δυνατόν να συμπεράνει κανείς ότι σε οποιαδήποτε περίπτωση υπάρχει πτώση ακρίβειας εκτός της περίπτωσης διαχωρισμού των δειγμάτων σε 90%-10% σε «train-test split». Στην προκειμένη περίπτωση είναι απαραίτητο η βάση δεδομένων που θα χρησιμοποιηθεί να έχει τον απαραίτητο αριθμό δειγμάτων καθώς όπως γίνεται εύκολα αντιληπτό απαιτεί έναν σχετικά μεγάλο αριθμό δειγμάτων. Πιο συγκεκριμένα, όσο πιο πολύπλοκο είναι το πρόβλημα που προσπαθούμε να λύσουμε τόσο πιο μεγάλος αριθμός δειγμάτων απαιτείται. Στο παρόν πείραμα είναι λογικό, να απαιτούνται αρκετά δείγματα για την εκπαίδευση του μοντέλου καθώς γίνεται προσπάθεια πρόβλεψης απόδοσης για συγκεκριμένες στιγμές ενός αγώνα βασίζόμενοι μόνο σε στατιστικά κανονικής διάρκειας και όχι συμπεριλαμβάνοντας άλλους παράγοντες όπως την ψυχολογία του αθλητή, το χαρακτήρα του και τις συνθήκες διεξαγωγής αγώνα.

4.1.2.2.2. Διαφορετική επιλογή κρυφών επιπέδων

Ύστερα από την διενέργεια ποικίλων πειραμάτων όπου ελέγχθηκε η αποτελεσματικότητα διαφορετικών αριθμών κρυφών επιπέδων, διαπιστώθηκε ότι η χρήση τριών κρυφών στρωμάτων αποτελεί την βέλτιστη επιλογή. Ο πίνακας παραπάνω φανερώνει ότι στα αποτελέσματα των δοκιμών η αύξηση του αριθμού των κρυφών επιπέδων πέραν των τριών δεν επέφερε καμία απολύτως βελτίωση στην απόδοση του προγράμματος. Αντιθέτως, η αύξηση αυτή συνεπάγεται την αύξηση της συνάρτησης απώλειας σε κάποιες περιπτώσεις, και την ταυτόχρονη μείωση της ακρίβειας του μοντέλου.

Κρυφά επίπεδα	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
3	0.85119	0.81139	0.9226	74.78%
5	0.50104	0.60243	0.70784	71.87%
10	1.4079	0.84139	1.1865	64.89%
15	1.3009	0.91136	1.1406	71.94%

Πίνακας 33: Διαφορετική επιλογή αριθμού κρυφών επιπέδων

Συνεπώς, προτιμάται η χρήση των τριών κρυφών επιπέδων στο τρέχον μοντέλο νευρωνικού δικτύου, καθώς αυτός ο αριθμός επιτυγχάνει τον βέλτιστο συνδυασμό πολυπλοκότητας του μοντέλου και της ακρίβειας πρόβλεψης στο κομμάτι πρόβλεψης επίδοσης των καλαθοσφαιριστών στο NBA στις κρίσιμες στιγμές ενός αγώνα.

4.1.2.2.2.3. Διαφορετική επιλογή εισόδων

Όπως φαίνεται στον παρακάτω πίνακα όπου δοκιμάστηκε η επίδραση διαφορετικού αριθμού εισόδων όσον αφορά στην εγκυρότητα του παρόντος μοντέλου νευρωνικού δικτύου, αποδεικνύεται ότι η χρήση του τρέχοντος συνδυασμού μεταβλητών εισόδου αποτελεί την βέλτιστη επιλογή. Τα πειράματά μας, δείχνουν ότι η αφαίρεση μεταβλητών εισόδου όχι μόνο δεν οδήγησε σε βελτίωση στην απόδοση του προγράμματος παρά μόνο σε χειροτέρευση.

Είσοδοι	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
	0.85119	0.81139	0.9226	74.78 %
Χωρίς θέση	0.96854	0.69715	0.98415	62.63%
Χωρίς θέση και TOV (λάθη)	0.69559	0.7007	0.83402	58.7%
Χωρίς FT%	0.58951	0.54001	0.7678	65.84%
Χωρίς τραυματισμούς	0.76833	0.61836	0.87654	60.5652%

Πίνακας 34: Διαφορετική επιλογή εισόδων

Συνολικά, δεν προτείνεται η αφαίρεση κάποιας εισόδου, διότι το πρόγραμμα από μόνο του κρύβει μια πολύπλοκη λογική, καθώς γίνεται πρόβλεψη απόδοσης σε πόντους συμπεριλαμβάνοντας μόνο αριθμούς και όχι άλλους παράγοντες όπως την ψυχολογία του εκάστοτε αθλητή.

4.1.2.3. Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων PYTHON - MATLAB

Σκοπός της παρακάτω ενότητας είναι η σύγκριση των υλοποιήσεων του προγράμματος πρόβλεψης αθλητών NBA στον λεγόμενο χρόνο «clutch».

Συγκεντρωτικοί πίνακες μεταξύ των βέλτιστων υλοποιήσεων ακολουθούν:

Ακρίβεια ANN (PYTHON)	ANN (PYTHON) train-test splits	ANN loss	Ακρίβεια RBF (PYTHON)	RBF (PYTHON) train-test splits	RBF loss	Ακρίβεια ANN MATLAB	MATLAB train-test splits	MATLAB loss (MSE) (MAE) (RMSE)
80.11 %	75% - 25%	0.0274	80.82%	80%-20%	0.0790	74.78%	80%-20%	0.85119 0.81139 0.9226

Πίνακας 35: Συγκεντρωτικά αποτελέσματα μεταξύ υλοποιήσεων

Όσο για τους χρόνους υλοποίησης για τα βέλτιστα αποτελέσματα, φαίνονται στον ακόλουθο πίνακα:

Χρόνος εκτέλεσης ANN (PYTHON)	ANN (PYTHON) epochs	Χρόνος εκτέλεσης RBF (PYTHON)	RBF (PYTHON) epochs	Χρόνος εκτέλεσης ANN MATLAB	MATLAB epochs
14.6 δευτ.	300	19.5 δευτ.	300	1 δευτ.	20

Πίνακας 36: Χρόνος εκτελέσεων μεταξύ υλοποιήσεων

Τα αποτελέσματα όπως φαίνονται και στους πίνακες παραπάνω αποδεικνύουν ότι ο αλγόριθμος της ροδιακής συνάρτησης βάσης (RBF) που υλοποιήθηκε σε PYTHON έστω και ελαφρώς ξεπέρασε τον αλγόριθμο ANN και την υλοποίηση του σε MATLAB ως προς την ακρίβεια των προβλέψεων. Η ακρίβεια είναι δυνατόν να αποδοθεί στην ικανότητά του να μάθει ότι επιτεύχθηκε ο ιδανικός συνδυασμός δεδομένων, συναρτήσεων και χωρισμού δεδομένων. Σημαντικό να σημειωθεί ότι σε αντίθεση με όλα τα προηγούμενα προγράμματα δεν επιτεύχθηκε αξιοσημείωτη ακρίβεια και σε μικρότερο όγκο δεδομένων εκπαίδευσης-επαλήθευσης κάτι το οποίο είναι λογικό αν αναλογιστούμε την πολυπλοκότητα του προβλήματος.

Παρόλο που οι αλγόριθμοι που υλοποιήθηκαν σε PYTHON ήταν οι πιο ακριβείς, αξίζει να σημειωθεί ότι η υλοποίηση σε MATLAB ήταν η ταχύτερη από όλες. Επομένως, αν η ταχύτητα αποτελεί το κριτήριο επιλογής στην διαδικασία πρόβλεψης, η συγκεκριμένη υλοποίηση ενδείκνυται ως η ιδανική επιλογή.

Συμπερασματικά, μία ακρίβεια της τάξης 75%-80% αποτελεί μια εξαιρετική ένδειξη ότι είναι δυνατή η πρόβλεψη των αθλητών καλαθοσφαίρισης του NBA και στις τελευταίες χρονικές στιγμές όπου κρίνεται το αποτέλεσμα ενός αγώνα. Οι σχετικές ενδείξεις των προγραμμάτων που υλοποιήθηκαν αποτελούν εξαιρετικά όπλα για αθλητικούς οργανισμούς καθώς γνωρίζοντας στατιστικά κανονικής διάρκειας ενός αθλητή θα είναι σε θέση να προβλέψουν την επίδραση του κάθε αθλητή στην εκάστοτε ομάδα. Ανάμεσα σε όλα αυτά, δεν πρέπει να παραλειφθούν και εξωτερικοί παράγοντες λόγω χάρη ο ανθρώπινος καθώς εξαιτίας άγχους, πίεσης ένας αθλητής ο οποίος *ενώ είναι* αρκετά παραγωγικός ενδέχεται να μην είναι το ίδιο παραγωγικός και στα τελευταία λεπτά ενός αγώνα.

4.1.3. Πρόβλεψη απόδοσης κανονικής περιόδου WNBA

Το τελευταίο πρόγραμμα που θα αναλυθεί αφορά στην πρόβλεψη απόδοσης καλαθοσφαιριστριών στο Αμερικάνικο πρωτάθλημα καλαθοσφαίρισης γυναικών ή αλλιώς WNBA.

Ειδικότερα, θα αποδειχθεί ότι είναι δυνατή η πρόβλεψη απόδοσης αθλητριών στον τομέα επίτευξης πόντων όπως και στο πρώτο πρόγραμμα γνωρίζοντας κάποια συγκεκριμένα ατομικά στατιστικά όπως ηλικία, χρόνος συμμετοχής κ.α. Σημαντικό να αναφερθεί σε αντίθεση με τα προαναφερθέντα προγράμματα η θέση στην οποία αγωνίζεται η εκάστοτε αθλήτρια δεν θα ληφθεί υπόψιν καθώς είναι αρκετά ασαφής. Θα αποδειχθεί σε τρεις διαφορετικές περιπτώσεις με την βοήθεια της γλώσσας PYTHON (δύο αλγόριθμοι) και της εφαρμογής MATLAB (ένας αλγόριθμος). Σε όλες τις περιπτώσεις για καλύτερη σύγκριση θα δίνονται οι ίδιες είσοδοι και θα παίρνουμε την ίδια έξοδο για την καλύτερη σύγκριση μεταξύ των προγραμμάτων. Ως έξοδος θα δίνεται σε όλες τις περιπτώσεις ο μέσος όρος επίτευξης πόντων της εκάστοτε αθλήτριας.

Σημαντική διαφορά με τα προηγούμενα προγράμματα είναι ότι δεν θα ληφθεί υπόψιν ως είσοδος η θέση της εκάστοτε αθλήτριας. Υπάρχει σχετική έλλειψη πληροφοριών σχετικά με την ανάλυση θέσης κάθε αθλήτριας καθώς όσες πληροφορίες είναι διαθέσιμες χωρίζουν τις αθλήτριες σε τρεις θέσεις και όχι σε πέντε όπως στο NBA. Συνεπώς, δεν βοηθά στην αποτελεσματική ανάλυση στατιστικών που επηρεάζουν την απόδοση όσον αφορά τον μέσο όρο πόντων μίας αθλήτριας.

Είναι γνωστό ότι, το επίπεδο του πρωταθλητισμού καλαθοσφαίρισης των γυναικών δεν βρίσκεται στο ίδιο με των ανδρών, αντίστοιχα και το πρωτάθλημα καλαθοσφαίρισης της Αμερικής των γυναικών είναι σαφώς χαμηλότερο από το αντίστοιχο των ανδρών. Αν και τα τελευταία χρόνια γίνονται εντατικές προσπάθειες για την ανάπτυξη του αθλήματος ώστε να γίνει πιο προσιτό στο κοινό, πρέπει να γίνουν πολλά βήματα ακόμα προκειμένου να αποκτήσει περισσότερους θεατές και ταυτοχρόνως να προσελκύσει υποψήφιες αθλήτριες.

4.1.3.1. Υλοποίηση σε γλώσσα PYTHON

Τα αποτελέσματα της εργασίας παρακάτω θα αποδείξουν ότι οι αλγόριθμοι ANN και RBF μπορούν να χρησιμοποιηθούν αποτελεσματικά για να την πρόβλεψη του αριθμού των πόντων που θα σκοράρει μια αθλήτρια του WNBA. Αρχικά, θα δούμε τα βέλτιστα αποτελέσματα τα οποία πέτυχαν ακρίβεια 83% με τον αλγόριθμο ANN και 80% με το δίκτυο RBF. Αυτό δείχνει ότι και οι δύο αλγόριθμοι έχουν δυνατότητες για ακριβείς προβλέψεις και θα μπορούσαν να χρησιμοποιηθούν ως βάση για περαιτέρω έρευνα και ανάπτυξη.

Επιπλέον, θα μελετηθεί μέσα από την διενέργεια περαιτέρω πειραμάτων αν υπάρχει χώρος για βελτίωση για το πρόγραμμα. Θα γίνει διεξαγωγή πειραμάτων με διαφορετικές παραμέτρους, όπως ο αριθμός των εποχών, των εισόδων και των συναρτήσεων ενεργοποίησης. Στόχος των πειραμάτων αποτελεί η περαιτέρω βελτίωση της ακρίβειας και της προσαρμοστικότητας του μοντέλου μας. Όσα ειπώθηκαν ενδέχεται να βοηθήσουν στην διεύρυνση του πεδίου εφαρμογής του μοντέλου και την επιβεβαίωση της αξιοπιστίας σε περισσότερες καταστάσεις.

Όπως και προηγουμένως, θα παρουσιαστούν πρώτα οι βέλτιστες υλοποιήσεις με τις ανάλογες παραμέτρους. Έπειτα, θα γίνει εκπαίδευση και δοκιμές σε ίδιες παραμέτρους μεταξύ των αλγορίθμων για να υπάρξει άμεση και αποτελεσματική σύγκριση και τέλος, θα συγκριθούν τα αποτελέσματα μεταξύ των δύο αλγορίθμων για να αποφανθούμε αν θα ήταν δυνατόν να διατηρήσουμε κάποια εκδοχή του προγράμματος.

4.1.3.1.1. Πειράματα μέγιστης ακρίβειας

Τα στατιστικά αφορούν πάλι στην κανονική περίοδο του NBA. Θα αναλυθούν διαφορετικές περιπτώσεις με διαφορετικές εισόδους σε κάθε περίπτωση. Όπως ειπώθηκε και παραπάνω δεν θα υπάρξει σαν είσοδος η θέση της εκάστοτε αθλήτριας. Άρα οι είσοδοι θα είναι:

1. ηλικία
2. ποσοστό αγώνων συμμετοχής
3. λεπτά συμμετοχής
4. eFG%
5. FG%
6. FT%
7. TOV

Και έξοδος:

1. Μ.Ο. πόντων

Γίνεται εύκολα αντιληπτό ότι η δομή του προγράμματος που χρησιμοποιήθηκε είναι ίδια με τις προηγούμενες υλοποιήσεις σε γλώσσα PYTHON και έχουν γίνει αλλαγές όπου κρίθηκε αναγκαίο για την προσαρμογή στην νέα βάση δεδομένων όσον αφορά τις αθλήτριες του WNBA.

Παράμετροι	ANN	RBF
Train-Test split	80%-20%	80%-20%
Κρυφά επίπεδα («hidden layers»)	3	3
Επαναλήψεις («epochs»)	500	300
Activation functions	Relu – Sigmoid	
Optimizers	SGD	RMSprop
Loss function	Mean squared error	Mean squared error

Πίνακας 37: Παράμετροι βέλτιστων αποτελεσμάτων WNBA

Όπως φαίνονται στον πίνακα οι διαφορές στις παραμέτρους των καλύτερων αποτελεσμάτων των πειραμάτων είναι:


- Ο Αριθμός επαναλήψεων («epochs»): Έχουμε 500 για τον ANN αλγόριθμο και 300 για τον RBF αλγόριθμο
- Optimizer: SGD RBF: RMSprop
- Συνάρτηση ενεργοποίησης έχουμε μόνο στον ANN διότι όπως έχουμε αναφέρει και σε προηγούμενες ενότητες δεν χρησιμοποιεί ο RBF

Όπως θα αποδειχθεί και στα διαγράμματα παρακάτω και στις επόμενες ενότητες οι παράμετροι αυτοί παρείχαν την μέγιστη ακρίβεια με ταυτόχρονα χαμηλό σφάλμα συναρτήσεων και αποφυγή κινδύνου υπερ-εκπαίδευσης («overfitting»)

Διαγράμματα καλύτερου πειράματος

Ακολουθούν τα διαγράμματα των πειραμάτων με τα καλύτερα αποτελέσματα:

- **Train: 80% - Test: 20% ANN Ακρίβεια προβλέψεων 83.4%**




Εικόνα 58: ANN Train - Test loss (80%-20% train-test)

Name	Age	Actual PPG	ANN Prediction	Accuracy
Aari McDonald	24	11.1	[[13.264864]]	[[88.58394]]%
Allie Quigley	36	11.4	[[14.264792]]	[[74.87824]]%
Candace Parker	36	13.2	[[14.756541]]	[[88.28882]]%
Betnijah Laney	29	11.2	[[14.438727]]	[[71.15422]]%
Elena Delle Donne	33	17.2	[[14.658224]]	[[85.17571]]%
Aerial Powers	28	14.4	[[13.598141]]	[[94.43153]]%
Arike Ogunbowale	25	19.7	[[16.81458]]	[[85.353195]]%
Asia (AD) Durr	25	7	[[7.8717947]]	[[87.54579]]%
The accuracy of the net is : [[83.48534]] %				

Εικόνα 59: ANN Train - Test loss (80%-20% train-test)

- **Train: 80% - Test: 20% RBF-Ακρίβεια προβλέψεων: 85.03%**



Εικόνα 60: RBF Train - Test loss (80%-20% train-test)

Name	Age	Actual PPG	RBF Prediction	Accuracy
Aari McDonald	24	11.1	[[11.193355]]	[[99.15897]]%
Allie Quigley	36	11.4	[[13.530116]]	[[81.314766]]%
Candace Parker	36	13.2	[[16.113194]]	[[77.93035]]%
Betnijah Laney	29	11.2	[[14.426246]]	[[71.19424]]%
Elena Delle Donne	33	17.2	[[14.343613]]	[[83.3931]]%
Aerial Powers	28	14.4	[[13.799176]]	[[95.827614]]%
Arike Ogunbowale	25	19.7	[[17.712729]]	[[89.91232]]%
Asia (AD) Durr	25	7	[[8.292265]]	[[81.53907]]%
The accuracy of the net is : [[85.03381]] %				

Εικόνα 61: RBF Πειράματα (80%-20% train-test) και ακρίβεια

Πίνακας 38: Αποτελέσματα βέλτιστων πειραμάτων WNBA


4.1.3.1.2. Πρόσθετα πειράματα

Όπως θα αποδειχθεί και παρακάτω ο αλγόριθμος των τεχνητών νευρωνικών δικτύων (ANN) είναι πιο ευέλικτος και μπορεί να χειριστεί καλύτερα τα πολύπλοκα δεδομένα από τον αντίστοιχο RBF. Τα δίκτυα RBF από την άλλη, απαιτούν προσεκτική επιλογή παραμέτρων για να αποφευχθεί η υπερ-εκπαίδευση με τα δεδομένα εκπαίδευσης. Με άλλα λόγια, τα ANN έχουν μεγαλύτερη ανοχή στα θορυβώδη και ποικίλα δεδομένα. Χαρακτηρίζονται, επίσης από μια πιο απλή αρχιτεκτονική και διαδικασία εκπαίδευσης από τα RBF, καθιστώντας τα πιο εύκολα στην υλοποίηση και βελτιστοποίηση. Επιπλέον, τα ANN έχουν την δυνατότητα να χρησιμοποιήσουν μια ποικιλία από συναρτήσεις ενεργοποίησης, οι οποίες μπορούν να προσαρμοστούν στην ειδική εργασία και τα δεδομένα. Για αυτόν τον λόγο, σε περισσότερες καταστάσεις, τα ANN αποτελούν καλύτερη επιλογή από τα RBF για διάφορες εργασίες μηχανικής μάθησης, συμπεριλαμβανομένου και του αντικειμένου της παρούσας εργασίας δηλαδή της πρόβλεψης του αριθμού των πόντων που θα σκοράρει μία αθλήτρια του WNBA.

4.1.3.1.2.1. Διαφορετική επιλογή train-test splits

Παρακάτω θα εξεταστούν, διάφορα σενάρια εκπαίδευσης και ελέγχου. Τα αποτελέσματά μας έδειξαν ότι σε όλες τις περιπτώσεις, το ANN είχε καλύτερες επιδόσεις από το αντίστοιχο δίκτυο RBF όσον αφορά στο σφάλμα απόδοσης και ελέγχου (train- test loss). Εάν οι παράμετροι δεν επιλεγθούν σωστά, το δίκτυο RBF είναι ευάλωτο στην υπερ-εκπαίδευση, με αποτέλεσμα κακή απόδοση γενίκευσης.

- **Train: 90% Test: 10% - ANN - Ακρίβεια προβλέψεων: 83.74%**




Εικόνα 62: ANN Train - Test loss (90%-10% train-test)

Name	Age	Actual PPG	ANN Prediction	Accuracy
Aari McDonald	24	11.1	[[12.95544]]	[[83.284]]
Candace Parker	36	13.2	[[15.077118]]	[[85.779]]
Elena Delle Donne	33	17.2	[[15.110465]]	[[87.851]]
Aerial Powers	28	14.4	[[14.559239]]	[[98.894]]
Arike Ogunbowale	25	19.7	[[16.919434]]	[[85.885]]
Asia (AD) Durr	25	7	[[7.9208813]]	[[86.844]]

The accuracy of the net is : [[83.74527]] %

Εικόνα 63: ANN Πειράματα (90%-10% train-test) και ακρίβεια

- **Train: 90% Test: 10% - RBF - Ακρίβεια προβλέψεων: 84.43%**




Εικόνα 64: RBF Train - Test loss (90%-10% train-test)

Name	Age	Actual PPG	RBF Prediction	Accuracy
Aari McDonald	24	11.1	[[9.804174]]	[[88.32589]]%
Allie Quigley	36	11.4	[[12.763747]]	[[88.0373]]%
Candace Parker	36	13.2	[[16.50023]]	[[74.998245]]%
Betnijah Laney	29	11.2	[[13.164197]]	[[82.462524]]%
Elena Delle Donne	33	17.2	[[14.195461]]	[[82.531746]]%
Aerial Powers	28	14.4	[[12.447596]]	[[86.441635]]%
Arike Ogunbowale	25	19.7	[[16.971504]]	[[86.149765]]%
Asia (AD) Durr	25	7	[[7.9452586]]	[[86.49631]]%

The accuracy of the net is : [[84.43043]] %

Εικόνα 65: RBF Πειράματα (90%-10% train-test) και ακρίβεια

- Train: 70% Test: 30% - ANN - Ακρίβεια προβλέψεων: 82.77%**




Εικόνα 66: ANN Train - Test loss (70%-30%) train-test

Name	Age	Actual PPG	ANN Prediction	Accuracy
Aari McDonald	24	11.1	[[11.719641]]	[[94.417656]]%
Allie Quigley	36	11.4	[[14.763694]]	[[70.49391]]%
Candace Parker	36	13.2	[[15.768929]]	[[80.53842]]%
Betnijah Laney	29	11.2	[[15.846699]]	[[58.511616]]%
Elena Delle Donne	33	17.2	[[15.64777]]	[[90.9754]]%
Aerial Powers	28	14.4	[[15.098535]]	[[95.14906]]%
Arike Ogunbowale	25	19.7	[[17.302376]]	[[87.829315]]%
Asia (AD) Durr	25	7	[[8.100157]]	[[84.28348]]%

Εικόνα 67: ANN Πειράματα (70%-30% train-test) και ακρίβεια

- Train: 70% Test: 30% - RBF - Ακρίβεια προβλέψεων: 84.67%**




Εικόνα 68: RBF Train - Test loss (70%-30%) train-test

Name	Age	Actual PPG	RBF Prediction	Accuracy
Aari McDonald	24	11.1	[[10.7162075]]	[[96.542484]]%
Allie Quigley	36	11.4	[[12.968892]]	[[86.237785]]%
Candace Parker	36	13.2	[[16.812029]]	[[72.63614]]%
Betnijah Laney	29	11.2	[[13.819956]]	[[76.60754]]%
Elena Delle Donne	33	17.2	[[13.858539]]	[[80.57289]]%
Aerial Powers	28	14.4	[[13.106102]]	[[91.0146]]%
Arike Ogunbowale	25	19.7	[[16.262253]]	[[82.5495]]%
Asia (AD) Durr	25	7	[[7.61322]]	[[91.23971]]%

Εικόνα 69: RBF Πειράματα (70%-30% train-test) και ακρίβεια

- Train: 60% Test: 40% - ANN - Ακρίβεια προβλέψεων: 83.37%**




Εικόνα 70: ANN Train - Test loss (60%-40%) train-test

Name	Age	Actual PPG	ANN Prediction	Accuracy
Aari McDonald	24	11.1	[[12.526205]]	[[87.151306]]%
Allie Quigley	36	11.4	[[13.726792]]	[[79.58954]]%
Candace Parker	36	13.2	[[15.629178]]	[[81.59714]]%
Betnijah Laney	29	11.2	[[15.438195]]	[[62.15897]]%
Elena Delle Donne	33	17.2	[[14.558361]]	[[84.64163]]%
Aerial Powers	28	14.4	[[14.531845]]	[[99.084404]]%
Arike Ogunbowale	25	19.7	[[16.873756]]	[[85.65358]]%
Asia (AD) Durr	25	7	[[7.899497]]	[[87.15004]]%

Εικόνα 71: RBF Πειράματα (70%-30% train-test) και ακρίβεια

- **Train: 60% Test: 40% - RBF - Ακρίβεια προβλέψεων: 81.89%**



Εικόνα 72: RBF Train - Test loss (60%-40%) train-test

Name	Age	Actual PPG	RBF Prediction	Accuracy
Aari McDonald	24	11.1	[[12.5881115]]	[[86.665665]]%
Allie Quigley	36	11.4	[[13.455974]]	[[81.96514]]%
Candace Parker	36	13.2	[[17.65295]]	[[66.265526]]%
Betnijah Laney	29	11.2	[[14.148539]]	[[73.745186]]%
Elena Delle Donne	33	17.2	[[14.068625]]	[[81.79433]]%
Aerial Powers	28	14.4	[[13.438993]]	[[93.27879]]%
Arike Ogunbowale	25	19.7	[[17.732773]]	[[90.81487]]%
Asia (AD) Durr	25	7	[[8.381648]]	[[81.48583]]%

The accuracy of the net is : [[81.898724]] %

Εικόνα 73: RBF Πειράματα (70%-30% train-test) και ακρίβεια

Πίνακας 39: Περαιτέρω πειράματα WNBA

Όπως φαίνεται και στους πίνακες παραπάνω σε όλες τις περιπτώσεις ο αλγόριθμος ANN πετυχαίνει μείωση του σφάλματος απόδοσης και ελέγχου (train-test loss) σε αντίθεση με τον αλγόριθμο RBF ο οποίος σε όλες τις περιπτώσεις παραμένει κοντά στην αρχική του τιμή με διακυμάνσεις, γεγονός το οποίο υποδεικνύει μία τάση προς υπέρ-εκπαίδευση με τα δεδομένα της βάσης δεδομένων.

4.1.3.1.2.2. Διαφορετική επιλογή «epochs»

Παρακάτω θα εξεταστούν ο αριθμός των επαναλήψεων ανάμεσα στους δύο αλγόριθμους, όπως αναφέρθηκε και παραπάνω ο αριθμός των 500 εποχών για τον αλγόριθμο ANN και 300 για τον RBF αντίστοιχα κρίθηκε ο ιδανικός για την ισορροπία μεταξύ χρόνου εκτέλεσης και υπερ-εκπαίδευσης.

Τεχνητό νευρωνικό δίκτυο με ANN

Epochs	Χρόνος εκτέλεσης	Loss	Ακρίβεια
100	4 δευτ.	0.0086	82.05%
300	11 δευτ.	0.0100	83.51%
500	19 δευτ.	0.008	83.4%
1000	35 δευτ.	0.0081	79.22%
10000	5 λεπ. 7δευτ.	0.0025	83.66%

Πίνακας 40: Πειράματα σε ANN με διαφορετική επιλογή epochs

Τεχνητό νευρωνικό δίκτυο με RBF

Epochs	Χρόνος εκτέλεσης	Loss	Ακρίβεια
100	7δευτ.	0.0082	81.45%
300	17δευτ.	0.0053	85.03%
500	28 δευτ.	0.0048	82.7%
1000	46 δευτ.	0.0037	82.49%
10000	7 λεπ. 2 δευτ.	0.0024	79.76%

Πίνακας 41: Πειράματα σε RBF με διαφορετική επιλογή epochs

Όπως φαίνεται στους πίνακες σε όλες τις περιπτώσεις πέρα από αυτές που αναφέρθηκαν ως ιδανικές δεν επιτεύχθηκε αύξηση ακρίβειας. Απεναντίας, υπήρξε είτε τεράστια αύξηση στον χρόνο εκτέλεσης είτε μείωση ακρίβειας.


4.1.3.1.2.3. Διαφορετική επιλογή loss functions

Η παρούσα ενότητα ασχολείται με την διενέργεια πειραμάτων όσον αφορά στις συναρτήσεις σφάλματος ανάμεσα στους δύο αλγόριθμους. Όπως θα αποδειχθεί και παρακάτω η επιλογή της συνάρτησης «Mean Squared Error» αποτελεί την βέλτιστη και για τους δύο τύπους αλγορίθμων, καθώς πετυχαίνει ταυτοχρόνως την μέγιστη ακρίβεια με ένα πολύ μικρό σφάλμα συνάρτησης.

Optimizer ANN	Optimizer RBF	Loss function	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
SGD	SGD	Mean Squared Error	0.008	0.01 σταθερό	83.4%	
SGD	RMSprop	Mean Squared Error	0.008	0.0053	83.4%	85.03%
SGD	RMSprop	Mean Absolute Error	0.0562	0.0636	78.91%	83.57%
SGD	SGD	Mean Squared Logarithmic Error	0.0032	0.1861 σταθερό	83.2%	40.1%

Πίνακας 42: Πειράματα με διαφορετική επιλογή loss functions

Ανάμεσα στις περιπτώσεις που αναγράφονται στον παραπάνω πίνακα, αξίζει να σταθεί κανείς στην συνάρτηση «Mean Squared Logarithmic Error» για τον αλγόριθμο ANN καθώς φαίνεται ότι πετυχαίνει το ελάχιστο σφάλμα συνάρτησης και μία πολύ καλή ακρίβεια δικτύου. Το παραπάνω οφείλεται στο γεγονός ότι η συνάρτηση «MSLE» είναι ιδιαίτερος χρήσιμη όταν οι τιμές της βάσης δεδομένων έχουν μεγάλες αποκλίσεις μεταξύ τους, στο παρόν πρόγραμμα έχουμε πιο μικρή βάση δεδομένων σε σχέση με τα προηγούμενα, συνεπώς υπάρχουν μεγαλύτερες αποκλίσεις μεταξύ των δεδομένων. Συμπερασματικά, είναι λιγότερη ευαίσθητη σε σχέση με την «MSE».



Εικόνα 74: ANN MSLE loss function (πείραμα 80% - 20% train -test split)

4.1.3.1.2.4. Διαφορετική επιλογή κρυφών επιπέδων

Παρακάτω θα εξεταστεί εάν η περαιτέρω αύξηση των κρυφών επιπέδων βελτιώνει την απόδοση του δικτύου.

Κρυφά επίπεδα	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
3	0.008	0.0053	83.4%	85.03%
5	0.0096	0.0058	84.25%	83.74%
10	0.0099	0.0100	83.54%	84.49%
15	0.0099	0.0101	83.59%	82.81%

Πίνακας 43: Πειράματα με διαφορετικό αριθμό κρυφών επιπέδων

Παρατηρεί κανείς ότι η αύξηση των κρυφών επιπέδων βελτιώνει την απόδοση του δικτύου αλλά αυξάνει το σφάλμα συνάρτησης. Θα προτιμηθούν τα τρία επίπεδα και πάλι ώστε να διατηρηθεί η απλότητα των δικτύων και να αποφευχθεί μία ενδεχόμενη υπερ-εκπαίδευση στα δεδομένα εκπαίδευσης.


4.1.3.1.2.5. Διαφορετική επιλογή συναρτήσεων ενεργοποίησης

Παρακάτω μελετάται η χρήση διαφορετικών συναρτήσεων ενεργοποίησης όσον αφορά τον αλγόριθμο ANN.

Activation functions	Loss	Accuracy
Relu- sigmoid	0.008	83.4%
elu-sigmoid	0.0058	84.42%
elu-softmax	0.2263 σταθερό	
Relu-softmax	0.2263 σταθερό	
Relu-softsign	0.0061	80.90%
Relu-tanh	0.0066	80.85%
Relu-Relu	0.0092	82.07%

Πίνακας 44: Πειράματα με διαφορετική επιλογή συναρτήσεων ενεργοποίησης

Ενδιαφέρουσα περίπτωση αποτελεί ο συνδυασμός elu-sigmoid όπου σε πείραμα επιτεύχθηκε ο βέλτιστος συνδυασμός σφάλματος συνάρτησης με την μέγιστη ακρίβεια. Επίσης κρίνοντας από την γραφική παράσταση είναι λογικό να ειπωθεί ότι ενδέχεται να ήταν δυνατή η χρήση του συγκεκριμένου συνδυασμού συναρτήσεων διότι είναι γνωστό ότι σε αντίθεση με την «RELU» η «ELU» έχει μηχανισμούς κανονικοποίησης από μόνη της. Επιπλέον, με την εφαρμογή της «ELU» γίνεται αποφυγή του προβλήματος «νεκρού νευρώνα» («dead neuron»). Όταν γίνεται αναφορά του προβλήματος νεκρού νευρώνα αναφερόμαστε στο γεγονός κατά το οποίο η συνάρτηση ενεργοποίησης μένει στάσιμη σε μία συγκεκριμένη τιμή (συνήθως την μέγιστη ή την ελάχιστη).



Εικόνα 75: ANN elu- softmax activation function (πείραμα 80% - 20% train -test split)


4.1.3.1.2.6. Διαφορετική επιλογή εισόδων

Παρακάτω θα εξεταστεί εάν η αφαίρεση κάποιας εισόδου στο πρόγραμμα βελτιώνει την απόδοση του προγράμματος.


Είσοδοι	ANN loss	RBF loss	ANN Accuracy	RBF Accuracy
	0.008	0.0053	83.4%	85.03%
Χωρίς FG%	0.0064	0.0050	80.97%	81.23%
Χωρίς FG% και TOV (λάθη)	0.0069	0.0052	83.15%	81.56
Χωρίς τραυματισμούς	0.0067	0.0049	82.33%	82.37%

Πίνακας 45: Διαφορετική επιλογή εισόδων

Σύμφωνα με τον παραπάνω πίνακα συμπεραίνουμε ότι αξίζει να σταθεί κανείς στις περιπτώσεις αφαίρεσης είτε των δεδομένων τραυματισμών είτε του ποσοστού ευστοχίας «%FG» καθώς η ακρίβεια του προγράμματος μειώθηκε ελαφρώς αλλά ταυτοχρόνως μειώθηκε το σφάλμα συνάρτησης. Επομένως, εάν δεν υπήρχε πρόσβαση σε δεδομένα όπως τα συγκεκριμένα πάλι θα υπήρχε μια αξιοσημείωτη ακρίβεια.



Εικόνα 76: ANN χωρίς τραυματισμούς



Εικόνα 77: ANN πειράματα χωρίς FG%

4.1.3.2. MATLAB

4.1.3.2.1. Πείραμα μέγιστης ακρίβειας

Γίνεται χρήση των εισόδων όπως και στην υλοποίηση της PYTHON


1. ηλικία
2. ποσοστό αγώνων συμμετοχής
3. λεπτά συμμετοχής
4. FG%
5. eFG%
6. FT%
7. TOV

Και έξοδος

1. Μ.Ο. πόντων
 - **Train: 80% Test: 20%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	9.7192	1 δευτ.	87.48%
Mean Absolute Error (MAE)	2.5244	1 δευτ.	87.48%
Root Mean Squared Error (RMSE)	3.1176	1 δευτ.	87.48%

Πίνακας 46: Πειράματα μέγιστης ακρίβειας MATLAB



Εικόνα 78: MATLAB μέγιστης ακρίβειας αποτελέσματα

Όπως φαίνεται στις παραπάνω εικόνες το πρόγραμμα του αλγόριθμου ANN στην MATLAB επιτυγχάνει 87.48% ακρίβεια προβλέψεων με τις ίδιες παραμέτρους που χρησιμοποιήθηκαν και στα προγράμματα της γλώσσας PYTHON ενώ ταυτόχρονα τερματίζει με σφάλμα εκπαίδευσης 9.7192, 2.5244, 3.1176 αντίστοιχα για συναρτήσεις ενεργοποίησης «MSE», «MAE», «RMSE». Επίσης, στην PYTHON παρατηρήθηκε ιδιαίτερος καλή ακρίβεια και μικρό σφάλμα με την «Mean Squared Logarithmic Error» που διαχειρίζεται αποτελεσματικά τις μεγάλες αποκλίσεις. Παρομοίως, και στο πείραμα της MATLAB το ελάχιστο σφάλμα επιτυγχάνεται με την συνάρτηση «RMSE» που γενικά χαρακτηρίζεται για την αποτελεσματική αντιμετώπιση των μεγάλων αποκλίσεων μεταξύ δεδομένων κάτι το οποίο είναι λογικό όπως αναφέρθηκε καθώς η βάση δεδομένων είναι πιο μικρή σε σχέση με τα προηγούμενα προγράμματα. Έπειτα, παρατηρείται στο διάγραμμα το πρόγραμμα σταματάει έπειτα από 5 εποχές («epochs») καθώς επιτυγχάνει την ελάχιστη τιμή σφάλματος. Ο σκοπός της διακοπής αυτής είναι η αποτροπή του δικτύου από την υπερ-εκπαίδευση, συνεπώς δεν έχει και νόημα η δοκιμή περισσότερων εποχών όπως στην PYTHON καθώς το πρόγραμμα διακόπτεται έπειτα από το μέγιστο 20 εποχές καθ' όλη την διάρκεια διαφορετικών πειραμάτων. Σημαντικό να ειπωθεί ότι δοκιμάστηκαν επίσης και τεχνικές κανονικοποίησης, διαφορετικές παράμετροι, ωστόσο με το συνδυασμό 80% train-20% test πάρθηκαν τα καλύτερα αποτελέσματα διατηρώντας τον συνδυασμό μικρού σφάλματος και μεγάλης ακρίβειας.

4.1.3.2.2. Πρόσθετα πειράματα


Στις επόμενες παραγράφους, διεξάγονται πειράματα για την απόδειξη του ισχυρισμού ότι τα παραπάνω ήταν τα πειράματα με τα βέλτιστα αποτελέσματα.

4.1.3.2.2.1. Διαφορετική επιλογή train-test splits

Παρακάτω θα αναλυθούν πειράματα για διαφορετικό διαχωρισμό δεδομένων εκπαίδευσης και επαλήθευσης.

- **Train: 90% Test: 10% Ακρίβεια προβλέψεων: 87.76%**


Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	5.0719	1 δευτ.	87.76%
Mean Absolute Error (MAE)	1.6751	1 δευτ.	87.76%
Root Mean Squared Error (RMSE)	2.2521	1 δευτ.	87.76%



Εικόνα 79: MATLAB 90%-10% train - test split

- **Train: 70% Test: 30% Ακρίβεια προβλέψεων: 81.83%**


Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	9.8687	1 δευτ.	81.83%
Mean Absolute Error (MAE)	2.4568	1 δευτ.	81.83%
Root Mean Squared Error (RMSE)	3.1415	1 δευτ.	81.83%



Εικόνα 80: MATLAB 70%-30% train - test split

- **Train: 60% Test: 40% Ακρίβεια προβλέψεων: 77.82%**

Activation function	Σφάλμα συνάρτησης	Χρόνος εκτέλεσης	Ακρίβεια
Mean Squared Error (MSE)	7.6698	1 δευτ.	77.82%
Mean Absolute Error (MAE)	2.2476	1 δευτ.	77.82%
Root Mean Squared Error (RMSE)	2.7694	1 δευτ.	77.82%



Εικόνα 81: MATLAB 60%-40% train - test split

Πίνακας 47: Περαιτέρω πειράματα MATLAB

Σύμφωνα με τα παραπάνω αποτελέσματα φαίνεται ότι σε οποιαδήποτε περίπτωση υπάρχει πτώση ακρίβειας και αύξησης του σφάλματος συνάρτησης εκτός της περίπτωσης διαχωρισμού των δειγμάτων σε 90% - 10% σε «train-test split». Η συγκεκριμένη περίπτωση είναι επιθυμητή στην περίπτωση που έχουμε επαρκή αριθμό δειγμάτων. Ωστόσο, όπως αναφέρθηκε και στην αρχή της ενότητας τα δεδομένα για το αμερικάνικο πρωτάθλημα καλαθοσφαίρισης γυναικών WNBA δεν είναι επαρκή. υνεπώς θα ήταν επιθυμητό το δίκτυο μας να έχει την δυνατότητα επαρκούς εκπαίδευσης με όσον το δυνατόν λιγότερα δεδομένα. Ένα πείραμα με αυτά χαρακτηριστικά είναι και ο διαχωρισμός δεδομένων εκπαίδευσης επαλήθευσης σε 60%-40% καθώς πετυχαίνει ακρίβεια άνω του 77% με ένα σχετικά χαμηλό σφάλμα.

4.1.3.2.2.2. Διαφορετική επιλογή κρυφών επιπέδων

Παρακάτω εξετάζεται οι περιπτώσεις να υπάρχουν παραπάνω από τρία κρυφά επίπεδα στην υλοποίηση του δικτύου

Κρυφά επίπεδα	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
3	9.7192	2.5244	3.1176	87.48%
5	14.1274	2.8656	3.7586	85.02%
10	21.2481	3.494	4.6096	75.19%
15	10.9105	2.1745	3.3031	82.07%

Πίνακας 48: Πειράματα επιλογής διαφορετικού αριθμού κρυφών επιπέδων

Όπως φαίνεται στον πίνακα παραπάνω η περαιτέρω αύξηση των κρυφών επιπέδων δεν οδήγησε στην παραμικρή βελτίωση, αντ' αυτού παρατηρείται μείωση ακρίβειας και αύξηση σφάλματος. Ενδείξεις οι οποίες υποδεικνύουν την τάση του δικτύου προς την υπερ-εκπαίδευση και αύξηση της πολυπλοκότητας του δικτύου χωρίς ουσιαστικό αποτέλεσμα. Για αυτούς τους λόγους είναι προτιμότερο να παραμείνει το δίκτυο στα τρία κρυφά επίπεδα καθώς ο συνδυασμός πολυπλοκότητας, ακρίβειας και σφάλματος συνάρτησης φαίνεται να είναι ο βέλτιστος.

4.1.3.2.2.3. Διαφορετική επιλογή εισόδων

Όπως και σε παρόμοιες ενότητες παρακάτω θα εξεταστεί αν η μείωση των εισόδων στο πρόγραμμα έχει σημαντική επίδραση στο πρόγραμμα μας.

Είσοδοι	Mean Squared Error (MSE)	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	Ακρίβεια
	9.7192	2.5244	3.1176	87.48%
Χωρίς FG%	11.5285	3.0816	3.3954	77.52%
Χωρίς FG% και TOV (λάθη)	5.9263	1.8329	2.4344	85.49%
Χωρίς τραυματισμούς	6.3789	2.0705	2.5257	86.18%

Πίνακας 49: Πειράματα με διαφορετική επιλογή εισόδων MATLAB

Όπως φαίνεται και στον πίνακα παραπάνω η διατήρηση της μετρικής «eFG%» με την ταυτόχρονη αφαίρεση είτε της μετρικής «FG%» με «TOV» είτε του στατιστικού συμμετοχής σε αγώνες δεν οδηγεί σε μεγάλη απώλεια ακρίβειας, πιο συγκεκριμένα υπάρχει μείωση της τάξης 1%-2% κάτι το οποίο υποδεικνύει ότι είναι δυνατή η εκπαίδευση του μοντέλου με λιγότερα δεδομένα καθώς όπως γίνεται αντιληπτό κάποια δεδομένα όπως των τραυματισμών χρειάζονται προεπεξεργασία και δεν είναι εύκολα διαθέσιμα στο διαδίκτυο. Είναι αξιοσημείωτο μάλιστα, ότι πετυχαίνουν μικρότερο σφάλμα συνάρτησης από το αρχικό πείραμα. Συμπερασματικά, εάν υπάρχει πρόσβαση σε όλα τα δεδομένα καλό θα ήταν να παραμείνουμε στο αρχικό πείραμα που πετυχαίνει την βέλτιστη ακρίβεια, ωστόσο εάν δεν υπάρχουν τα αντίστοιχα δεδομένα διαθέσιμα είναι δυνατόν να γίνει εκπαίδευση και με λιγότερα δεδομένα.

4.1.3.3. Συμπεράσματα και σύγκριση μεταξύ υλοποιήσεων

Για την καλύτερη σύγκριση μεταξύ των υλοποιήσεων των προγραμμάτων δημιουργήθηκαν οι παρακάτω πίνακες για την παροχή μίας συνολικής εικόνας.

Ακρίβεια ANN (PYTHON)	ANN -RBF (PYTHON) train-test splits	ANN loss: SGD - MSE	Ακρίβεια RBF (PYTHON)	RBF loss: RMSprop- MSE	Ακρίβεια ANN MATLAB	MATLAB train-test splits	MATLAB loss (MSE) (MAE) (RMSE)
83.4%	80%-20%	0.008	85.03%	0.0053	87.48%	80%-20%	9.7192 2.5244 3.1176

Πίνακας 50: Συγκεντρωτικά αποτελέσματα WNBA

Όσο για τους χρόνους υλοποίησης για τα βέλτιστα αποτελέσματα, φαίνονται στον πίνακα της επόμενης σελίδας.

Χρόνος εκτέλεσης ANN (PYTHON)	ANN (PYTHON) epochs	Χρόνος εκτέλεσης RBF (PYTHON)	RBF (PYTHON) epochs	Χρόνος εκτέλεσης ANN MATLAB	MATLAB epochs
19 δευτ.	500	17 δευτ.	300	1 δευτ.	20

Πίνακας 51: Χρόνοι εκτέλεσης μεταξύ υλοποιήσεων

Όπως φαίνεται στους πίνακες παραπάνω η MATLAB στο συγκεκριμένο πρόγραμμα αποτελεί το πιο δυνατό εργαλείο διότι είναι ταυτόχρονα ταχύτερη από οποιαδήποτε άλλη υλοποίηση σε PYTHON (είτε ANN είτε RBF) και πετυχαίνει την πιο υψηλή ακρίβεια από όλα τα υπόλοιπα προγράμματα.

Ωστόσο, είναι σημαντικό να σταθούμε στο σφάλμα συνάρτησης το οποίο είναι αρκετά υψηλό στην υλοποίηση της MATLAB και με οποιαδήποτε συνάρτηση ενεργοποίησης κάτι που ενδεχομένως υποδεικνύει μια τάση προς υπερ-εκπαίδευση με την συγκεκριμένη βάση δεδομένων. Συνεπώς, εάν θέλουμε ένα τέτοιο συμβάν ίσως να ήταν προτιμότερο να γίνει με τις υλοποιήσεις της PYTHON όπου ναι μεν υπάρχει πτώση ακρίβειας και αύξηση χρόνου εκτέλεσης αλλά είναι πιο αξιόπιστο και παρέχει μεγαλύτερη ανεκτικότητα έναντι στην υπερ-εκπαίδευση. Έπειτα, ακολουθεί ο πίνακας χωρίς την είσοδο των τραυματισμών μίας αθλήτριας.

Ακρίβεια ANN (PYTHON)	ANN loss	Ακρίβεια RBF (PYTHON)	RBF loss	Ακρίβεια ANN MATLAB	MATLAB loss (MSE) (MAE) (RMSE)
82.33%	0.0067	82.37%	0.0049	86.18%	6.3789 2.0705 2.5257

Πίνακας 52: Αποτελέσματα χωρίς είσοδο τραυματισμών

Τέλος, όπως φαίνεται έπειτα από την αφαίρεση της εισόδου των τραυματισμών πάλι το πρόγραμμα σε οποιαδήποτε υλοποίηση πετυχαίνει αξιοσημείωτη ακρίβεια, κάτι που υποδεικνύει ότι άλλες μετρικές είναι αυτές που επηρεάζουν την απόδοση του προγράμματος.

Συνολικά, Η πρόβλεψη της απόδοσης των αθλητριών WNBA μέσω μοντέλων μηχανικής μάθησης μπορεί να αποτελέσει ένα χρήσιμο εργαλείο για τους αθλητικούς οργανισμούς ώστε να συγκροτούν μία πιο συγκροτημένη στρατηγική λαμβάνοντας υπόψιν όσο το δυνατόν περισσότερους παράγοντες λόγω χάρη, ηλικία, τραυματισμούς, ευστοχία σε διάφορες συνθήκες. Χρησιμοποιώντας ιστορικά δεδομένα, αποδείχθηκε ότι τα μοντέλα μηχανικής μάθησης είναι δυνατόν να πετύχουν προβλέψεις υψηλής ακρίβειας σχετικά με το πόσους πόντους ενδέχεται να σκοράρει μία αθλήτρια. Ωστόσο, είναι σημαντικό να ληφθούν υπόψιν και ανθρώπινοι παράγοντες, όπως κόπωση και άλλοι ψυχολογικοί παράγοντες, οι οποίοι ενδέχεται να επηρεάσουν σημαντικά την απόδοση της αθλήτριας και δεν αποτυπώνονται εύκολα σε ψηφιακά δεδομένα.

5. Συμπεράσματα

Μέσω αυτής της εργασίας αποδείχτηκε ότι είναι δυνατόν να προβλεφθεί η πορεία καριέρας των αθλητών και αθλητριών του NBA και του WNBA αντίστοιχα βασιζόμενοι στα στατιστικά ενός σχετικά μικρού δείγματος αθλητών κατά τη διάρκεια προηγούμενων ετών. Επίσης, είναι δυνατή η πρόβλεψη των επιδόσεων τους κατά τη διάρκεια των κρίσιμων στιγμών με άλλα λόγια στα λεπτά του «clutch time» της κανονικής περιόδου. Χρησιμοποιήθηκαν δεδομένα δημοσίως διαθέσιμα σε ιστοσελίδες όπως NBA.com, WNBA.com και basketball-reference.com και έτυχαν επεξεργασίας στο περιβάλλον του Excel για να παραχθεί ένα CSV αρχείο με στατιστικά ανά λεπτό για κάθε παίκτη, ώστε να διασφαλιστεί η δίκαιη και ισότιμη σύγκριση μεταξύ όλων των παικτών.

Για την πραγματοποίηση της ανάλυσής μας, χρησιμοποιήθηκαν ισχυρά μοντέλα τεχνητών νευρωνικών δικτύων, και πιο συγκεκριμένα οι αλγόριθμοι ANN και RBF. Εφαρμόστηκαν στο περιβάλλον του Google Colaboratory για την γλώσσα PYTHON και στο περιβάλλον της MATLAB για το ANN. Η επιλογή αυτών των γλωσσών οφείλεται στην απλότητα τους, τη συνολική τους τεκμηρίωση και τις ισχυρές βιβλιοθήκες που είναι διαθέσιμες σε αμφότερες τις γλώσσες. Επιπλέον, η χρήση των δύο διαφορετικών αλγορίθμων νευρωνικών δικτύων ANN και RBF και η σύγκρισή τους στην πρόβλεψη των στατιστικών επιδόσεων των αθλητών αποδεικνύει τη δύναμη αυτών των δύο εργαλείων στον χώρο ανάλυσης δεδομένων και πρόβλεψης αποτελέσματος.

Με βάση τα αποτελέσματα της έρευνας, διαπιστώθηκε ότι τα μοντέλα αυτά είναι δυνατόν να χρησιμοποιηθούν αποτελεσματικά για την πρόβλεψη απόδοσης των αθλητών και αθλητριών σε μελλοντικούς αγώνες και να εξεταστεί η επίδοσή τους σε διάφορες συνθήκες και πιο σημαντικό σε κρίσιμες στιγμές όπως είναι οι περίοδοι clutch. Σημαντικό να ειπωθεί, ότι τα στατιστικά που χρησιμοποιήθηκαν δεν αποτελούν τα προηγμένα στατιστικά των ομάδων υποδεικνύοντας ότι είναι δυνατή η πρόβλεψη της απόδοσης των αθλητών χωρίς κάποιο ιδιαίτερος πολύπλοκο μοντέλο.

Συμπερασματικά, αυτή η έρευνα αποδεικνύει ότι είναι δυνατή η πρόβλεψη της πορείας της καριέρας ενός αθλητή και αθλήτριας είτε στο NBA είτε στο WNBA μέσω των στατιστικών του επιδόσεων κατά τη διάρκεια των ετών και να δειχθεί η απόδοσή τους σε αποφασιστικές στιγμές των αγώνων λόγω χάρη στον χρόνο «clutch time». Αυτή η έρευνα έχει αρκετές δυνατότητες στον χώρο του αθλητισμού και μπορεί να χρησιμοποιηθεί για τη βελτίωση της εκτίμησης της απόδοσης των αθλητών, για τη λήψη καλύτερων αποφάσεων που σχετίζονται με τη διαχείριση των αθλητικών ομάδων και των αθλητών.

6. Μελλοντική εργασία

Η παρούσα μελέτη αναδεικνύει πολλές δυνατότητες για μελλοντική έρευνα στον τομέα των νευρωνικών δικτύων στον τομέα του αθλητισμού.

Καταρχάς είναι δυνατή η επέκταση του συστήματος πρόβλεψης σε άλλα αθλήματα. Με άλλα λόγια, μπορεί να δημιουργηθεί ένα αντίστοιχο σύστημα πρόβλεψης για το ποδόσφαιρο, την πετοσφαίριση και το αμερικάνικο ποδόσφαιρο.

Έπειτα τονίζεται η χρήση προηγμένων στατιστικών. Πιο συγκεκριμένα, η παρούσα έρευνα έκανε χρήση στατιστικών δεδομένων που είναι διαθέσιμα στο ευρύ κοινό. Με τη χρήση προηγμένων στατιστικών, όπως αυτών που είναι διαθέσιμα μόνο από αθλητικούς οργανισμούς, μπορεί να επιτευχθεί βελτίωση της ακρίβειας του συστήματος πρόβλεψης.

Επιπροσθέτως, τέτοιου είδους ευρήματα θα ήταν ιδιαίτερος χρήσιμα σε εταιρίες στοιχηματισμού. Αν σκεφτεί κανείς το γεγονός ότι οι εταιρείες στοιχηματισμού θα είναι σε θέση να προβλέψουν τον νικητή ενός αγώνα, τον αθλητή ή αθλήτρια με τα καλύτερα στατιστικά, θα είναι σε θέση να προσφέρουν εξατομικευμένες επιλογές στους χρήστες τους με ταυτόχρονο στόχο την μεγιστοποίηση των κερδών τους.

Τέλος, θα ήταν δυνατόν να επεκταθούν τα ευρήματα της εργασίας ώστε ο εκάστοτε αθλητικός οργανισμός να διαμορφώνει την ομάδα του και να είναι σε θέση να προβλέψει πόσες νίκες θα μπορεί να αποσπάσει σε μία χρονιά. Με άλλα λόγια, συμβουλευμένος τα ατομικά και ομαδικά στατιστικά για το πως θα δομείται η κάθε ομάδα θα προβλέπεται μια προσέγγιση η οποία θα δείχνει πόσες αγώνες θα είναι σε θέση να κερδίσει μία ομάδα.

Συνολικά η παρούσα εργασία είναι δυνατόν να επεκταθεί για ανάλυση δεδομένων σε μεγαλύτερη κλίμακα, ώστε να είναι όπως η πρόβλεψη νικητών αγώνων ή της πρόβλεψης επιδόσεων ολόκληρων ομάδων σε βάθος χρόνου σύμφωνα με το σύνολο αθλητών που διαθέτουν. Όλες αυτές οι δυνατότητες ανοίγουν νέους ορίζοντες για την ανάλυση δεδομένων στον αθλητισμό.

Παράρτημα

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG	AH
1	NAME	Pos	Age	season	Total	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp	mp
1	Kyle Iv PG	19	2011-12	66	51	0.77	30.5	0.64	8.9	0.23	0.47	1.4	0.05	0.4	5.4	0.18	0.49	0.52	3.4	0.11	0.87	3.7	0.12	5.4	0.18	1.1	0.04	3.1	0.1	2.2	0.07	18.5	0.61	
2	Kyle Iv PG	20	2012-13	82	69	0.72	34.7	0.72	8.2	0.24	0.45	1.8	0.05	0.39	6.4	0.18	0.47	0.5	4.2	0.12	0.88	3.7	0.11	5.9	0.17	1.5	0.04	3.2	0.09	2.5	0.07	22.5	0.65	
3	Kyle Iv PG	21	2013-14	82	71	0.87	36.2	0.73	7.5	0.21	0.43	1.7	0.05	0.36	5.8	0.16	0.46	0.48	4.1	0.12	0.88	3.6	0.1	6.1	0.17	1.5	0.04	2.7	0.08	2.3	0.07	20.8	0.69	
4	Kyle Iv PG	22	2014-15	82	75	0.91	36.4	0.76	7.7	0.21	0.47	2.1	0.06	0.42	5.6	0.15	0.49	0.53	4.2	0.12	0.88	3.2	0.09	5.2	0.14	1.5	0.04	2.5	0.07	1.9	0.05	21.7	0.8	
5	Kyle Iv PG	23	2015-16	82	53	0.65	31.5	0.66	7.4	0.23	0.45	1.6	0.05	0.32	5.8	0.18	0.5	0.5	3.2	0.1	0.89	3	0.1	4.7	0.15	1.1	0.03	2.3	0.07	2	0.06	19.6	0.62	
6	Kyle Iv PG	24	2016-17	82	72	0.88	35.1	0.73	9.3	0.27	0.47	2.6	0.07	0.4	6.9	0.2	0.51	0.54	4.1	0.12	0.91	3.2	0.09	5.8	0.17	1.2	0.03	2.5	0.07	2.2	0.06	25.2	0.72	
7	Kyle Iv PG	25	2017-18	82	60	0.73	32.2	0.67	8.9	0.28	0.49	2.8	0.09	0.41	6.1	0.19	0.54	0.57	3.9	0.12	0.89	3.8	0.12	5.1	0.16	1.1	0.03	2.3	0.07	2	0.06	24.4	0.76	
8	Kyle Iv PG	26	2018-19	82	67	0.82	33	0.69	9	0.27	0.49	2.6	0.08	0.4	6.4	0.19	0.53	0.58	3.2	0.1	0.87	5	0.15	6.9	0.21	1.5	0.05	2.6	0.08	2.5	0.08	23.8	0.72	
9	Kyle Iv PG	27	2019-20	72	20	0.28	32.9	0.69	10	0.3	0.48	2.8	0.09	0.39	7.2	0.22	0.52	0.55	4.7	0.14	0.92	5.2	0.16	6.4	0.19	1.4	0.04	2.6	0.08	2.7	0.08	27.4	0.83	
10	Kyle Iv PG	28	2020-21	82	29	0.35	37.6	0.78	10	0.27	0.47	3.4	0.09	0.42	6.5	0.17	0.5	0.55	4.1	0.11	0.92	4.4	0.12	5.8	0.15	1.4	0.04	2.5	0.07	2.8	0.07	27.4	0.73	
11	Kyle Iv PG	29	2021-22	82	29	0.35	37.6	0.78	10	0.27	0.47	3.4	0.09	0.42	6.5	0.17	0.5	0.55	4.1	0.11	0.92	4.4	0.12	5.8	0.15	1.4	0.04	2.5	0.07	2.8	0.07	27.4	0.73	
12	Kyle Iv PG	30	2022-23	82	29	0.35	37.6	0.78	10	0.27	0.47	3.4	0.09	0.42	6.5	0.17	0.5	0.55	4.1	0.11	0.92	4.4	0.12	5.8	0.15	1.4	0.04	2.5	0.07	2.8	0.07	27.4	0.73	
13	Damian PG	23	2012-13	82	82	1	36.8	0.8	6.7	0.17	0.42	2.3	0.08	0.37	4.5	0.12	0.47	0.5	3.3	0.09	0.84	3.1	0.08	6.5	0.17	0.9	0.02	3	0.08	2.1	0.05	19	0.49	
14	Damian PG	24	2013-14	82	82	1	36.8	0.75	6.7	0.19	0.42	2.7	0.08	0.39	4.1	0.11	0.45	0.51	4.5	0.13	0.87	3.5	0.1	5.6	0.16	0.8	0.02	2.4	0.07	2.4	0.07	20.7	0.68	
15	Damian PG	25	2014-15	82	82	1	35.7	0.74	7.2	0.2	0.43	2.4	0.07	0.34	4.8	0.13	0.5	0.51	4.2	0.12	0.86	4.6	0.13	6.2	0.17	1.2	0.03	2.7	0.08	2	0.06	21	0.59	
16	Damian PG	26	2015-16	82	75	0.91	35.7	0.74	8.2	0.23	0.42	3.1	0.09	0.38	5.2	0.15	0.46	0.5	5.5	0.15	0.89	4	0.11	6.8	0.19	0.9	0.03	3.2	0.09	2.2	0.06	25.1	0.7	
17	Damian PG	27	2016-17	82	75	0.91	35.9	0.75	8.8	0.25	0.44	2.9	0.08	0.37	6	0.17	0.49	0.52	6.5	0.18	0.9	4.9	0.14	5.9	0.16	0.9	0.03	2.6	0.07	2	0.06	27	0.75	
18	Damian PG	28	2017-18	82	73	0.89	36.6	0.76	8.5	0.23	0.44	3.1	0.08	0.36	5.4	0.15	0.5	0.52	6.8	0.19	0.92	4.5	0.12	6.6	0.18	1.1	0.03	2.8	0.08	1.6	0.04	26.9	0.74	
19	Damian PG	29	2018-19	82	80	0.96	35.5	0.74	8.5	0.24	0.44	3	0.08	0.37	5.6	0.16	0.5	0.52	5.9	0.17	0.91	4.6	0.13	6.9	0.19	1.1	0.03	2.7	0.08	1.9	0.05	25.8	0.73	
20	Damian PG	30	2019-20	82	66	0.8	37.5	0.78	9.5	0.25	0.46	4.1	0.11	0.4	5.4	0.14	0.52	0.59	7	0.19	0.89	4.3	0.11	8	0.21	1.1	0.03	2.9	0.08	1.7	0.05	30	0.8	
21	Damian PG	31	2020-21	74	67	0.91	35.8	0.75	9	0.25	0.45	4.1	0.11	0.39	4.9	0.14	0.52	0.55	6.7	0.19	0.93	4.2	0.12	7.5	0.21	0.9	0.03	3	0.08	1.5	0.04	28.8	0.8	
22	Damian PG	32	2021-22	82	29	0.35	36.4	0.76	7.7	0.21	0.4	3.2	0.09	0.32	4.5	0.12	0.49	0.49	5.5	0.15	0.88	4.1	0.11	7.3	0.2	0.6	0.02	2.9	0.08	1.3	0.04	24	0.68	
23	Russel w PG	21	2008-09	82	82	1	32.5	0.68	5.3	0.16	0.4	0.4	0.01	0.27	4.9	0.15	0.42	0.41	4.3	0.13	0.82	4.9	0.15	5.3	0.16	1.3	0.04	3.3	0.1	2.3	0.07	16.3	0.47	
24	Russel w PG	22	2009-10	82	82	1	34.3	0.71	5.9	0.17	0.42	0.3	0.01	0.22	5.6	0.16	0.44	0.43	4	0.12	0.78	4.9	0.14	8	0.23	1.3	0.04	3.3	0.1	2.5	0.07	16.1	0.47	
25	Russel w PG	23	2010-11	82	82	1	34.7	0.72	7.5	0.22	0.44	0.4	0.01	0.23	7.1	0.2	0.45	0.45	6.5	0.19	0.84	4.6	0.13	8.2	0.24	1.9	0.05	3.9	0.11	2.5	0.07	21.9	0.63	
26	Russel w PG	24	2011-12	66	66	1	35.3	0.74	8.8	0.25	0.46	0.9	0.03	0.32	7.8	0.22	0.48	0.48	5.2	0.15	0.82	4.6	0.13	5.5	0.16	1.7	0.05	3.6	0.1	2.2	0.06	23.6	0.67	
27	Russel w PG	25	2012-13	82	82	1	34.9	0.73	8.2	0.24	0.44	1.2	0.03	0.32	7	0.2	0.47	0.47	5.6	0.16	0.8	5.2	0.15	7.4	0.21	1.8	0.05	3.3	0.09	2.3	0.07	23.2	0.66	
28	Russel w PG	26	2013-14	82	46	0.56	30.7	0.64	7.5	0.24	0.44	1.5	0.05	0.32	6	0.2	0.48	0.48	5.3	0.17	0.83	5.7	0.19	6.9	0.22	1.9	0.06	3.8	0.12	2.3	0.07	21.8	0.71	
29	Russel w PG	27	2014-15	82	67	0.82	34.4	0.72	9.4	0.27	0.43	1.3	0.04	0.3	8.1	0.24	0.46	0.46	8.1	0.24	0.84	7.3	0.21	8.6	0.25	2.1	0.06	4.4	0.13	2.7	0.08	28.1	0.82	
30	Russel w PG	28	2015-16	82	80	0.88	34.4	0.72	8.2	0.24	0.45	1.3	0.04	0.3	6.9	0.2	0.5	0.49	5.8	0.17	0.81	7.8	0.23	10.4	0.3	2	0.06	4.3	0.13	2.5	0.07	23.5	0.68	
31	Russel w PG	29	2016-17	82	81	0.99	34.6	0.72	10.2	0.29	0.43	2.5	0.07	0.34	7.7	0.22	0.46	0.48	8.8	0.25	0.85	10.7	0.31	10.4	0.3	1.6	0.05	5.4	0.16	2.3	0.07	31.6	0.91	
32	Russel w PG	30	2017-18	82	80	0.86	36.4	0.76	9.5	0.26	0.45	1.2	0.03	0.3	8.3	0.23	0.49	0.48	5.2	0.14	0.74	10.1	0.28	10.3	0.28	1.8	0.05	4.8	0.13	2.5	0.07	25.4	0.7	
33	Chris Pa PG	20	2005-06	82	78	0.95	36	0.75	5.2	0.14	0.43	0.6	0.02	0.28	4.6	0.13	0.46	0.46	5.1	0.14	0.85	5.1	0.14	7.8	0.22	2.2	0.06	2.3	0.08	2.8	0.08	16.1	0.45	
34	Chris Pa PG	21	2006-07	82	64	0.78	36.8	0.77	6	0.16	0.44	0.8	0.02	0.35	5.2	0.14	0.46	0.47	4.6	0.13	0.82	4.4	0.12	8.9	0.24	1.8	0.05	2.5	0.07	2.4	0.07	17.3	0.47	
35	Chris Pa PG	22	2007-08	82	80	0.88	37.6	0.78	7.9	0.21	0.49	1.2	0.03	0.37	6.7	0.18	0.52	0.52	4.2	0.11	0.85	4	0.11	11.6	0.31	2.7	0.07	2.5	0.07	2.3	0.06	21.1	0.56	
36	Chris Pa PG	23	2008-09	82	78	0.95	38.5	0.8	8.1	0.21	0.5	0.8	0.02	0.36	7.3	0.19	0.53	0.53	5.8	0.15	0.87	5.5	0.14	11	0.29	2.8	0.07	3	0.08	2.7	0.07	22.8	0.59	
37	Chris Pa PG	24	2009-10	82	45	0.55	38	0.79	7	0.18	0.49	1.2	0.03	0.41	5.8	0.15	0.51	0.53	3.6	0.09	0.85	4.2	0.11	10.7	0.28	2.1	0.06	2.5	0.07	2.6	0.07	18.7	0.49	
38	Chris Pa PG	25	2010-11	82	80	0.88	36	0.75	5.4	0.15	0.46	0.9	0.03	0.39	4.5	0.13	0.48	0.5	4.2	0.12	0.88	4.1	0.11	9.8	0.27	2.4	0.07	2.2	0.06	2.5	0.07	15.9	0.44	
39	Chris Pa PG	26	2011-12	66	60	0.91	35.4	0.76	7.1	0.2	0.48	1.3	0.04	0.37	5.8	0.16	0.51	0.52	4.3	0.12	0.86	3.6	0.1	9.1	0.25	2.5	0.07	2.1	0.06	2.3	0.06	19.8	0.54	
40	Chris Pa PG	27	2012-13	82	70	0.85	33.4	0.7	5.9	0.18	0.48	1.1	0.03	0.33	4.8	0.14	0.54	0.53	4.1	0.12	0.89	3.7	0.11	9.7	0.29	2.4	0.07	2.3	0.07	2	0.06	16.9	0.51	
41	Chris Pa PG	28	2013-14	82	62	0.76	35	0.73	6.5	0.19	0.47	1.3	0.04	0.37	5.3	0.15	0.5	0.5	4															

```

% Read data from CSV file
data = readtable('all_players_with_injuries.csv');

% Preprocess string column with one-hot encoding
categories = unique(data(:,2));
encodedCategories = eye(length(categories));
numCategories = size(encodedCategories, 2);
categoryIndices = zeros(size(data(:,2)));
for i = 1:length(categories)
    categoryIndices(strcmp(data(:,2), categories{i})) = i;
end
encodedCategoriesData = encodedCategories(categoryIndices, :);

% Combine encoded categories with other input columns
inputs = [encodedCategoriesData, data(:, [7, 8, 12, 19, 22, 29])];

% Split data into input and output variables
outputs = data(:, 33);

% Split data into 80-20 train-test sets
[trainInd, testInd] = dividerand(size(inputs, 1), 0.8, 0.2);
trainInputs = inputs(trainInd, :);
trainOutputs = outputs(trainInd, :);
testInputs = inputs(testInd, :);
testOutputs = outputs(testInd, :);

% Create neural network
net = feedforwardnet([8, 8, 8]);
net.trainParam.epochs = 1000;
net.trainParam.lr = 0.01;

% Train neural network
net = train(net, trainInputs', trainOutputs');

% Test neural network
predictedOutputs = net(testInputs');
mse = mean((predictedOutputs - testOutputs').^2);

% Test neural network
predictedOutputs = net(testInputs');
rmse = sqrt(mean((predictedOutputs - testOutputs').^2));
disp(['RMSE: ' num2str(rmse)]);
% Make predictions on test set
predictedOutputs = net(testInputs');

% Calculate accuracy
errors = abs((predictedOutputs - testOutputs') ./ testOutputs');
accuracy = 100 - mean(errors) * 100;
disp(['Accuracy: ' num2str(accuracy) '%']);

% Print examples of predictions and their accuracy
for i = 1:length(testOutputs)
    error = abs((predictedOutputs(i) - testOutputs(i)) / testOutputs(i));
    accuracy = 100 - error * 100;
    disp(['Example ' num2str(i) ': predicted=' num2str(predictedOutputs(i)) ', actual=' num2str(testOutputs(i)) ', accuracy=' num2str(accuracy) '%']);
end
% Train the neural network
net = feedforwardnet([8 8 8]);
net = train(net, trainInputs', trainOutputs');

% Make predictions on test set
predictedOutputs = net(testInputs');

% Calculate metrics
mse = mean((predictedOutputs - testOutputs').^2);
mae = mean(abs(predictedOutputs - testOutputs'));
rmse = sqrt(mse);
r = corrcoef(predictedOutputs, testOutputs');
r2 = r(1,2)^2;

% Print metrics
disp(['Mean Squared Error (MSE): ' num2str(mse)]);
disp(['Mean Absolute Error (MAE): ' num2str(mae)]);
disp(['Root Mean Squared Error (RMSE): ' num2str(rmse)]);
disp(['Coefficient of Determination (R^2): ' num2str(r2)]);

% Print examples of predictions and their accuracy
for i = 1:length(testOutputs)
    error = abs((predictedOutputs(i) - testOutputs(i)) / testOutputs(i));
    accuracy = 100 - error * 100;
    disp(['Example ' num2str(i) ': predicted=' num2str(predictedOutputs(i)) ', actual=' num2str(testOutputs(i)) ', accuracy=' num2str(accuracy) '%']);
end

% Plot training and testing losses
plot(net.trainRecord.perf);
hold on;
plot(net.trainRecord.tperf);
legend('Training Loss', 'Testing Loss');
xlabel('Epoch');
ylabel('Loss');
title('Training and Testing Losses');

```

Εικόνα 83: Ενδεικτικές εικόνες κώδικα MATLAB

ποσοστό αγώνων συμμετοχής	Η κάθε ομάδα αγωνίζεται σε 82 αγώνες. Από αυτούς τους αγώνες ο εκάστοτε αθλητής αγωνίζεται είτε σε όλους είτε σε μέρος των αγώνων αυτών. Οπότε σαν ποσοστό αγώνων συμμετοχής υπολογίζεται ο αριθμός των αγώνων στον οποίο αγωνίζεται ο αθλητής προς τον συνολικό αριθμό αγώνων της ομάδας (82 αγώνες συνήθως).
λεπτά συμμετοχής στην διάρκεια του αγώνα	Ο Μ.Ο. των λεπτών συμμετοχής που αγωνίζεται ο αθλητής με την ομάδα του (ή και άλλες) στην διάρκεια μίας κανονικής περιόδου πρωταθλήματος.
ποσοστό ευστοχίας σουτ ή αλλιώς FG%	Μ.Ο. συνολικών εύστοχων σουτ (είτε δίποντα είτε τρίποντα) προς τον συνολικό αριθμό προσπαθειών του.
Πραγματικό ποσοστό ευστοχίας σουτ ή αλλιώς eFG%	Υπολογίζονται από τον τύπο: $eFG = (FG + 0.5 * 3P) / FGA$ • Όπου FG εύστοχες προσπάθειες σουτ αθλητή (είτε τρίποντα είτε δίποντα). • Όπου 3P εύστοχες προσπάθειες σουτ τριών πόντων αθλητή. • Όπου FGA συνολικές προσπάθειες σουτ αθλητή (είτε εύστοχες είτε άστοχες).
ποσοστό ευστοχίας βολών ή αλλιώς FT%	Μ.Ο. εύστοχων προσπαθειών βολών προς τον συνολικό αριθμό προσπαθειών.
ΤΟV ή αλλιώς λάθη	Μ.Ο. λαθών ανά χρονιά.

Πίνακας 53: επεξήγηση στατιστικών (NBA.com)

Αναφορές

- (n.d.). Retrieved from <https://www.greecehighdefinition.com/blog/the-history-of-gambling-in-ancient-greece>
- (n.d.). Retrieved from <https://www.pxfuel.com/desktop-wallpaper-kkzdh>
- 360digit.b-cdn.net. (n.d.). Γραφική παράσταση Sigmoid. Retrieved March 2023, from <https://360digit.b-cdn.net/assets/admin/ckfinder/userfiles/images/blog/elu.png>
- Anderson, J. A. (1972). A perceptron learning algorithm for non-separable data. *IEEE Transactions on Systems, Man, and Cybernetics*, 2(4), pp. 718-724.
- Arjovsky, M. C. (2017). Wasserstein GAN. doi:1701.07875.
- basketball-reference.com. (2023, March). Στατιστικά καριέρας LeBron James από την ιστοσελίδα basketball-reference.com. Retrieved from <https://www.basketball-reference.com/players/j/jamesle01.html>
- Bengio, Y. C. (2013). A tutorial on deep learning. *Foundations and Trends in Machine Learning*. 1-127.
- Bengio, Y. S. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5, pp. 157-166.
- Bishop, C. M. (1995). *Neural networks for pattern recognition*. Oxford university press.
- Champions, N. (n.d.). Οι πιο πρόσφατοι πρωταθλητές NBA (εικόνα από <https://www.pxfuel.com/desktop-wallpaper-kkzdh>). (u. i. pxfuel, Ed.) Retrieved March 2023, from <https://www.pxfuel.com/desktop-wallpaper-kkzdh>
- Chen, X. D. (2016). In Advances in Neural Information Processing Systems. In *InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets*. (pp. 2172-2180).
- Chung, J. G. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. doi:1412.3555
- Clevert, D. A. (2016). Fast and accurate deep network learning by exponential linear units (ELUs). doi:1511.07289
- Cybenko, G. (1989). Multilayer feedforward networks are universal approximators. In *Neural Networks* (2(5) ed., pp. 359-366).

- dices, A. a. (2020, december). Retrieved from <https://www.greecehighdefinition.com/blog/the-history-of-gambling-in-ancient-greece>
- Duchi, J. H. (2011). Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*(12), pp. 2121-2159.
- fanduel (Ed.). (n.d.). Πιο πρόσφατες πρωταθλήτριες WNBA (εικόνα από τον λογαριασμό της fanduel στο Twitter). Retrieved March 2023, from <https://twitter.com/FanDuel/status/1571624954176602112>
- Gal, Y. &. (2016). A theoretically grounded application of dropout in recurrent neural networks. . In *In Advances in neural information processing systems* (pp. 1019-1027).
- Golden, M. (1998). *Sport in the Cultures of the Ancient World*. New York: Routledge.
- Goodfellow, I. J.-A.-F. (2014). Generative Adversarial Nets. In *Advances in Neural Information Processing Systems*.
- Google. (n.d.). Google Colab. Retrieved March 2023, from <https://colab.research.google.com/>
- Graves, A. (2012). Supervised sequence labelling with recurrent neural networks. *Springer*.
- Hahnloser, R. H. (2000). Digital selection and analogue amplification coexist in a cortex-inspired silicon circuit. *Nature*, 405(6789), 947-951.
- Haykin, S. (1994). *Neural networks: A comprehensive foundation*. Prentice-Hall.
- He, K. Z. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, (pp. 770-778).
- Hinton, G. (2013). Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning. Technical report, University of Toronto.
- Hinton, G. E. (2006). Reducing the dimensionality of data with neural networks.
- Hinton, G. O. (2006). A fast learning algorithm for deep belief net. In *Neural computation* (18(7) ed., pp. 1527-1554).
- Hochreiter, S. &. (1997). Neural computation,. In *Long short-term memory* (9(8) ed., pp. 1735-1780).
- Hopfield, J. J. (1982). Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the National Academy of Sciences*, (pp. 2554-2558).

- Hopfield, J. J. (1991). Computing with neural circuits: a model. . *Science*, 233(4764), (pp. 625-633).
- Ioffe, S. &. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. doi:1502.03167
- Jozefowicz, R. Z. (2015). An empirical exploration of recurrent network architectures. . *In International Conference on Machine Learning* , (pp. 2342-2350).
- Karpathy, A. (2015). Part 1 – Introduction to RNNs. In *Recurrent neural networks tutorial*. Retrieved from <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>
- Kingma, D. P. (2013). Auto-Encoding Variational Bayes . doi:1312.6114.
- Kingma, D. P. (2014). Adam: A method for stochastic optimization. doi:1412.6980
- Krizhevsky, A. S. (2012). ImageNet classification with deep convolutional neural networks. In *In Advances in neural information processing systems* (pp. 1097-1105).
- Kyle, D. (1998). *Sport and Spectacle in the Ancient World*. Blackwell Publishers.
- Le, Q. V. (2015). A simple way to initialize recurrent networks of rectified linear units. doi:1504.00941
- LeCun, Y. B. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, (pp. 2278-2324).
- LeCun, Y. B. (2015). The history of backpropagation. In *Neural Networks. IEEE Conference* , (pp. 3-13).
- LeCun, Y. B. (n.d.). Deep learning. *Nature*. 436-444. doi: 521(7553)
- Lipton, Z. C. (2015). Critical review of recurrent neural networks for sequence learning. . doi:1506.00019
- Little, W. A. (1986). In *Neural information processing systems*. In *Learning patterns in random networks*. (pp. 281-297).
- Martens, J. &. (2010). Deep learning via Hessian-free optimization. *In Proceedings of the 27th International Conference on Machine Learning (ICML-10)* , (pp. 735-742).
- Matlab. (n.d.). Retrieved from <https://www.mathworks.com/products/matlab.html>
- Matlab. (n.d.). Retrieved from <https://www.mathworks.com/products/matlab.html>
- Matlab. (2023). Retrieved March 2023, from Math Works: <https://www.mathworks.com/products/matlab.html>

- McCulloch, W. S. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 115-133.
- Miller, S. (2010). *Ancient Greek Athletics*. New Haven: Yale University Press.
- Minsky, M. &. (1969). Perceptrons: An introduction to computational geometry. *MIT Press*.
- Mirza, M. &. (2014). Conditional Generative Adversarial Nets.
- NBA Champions 2021-22: Golden State Warriors. (n.d.). Retrieved from <https://www.pxfuel.com/en/desktop-wallpaper-kkzdh>
- NBA.com. (n.d.). NBA metrics. Retrieved April 2023, from [nba.com](https://www.nba.com)
- NBAStuffer. (n.d.). Retrieved March 2023, from <https://www.nbastuffer.com/analytics101/nba-analytics-movement/#utilize>
- Ng, A. K. (2008). *Sparse autoencoder*. In *Proceedings of the 16th International Conference on Neural Information Processing Systems (NIPS'08)*, (pp. pp. 801-808).
- Olah, C. (2015). An introduction to recurrent neural networks. Retrieved from <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- Platt, J. C. (1998). Sequential minimal optimization: A fast algorithm for training support vector machines. *Machine learning*, 14(1), pp. 185-208.
- Platt, J. C. (1999). Fast training of support vector machines using sequential minimal optimization. . In *Advances in kernel methods* (pp. 185-208).
- Poggio, T. &. (2002). The mathematics of learning: Dealing with data. In *Notices of the American Mathematical Society*. (49(8) ed., pp. 922-932).
- Python. (n.d.). Retrieved from <https://www.python.org/>
- Radford, A. M. (2016). Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks.
- Robbins, H. &. (1951). A stochastic approximation method. *The annals of mathematical statistics*.
- Rosenblatt, F. (. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
- Rumelhart, D. E. (1986). Parallel Distributed Processing. In *A theory of the backpropagation neural network*. (1 ed., pp. 318-362).
- Sansone, D. (2003). Sport, Democracy and War in Classical Athens. *Cambridge: Cambridge University Press*.

- Schmidhuber, J. (2015). A brief history of neural nets and deep learning. In *Big data*. Springer, pp. 1-24.
- Schmidhuber, J. (2015). Neural Networks. In *Deep learning in neural networks: An overview*. (pp. 85-117).
- Schulz, R. E. (1991). Women and Athletics in the Ancient World. *Journal of Sport History* 18, 3, pp. 305-320.
- Simonyan, K. &. (2014). Very deep convolutional networks for large-scale image recognition. doi:1409.1556.
- (n.d.). *Sports Betting Market - Global Outlook and Forecast 2020-2024*. ResearchAndMarkets.
- Swaddling, J. (1999). The Ancient Olympic Games. . Austin: University of Texas Press.
- Szegedy, C. L. (2015). Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition* , (pp. 1-9).
- Tensorflow. (n.d.). Tensorflow. Retrieved March 2023, from <https://www.tensorflow.org/>
- Vincent, P. L. (2010, December 11). Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. . *Journal of Machine Learning Research*, pp. 3371-3408.
- Widrow, B. L. (1994). Neural networks: Applications in industry, business and science. *Communications of the ACM*. 37(3), 93-105. Retrieved from <https://www-isl.stanford.edu/~widrow/papers/j1994neuralnetworks.pdf>
- wikipedia. (n.d.). Δομή πρωταθλήματος NBA από wikipedia. Retrieved March 2023, from https://en.wikipedia.org/wiki/National_Basketball_Association
- wikipedia. (n.d.). Πρώιμη μορφή πρωταθλήματος WNBA. (wikipedia, Ed.) Retrieved March 2023, from https://en.wikipedia.org/wiki/Women%27s_National_Basketball_Association
- WNBA Format. (n.d.). Retrieved from https://en.wikipedia.org/wiki/Women%27s_National_Basketball_Association
- www.greecehighdefinition.com (Ed.). (2020, december). Τυχερά παίγνια «The history of gambling in ancient Greece», ο Αχιλλέας και Αίαντας παίζοντας ζάρια. Retrieved March 2023, from <https://www.greecehighdefinition.com/blog/the-history-of-gambling-in-ancient-greece>

www.researchgate.net. (2023, March). Γραφική παράσταση Relu. (researchgate, Ed.) Retrieved from https://www.researchgate.net/figure/ReLU-activation-function_fig7_333411007

www.researchgate.net. (n.d.). Γραφική παράσταση Elu. Retrieved March 2023, from https://www.researchgate.net/figure/Exponential-linear-units-ELU-function-curve-In-the-figure-x-represents-the-original_fig1_340674688

www.researchgate.net. (n.d.). Γραφική παράσταση Softmax. Retrieved March 2023, from https://www.researchgate.net/figure/Graphic-representation-of-the-softmax-activation-function_fig5_348703101

www.researchgate.net. (n.d.). Γραφική παράσταση Softsign. (researchgate, Ed.) Retrieved March 2023, from https://www.researchgate.net/figure/Curve-of-the-SoftSign-function_fig6_332295580

Zaremba, W. S. (2014). Recurrent neural network regularization. doi:1409.2329

Zurada, J. M. (1992). The theory of the perceptron: A geometric, non-statistical view. . *IEEE Transactions on Systems, Man, and Cybernetics*, 3, pp. 477-494.

Zurada, J. M. (n.d.). The theory of the perceptron: A geometric, non-statistical view. *IEEE Transactions on Systems, Man, and Cybernetics*, 22(3), pp. 477-494.

Εικόνα 1: Τυχρά παίγνια στην Αρχαία Ελλάδα. (n.d.). Retrieved from <https://www.greecehighdefinition.com/blog/the-history-of-gambling-in-ancient-greece>

Εικόνα 4: Στατιστικά LeBron James . (n.d.). Retrieved from www.basketball-reference.com

Εικόνα 8: Sigmoid figure. (n.d.). Retrieved from <https://360digit.b-cdn.net/assets/admin/ckfinder/userfiles/images/blog/elu.png>